

SISTEMA DE RECOMENDACIÓN HÍBRIDO EN PUEBLOS MÁGICOS: INTEGRACIÓN DE ANÁLISIS DE ASPECTOS Y OPTIMIZACIÓN

T E S I S

Que para obtener el grado de
Maestro en Cómputo Estadístico

Presenta

Gustavo Hernández Angeles

Director de Tesis:

Dr. Norberto Alejandro Hernández Leandro

Autorización de la versión final

A mi familia.

Agradecimientos

A mis padres Octavio y Abigail, quienes me han brindado un apoyo inmenso e incondicional. Son mi inspiración y fortaleza.

A mis hermanos, Arael y Javier, por su apoyo constante y por ser mis modelos a seguir.

A mis amigos, por hacer este camino más llevadero con risas y apoyo constante.

A Yazmin, por el gran apoyo, paciencia y alegrías continuas.

Resumen

Keywords: Recommendation Systems, Aspect-Based Sentiment Analysis, Hybrid Models, Optimization, Pueblos Mágicos

Índice general

Agradecimientos	III
Resumen	V
Índice de figuras	IX
1. Introducción	1
1.1. Trabajo previo	1
1.2. Hipótesis de trabajo	1
1.3. Objetivos	1
1.4. Contribución	1
1.5. Organización de la tesis	1
2. Conjunto de datos	3
2.1. La tarea compartida REST-MEX	3
2.2. Corpus REST-MEX 2025	4
2.3. Estructura y limpieza del dataset	5
2.4. Filtrado para densidad de interacciones	6
2.5. Dataset de trabajo	6
3. Marco teórico	9
3.1. Sistemas de recomendación	9
3.1.1. Filtrado colaborativo	10
3.1.2. Filtrado basado en contenido	13
3.1.3. Sistemas híbridos	14
3.1.4. Problema del arranque en frío y dispersión	15
3.2. Procesamiento de lenguaje natural	18
3.2.1. Representación de texto	18
3.2.2. Arquitectura Transformer	18
3.3. Análisis de sentimientos basado en aspectos	18
3.3.1. Subtareas del ABSA	18
3.3.2. Clasificación Zero-Shot	18
3.3.3. Análisis de sentimientos con modelos pre-entrenados	18
3.4. Optimización metaheurística	18
3.4.1. Optimización por enjambre de partículas (PSO)	18

3.4.2. Optimización bayesiana	18
3.4.3. Evolución diferencial	18
3.5. Métricas de evaluación	18
3.5.1. Métricas de ranking	18
3.5.2. Métricas beyond-accuracy	18
3.6. Explicabilidad en sistemas de recomendación	18
4. Análisis Exploratorio	19
4.1. Bases de datos	19
5. Modelación espacio-temporal	21
5.1. Modelos espaciales	21
6. Conclusiones y trabajo futuro	23
Referencias	25
A. Anexo	29

Índice de figuras

4.1. Selección de 7 estados de la República Mexicana para la modelación. Este mapa fue construido con el uso de <code>ggmap</code> (?) y requirió la activación de los servicios de Google Maps.	19
5.1. Gráfica Acíclica Dirigida de la representación jerárquica del modelo Poisson-Gamma.	22

Capítulo 1

Introducción

El aumento exponencial de información generada por los usuarios en plataformas digitales ha transformado la manera en que las organizaciones comprenden y responden a las necesidades y preferencias de sus clientes.

1.1. Trabajo previo

1.2. Hipótesis de trabajo

1.3. Objetivos

1.4. Contribución

1.5. Organización de la tesis

Capítulo 2

Conjunto de datos

En este capítulo se describe el origen, estructura y preprocesamiento del conjunto de datos utilizado en esta tesis. El corpus proviene de la tarea compartida REST-MEX 2025, organizada en el marco de IberLEF 2025. Se detalla el contexto del evento, la composición del dataset original, y el proceso de filtrado aplicado para obtener una matriz de interacciones con densidad suficiente para el entrenamiento de sistemas de recomendación.

2.1. La tarea compartida REST-MEX

REST-MEX (*Researching Sentiment Evaluation in Text for Mexican Magical Towns*) es una tarea compartida organizada dentro del foro de evaluación IberLEF (*Iberian Languages Evaluation Forum*), cuyo objetivo es establecer referencias comparativas (*benchmarks*) para sistemas de procesamiento de lenguaje natural en el ámbito del turismo mexicano (Álvarez-Carmona y cols., 2025).

La tarea se lanzó en 2021 con un enfoque en la predicción de polaridad de reseñas turísticas en español (Álvarez-Carmona y cols., 2021). En ediciones subsecuentes, se incorporó la clasificación del tipo de servicio reseñado (hotel, restaurante o atractivo) (Álvarez-Carmona y cols., 2022) y la identificación del país de origen de la reseña (Álvarez-Carmona y cols., 2023). La edición 2025 marca la cuarta iteración del evento e introduce cambios significativos: (i) la clasificación geográfica se refina a nivel de

Pueblo Mágico específico (40 pueblos predefinidos), (ii) el corpus se amplía considerablemente, y (iii) se fomenta el uso de técnicas avanzadas como ingeniería de *prompts*, binarización de clases y selección de instancias basada en centroides.

En esta edición, 32 equipos participantes enviaron un total de 70 sistemas válidos, explorando una amplia variedad de enfoques que incluyen modelos basados en Transformers, aprendizaje por transferencia, esquemas de binarización y estrategias de selección de instancias (Álvarez-Carmona y cols., 2025). La tarea se estructura en tres subtareas simultáneas que, dada una reseña turística, requieren determinar:

1. La **polaridad** del sentimiento, en una escala ordinal de 1 (muy malo) a 5 (muy bueno).
2. El **tipo de servicio** reseñado: *Attractive*, *Hotel* o *Restaurant*.
3. El **Pueblo Mágico** específico al que refiere la reseña, seleccionado de una lista predefinida de 40 destinos.

Si bien la Tarea 4 del evento REST-MEX contempla la construcción de un sistema de recomendación para Pueblos Mágicos, en esta tesis se extiende dicho planteamiento incorporando análisis de sentimientos basado en aspectos y optimización metaheurística para la fusión de componentes, aspectos que no están contemplados en la formulación original del evento.

2.2. Corpus REST-MEX 2025

El corpus REST-MEX 2025 consta de 297,217 escritas por turistas que visitaron destinos representativos de México y compartieron sus opiniones en la plataforma TripAdvisor entre 2002 y 2024 (Álvarez-Carmona y cols., 2025). Cada reseña está etiquetada con una calificación de polaridad en una escala ordinal de cinco puntos $\{1, 2, 3, 4, 5\}$, el tipo de negocio (*Attractive*, *Hotel*, *Restaurant*) y el Pueblo Mágico correspondiente.

El corpus presenta un notable desbalance de clases en los tres ejes de clasificación. En el eje de polaridad, la clase 5 (muy bueno) concentra el 65.6 % de las instancias

de entrenamiento (136,561 de 208,051), mientras que las clases 1 y 2 representan conjuntamente menos del 5.3 %. En el eje geográfico, tres pueblos (Tulum, Isla Mujeres y San Cristóbal de las Casas) concentran el 42.2 % de las instancias.

Para los fines de esta tesis, se recopiló un conjunto extendido de reseñas a partir de los archivos fuente del evento. El proceso de carga concatenó 1,559 archivos CSV, resultando en un dataset crudo de 313,836 registros con 12 columnas originales.

2.3. Estructura y limpieza del dataset

Cada registro del dataset crudo contiene los siguientes campos:

Tabla 2.1: Esquema del dataset crudo de reseñas turísticas.

Campo	Tipo	Descripción
Author	Texto	Seudónimo del usuario en TripAdvisor
Titulo	Texto	Título de la reseña
Review	Texto	Cuerpo de la reseña
Calificacion	Númerico	Calificación numérica (1–5)
OrigenAutor	Texto	País de origen del autor
FechaOpinion	Fecha	Fecha de publicación de la reseña
FechaEstadia	Fecha	Mes y año de la estancia
Pueblo	Texto	Pueblo Mágico del establecimiento
Estado	Texto	Estado de la república
Pais	Texto	País del establecimiento
Tipo	Texto	Tipo de servicio (Hotel/Restaurant/Attractive)
Lugar	Texto	Nombre del establecimiento

El proceso de limpieza consistió en:

1. **Eliminación de columnas redundantes:** se descartaron `OrigenAutor` (53.5 % de valores nulos), `FechaOpinion` (redundante con `FechaEstadia`) y `Pais` (valor constante “Mexico”).
2. **Eliminación de registros incompletos:** se eliminaron filas con valores nulos en los campos `Author`, `Calificacion`, `Review` o `FechaEstadia`, reduciendo el dataset de 313,836 a **306,854 registros**.

3. **Conversión de fechas:** el campo `FechaEstadia`, originalmente en formato textual en español (e.g., “enero de 2023”), se convirtió a formato `datetime` mediante un mapeo de nombres de meses en español a sus equivalentes numéricos.

El dataset limpio resultante contiene 9 columnas y abarca estancias desde 2001 hasta 2023.

2.4. Filtrado para densidad de interacciones

Para el entrenamiento de algoritmos de filtrado colaborativo, es necesario que la matriz de interacciones usuario-ítem presente una densidad mínima que permita calcular similitudes confiables entre usuarios o entre ítems. El dataset limpio de 306,854 reseñas contiene un gran número de usuarios que han reseñado establecimientos en un solo Pueblo Mágico, lo cual resulta insuficiente para la tarea de recomendación a nivel de pueblos.

Se diseñó un procedimiento de filtrado iterativo con dos criterios de densidad:

1. **Usuarios activos:** retener únicamente usuarios que hayan reseñado establecimientos en al menos $\tau_u = 3$ Pueblos Mágicos distintos.
2. **Pueblos con cobertura:** retener únicamente Pueblos Mágicos que contengan al menos $\tau_p = 10$ establecimientos (*Lugares*) distintos con reseñas.

Dado que la eliminación de usuarios puede dejar pueblos sin cobertura suficiente (y viceversa), el filtrado se aplica de forma iterativa hasta convergencia, es decir, hasta que ningún registro adicional sea eliminado. El Algoritmo 1 formaliza este procedimiento.

2.5. Dataset de trabajo

La aplicación del filtrado iterativo con $\tau_u = 3$ y $\tau_p = 10$ reduce el dataset de 306,854 a **79,264 registros**, correspondientes a **9,582 usuarios** y **48 Pueblos Mágicos**. La Tabla 2.2 resume las estadísticas principales antes y después del filtrado.

Algorithm 1 Filtrado iterativo para densidad de interacciones.

Require: Dataset $\mathcal{D}$, umbrales τ_u, τ_p **Ensure:** Dataset filtrado $\mathcal{D}'$

```

1:  $\mathcal{D}' \leftarrow \mathcal{D}$ 
2: repeat
3:    $n_{\text{prev}} \leftarrow |\mathcal{D}'|$ 
4:    $\mathcal{U}_{\text{dense}} \leftarrow \{u \in \mathcal{U} \mid |\{p : \exists r \in \mathcal{D}' \text{ con } r.\text{Author} = u, r.\text{Pueblo} = p\}| \geq \tau_u\}$ 
5:    $\mathcal{D}' \leftarrow \{r \in \mathcal{D}' \mid r.\text{Author} \in \mathcal{U}_{\text{dense}}\}$ 
6:    $\mathcal{P}_{\text{dense}} \leftarrow \{p \in \mathcal{P} \mid |\{l : \exists r \in \mathcal{D}' \text{ con } r.\text{Pueblo} = p, r.\text{Lugar} = l\}| \geq \tau_p\}$ 
7:    $\mathcal{D}' \leftarrow \{r \in \mathcal{D}' \mid r.\text{Pueblo} \in \mathcal{P}_{\text{dense}}\}$ 
8: until  $|\mathcal{D}'| = n_{\text{prev}}$ 
9: return  $\mathcal{D}'$ 

```

Tabla 2.2: Estadísticas del dataset antes y después del filtrado de densidad.

Métrica	Dataset limpio	Dataset filtrado
Reseñas totales	306,854	79,264
Usuarios únicos	—	9,582
Pueblos Mágicos	—	48
Mín. pueblos/usuario	1	3
Máx. pueblos/usuario	—	28
Mín. lugares/pueblo	—	10

La distribución de pueblos en el dataset filtrado presenta un marcado desbalance geográfico. Tulum es el pueblo con mayor representación (10,051 títulos únicos), seguido de Isla Mujeres (6,082) y San Cristóbal de las Casas (4,902), mientras que pueblos como Tecate (175), San Sebastián del Oeste (193) y Santiago (242) tienen una representación considerablemente menor.

En términos de la matriz de utilidad para el sistema de recomendación—donde las filas representan usuarios y las columnas Pueblos Mágicos—la dispersión (*sparsity*) se calcula como:

$$\text{sparsity} = 1 - \frac{|\{(u, p) : \exists r \in \mathcal{D}'\}|}{|\mathcal{U}| \times |\mathcal{P}|} = 1 - \frac{n_{\text{interacciones}}}{9,582 \times 48} \approx 90.32\% \quad (2.1)$$

Esta dispersión del 90.32 % implica que cada usuario ha interactuado, en promedio, con menos de 5 de los 48 pueblos disponibles. En cuanto a las calificaciones, la media global es $\bar{r} = 4.41$ con el 61.3 % de las calificaciones siendo de 5 estrellas, reflejando el

sesgo positivo característico de las plataformas de reseñas turísticas. Estos desafíos—alta dispersión y desbalance en calificaciones—motivan la adopción de un enfoque híbrido que combine señales colaborativas con información semántica extraída de las reseñas textuales, como se detalla en los capítulos subsecuentes.

Capítulo 3

Marco teórico

En este capítulo se presentan los fundamentos teóricos que sustentan el desarrollo de la metodología en este trabajo. Se abordan tres ejes principales: los sistemas de recomendación, el procesamiento de lenguaje natural con enfoque en el análisis de sentimientos basado en aspectos, y las técnicas de optimización metaheurística en las secciones 3.1, 3.3 y 3.4, respectivamente. Adicionalmente, en la sección 3.5 se discuten las métricas de evaluación, y en la sección 3.6 los fundamentos de explicabilidad en sistemas de recomendación.

3.1. Sistemas de recomendación

Un sistema de recomendación (SR) es un sistema de filtrado de información diseñado para predecir la preferencia o utilidad que un usuario asignaría a un ítem con el cual no ha interactuado previamente (Raza y cols., 2025). Formalmente, el problema se define como la estimación de una función de utilidad:

$$\hat{r}_{ui} = f(u, i; \Theta) \tag{3.1}$$

donde $u \in \mathcal{U}$ representa un usuario, $i \in \mathcal{I}$ un ítem, Θ los parámetros del modelo y $\hat{r}_{ui}$ la calificación predicha. El conjunto de interacciones observadas se organiza en una *matriz de utilidad* $\mathbf{R} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|}$, donde r_{ui} denota la calificación que el usuario u

asignó al ítem i , y la mayoría de las entradas permanecen desconocidas (Adomavicius y Tuzhilin, 2005).

Los métodos de recomendación se clasifican tradicionalmente en tres familias: filtrado colaborativo, filtrado basado en contenido y sistemas híbridos (Raza y cols., 2025; Sarkar, Majumder, Panigrahi, Roy, y Pati, 2023). A continuación se formalizan cada una de estas aproximaciones.

3.1.1. Filtrado colaborativo

El filtrado colaborativo (FC) se fundamenta en la hipótesis de que usuarios con comportamientos similares en el pasado tendrán preferencias similares en el futuro (Raza y cols., 2025). El FC no requiere información sobre las características de los ítems; opera exclusivamente sobre la matriz de interacciones $\mathbf{R}$. Los métodos de FC se dividen en dos categorías: basados en memoria y basados en modelo.

Basado en memoria

Los métodos basados en memoria (*neighborhood-based*) generan predicciones directamente a partir de las interacciones históricas, sin aprender un modelo paramétrico explícito. Se distinguen dos variantes: basado en usuarios (*user-based*) y basado en ítems (*item-based*).

FC basado en usuarios. La predicción para un usuario u sobre un ítem i se calcula como el promedio ponderado de las calificaciones de los usuarios más similares a u que han calificado el ítem i :

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v) \cdot (r_{vi} - \bar{r}_v)}{\sum_{v \in \mathcal{N}_k(u)} |\text{sim}(u, v)|} \quad (3.2)$$

donde $\bar{r}_u$ es la calificación promedio del usuario u , $\mathcal{N}_k(u)$ denota los k vecinos más similares a u que han calificado el ítem i , y $\text{sim}(u, v)$ es una medida de similitud

entre usuarios. Las medidas más utilizadas son la similitud coseno y la correlación de Pearson:

$$\text{sim}_{\cos}(u, v) = \frac{\sum_{i \in \mathcal{I}_{uv}} r_{ui} \cdot r_{vi}}{\sqrt{\sum_{i \in \mathcal{I}_{uv}} r_{ui}^2} \cdot \sqrt{\sum_{i \in \mathcal{I}_{uv}} r_{vi}^2}} \quad (3.3)$$

$$\text{sim}_{\text{Pearson}}(u, v) = \frac{\sum_{i \in \mathcal{I}_{uv}} (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum_{i \in \mathcal{I}_{uv}} (r_{ui} - \bar{r}_u)^2} \cdot \sqrt{\sum_{i \in \mathcal{I}_{uv}} (r_{vi} - \bar{r}_v)^2}} \quad (3.4)$$

donde $\mathcal{I}_{uv} = \{i \in \mathcal{I} \mid r_{ui} \neq 0 \wedge r_{vi} \neq 0\}$ es el conjunto de ítems co-calificados por ambos usuarios.

FC basado en ítems. De manera análoga, la similitud se calcula entre ítems en lugar de entre usuarios. La predicción se obtiene como (Linden, Smith, y York, 2003):

$$\hat{r}_{ui} = \frac{\sum_{j \in \mathcal{N}_k(i)} \text{sim}(i, j) \cdot r_{uj}}{\sum_{j \in \mathcal{N}_k(i)} |\text{sim}(i, j)|} \quad (3.5)$$

donde $\mathcal{N}_k(i)$ son los k ítems más similares a i que el usuario u ha calificado. Este enfoque tiende a ser más escalable que el basado en usuarios cuando $|\mathcal{U}| \gg |\mathcal{I}|$, ya que las similitudes entre ítems son más estables en el tiempo.

Ambas variantes enfrentan limitaciones inherentes: la complejidad computacional para el cálculo de similitudes es $O(|\mathcal{U}|^2 \cdot |\mathcal{I}|)$ u $O(|\mathcal{I}|^2 \cdot |\mathcal{U}|)$, su rendimiento se degrada en matrices con alta dispersión, y no pueden generar recomendaciones para usuarios o ítems nuevos (este problema es conocido como *cold-start*, se abordará en la sección 3.1.4).

Basado en modelo

Los métodos basados en modelo aprenden una representación paramétrica compacta de los patrones de interacción. La técnica más establecida es la **factorización**

matricial (FM), que descompone la matriz de utilidad en el producto de dos matrices de menor dimensionalidad (Koren, Bell, y Volinsky, 2009):

$$\mathbf{R} \approx \mathbf{P}\mathbf{Q}^\top \quad (3.6)$$

donde $\mathbf{P} \in \mathbb{R}^{|\mathcal{U}| \times k}$ y $\mathbf{Q} \in \mathbb{R}^{|\mathcal{I}| \times k}$ representan las matrices de factores latentes de usuarios e ítems, respectivamente, y $k \ll \min(|\mathcal{U}|, |\mathcal{I}|)$ es la dimensionalidad del espacio latente. Cada fila $\mathbf{p}_u \in \mathbb{R}^k$ codifica las preferencias del usuario u , y cada fila $\mathbf{q}_i \in \mathbb{R}^k$ las características latentes del ítem i , de modo que la predicción se obtiene como:

$$\hat{r}_{ui} = \mathbf{p}_u^\top \mathbf{q}_i \quad (3.7)$$

En el contexto de REST-MEX, los k factores latentes podrían capturar dimensiones implícitas como la preferencia por aspectos culturales, gastronómicos o naturales de los Pueblos Mágicos, aunque su naturaleza latente impide una interpretación directa—limitación que motiva la incorporación de aspectos explícitos vía ABSA (Sección 3.3).

Para estimar los parámetros, se minimiza el error cuadrático regularizado sobre las interacciones observadas $\mathcal{K}$:

$$\min_{\mathbf{P}, \mathbf{Q}} \sum_{(u,i) \in \mathcal{K}} (r_{ui} - \mathbf{p}_u^\top \mathbf{q}_i)^2 + \lambda (\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2) \quad (3.8)$$

donde $\lambda > 0$ es el coeficiente de regularización que previene el sobreajuste. Esta optimización se resuelve típicamente mediante descenso por gradiente estocástico (SGD) o mínimos cuadrados alternados (ALS).

Se consideran las siguientes variantes relevantes para este trabajo:

- **SVD** (*Singular Value Decomposition*): Extiende la Ecuación (3.7) incorporando sesgos de usuario e ítem:

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^\top \mathbf{q}_i \quad (3.9)$$

donde μ es la media global de calificaciones, b_u el sesgo del usuario y b_i el sesgo del ítem.

- **SVD++**: Incorpora retroalimentación implícita al modelo SVD, enriqueciendo la representación del usuario con información de los ítems que ha calificado (Koren, 2008):

$$\hat{r}_{ui} = \mu + b_u + b_i + \left(\mathbf{p}_u + |\mathcal{I}_u|^{-\frac{1}{2}} \sum_{j \in \mathcal{I}_u} \mathbf{y}_j \right)^\top \mathbf{q}_i \quad (3.10)$$

donde $\mathcal{I}_u$ es el conjunto de ítems calificados por u y $\mathbf{y}_j \in \mathbb{R}^k$ son vectores que capturan la influencia implícita de haber interactuado con el ítem j .

- **NMF** (*Non-negative Matrix Factorization*): Impone la restricción $\mathbf{P} \geq 0$, $\mathbf{Q} \geq 0$, lo que produce representaciones aditivas más interpretables, donde cada factor latente contribuye exclusivamente de forma positiva a la predicción.

En este trabajo se emplea la biblioteca Surprise (Hug, 2020) para la implementación de los algoritmos de FC, la cual provee implementaciones de KNNBasic, KNN-WithMeans, SVD, SVD++ y NMF, entre otros.

3.1.2. Filtrado basado en contenido

El filtrado basado en contenido (FBC) recomienda ítems cuyas características son similares a las de ítems previamente preferidos por el usuario (Pazzani y Billsus, 2007; Raza y cols., 2025). Se construyen dos representaciones vectoriales:

- **Perfil del ítem** $\phi(i) \in \mathbb{R}^d$: un vector de d características que describe al ítem i .
- **Perfil del usuario** $\theta(u) \in \mathbb{R}^d$: una agregación de los perfiles de ítems con los que el usuario ha interactuado, típicamente ponderada por las calificaciones otorgadas.

La predicción se obtiene mediante la similitud entre ambos perfiles:

$$\hat{r}_{ui} = \text{sim}(\boldsymbol{\theta}(u), \boldsymbol{\phi}(i)) = \frac{\boldsymbol{\theta}(u)^\top \boldsymbol{\phi}(i)}{\|\boldsymbol{\theta}(u)\| \cdot \|\boldsymbol{\phi}(i)\|} \quad (3.11)$$

En el contexto de esta tesis, las características de los ítems no provienen de metadatos estáticos sino de las reseñas textuales, procesadas mediante análisis de sentimientos basado en aspectos (ABSA, Sección 3.3). Concretamente, el perfil de un Pueblo Mágico se construye como un vector de sentimientos por aspecto:

$$\boldsymbol{\phi}(i) = (s_{i,1}, s_{i,2}, \dots, s_{i,A}) \quad (3.12)$$

donde $s_{i,a}$ es el sentimiento agregado del aspecto a (e.g., *servicio*, *gastronomía*, *naturaleza*) para el pueblo i , y A es el número de aspectos definidos. El perfil del usuario se obtiene como el promedio ponderado de los perfiles de los pueblos que ha visitado:

$$\boldsymbol{\theta}(u) = \frac{1}{|\mathcal{I}_u|} \sum_{i \in \mathcal{I}_u} r_{ui} \cdot \boldsymbol{\phi}(i) \quad (3.13)$$

La principal ventaja del FBC sobre el FC es su capacidad de mitigar el *cold-start* de ítems: un nuevo Pueblo Mágico puede ser recomendado tan pronto como se disponga de reseñas textuales, sin necesidad de calificaciones numéricas previas. Su limitación principal es la sobre-especialización, ya que tiende a recomendar ítems similares a los ya conocidos por el usuario, reduciendo la diversidad de las recomendaciones.

3.1.3. Sistemas híbridos

Los sistemas híbridos combinan múltiples estrategias de recomendación para compensar las debilidades individuales de cada enfoque (Raza y cols., 2025; Sarkar y cols., 2023). (Burke, 2002) propuso una taxonomía ampliamente adoptada que identifica siete estrategias de hibridación: *weighted*, *switching*, *mixed*, *feature combination*, *cascade*, *feature augmentation* y *meta-level*.

En esta tesis se adopta una estrategia de **combinación ponderada**, donde la pre-

dicción final es una combinación lineal convexa de las predicciones de los componentes colaborativo y basado en contenido:

$$\hat{r}_{ui} = \alpha \cdot \hat{r}_{ui}^{\text{CF}} + (1 - \alpha) \cdot \hat{r}_{ui}^{\text{CBF}} \quad (3.14)$$

donde $\alpha \in [0, 1]$ controla la contribución relativa de cada componente. Esta formulación se extiende naturalmente a un vector de pesos $\boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_M)$ cuando se combinan M señales de recomendación, sujeto a $\sum_{m=1}^M \alpha_m = 1$.

La determinación de los pesos óptimos constituye en sí un problema de optimización no convexo, cuya solución se aborda mediante técnicas metaheurísticas (Sección 3.4). Esta aproximación—donde los aspectos y sentimientos extraídos por el componente NLP enriquecen las características del sistema colaborativo—ha demostrado ser efectiva en dominios donde la información textual complementa las calificaciones numéricas. (Musto, de Gemmis, Semeraro, y Lops, 2017) mostraron que un FC multi-criterio alimentado con sentimientos por aspecto extraídos automáticamente de reseñas supera tanto a algoritmos de un solo criterio como a técnicas de factorización matricial. De manera similar, (Zhang y cols., 2014) propusieron el *Explicit Factor Model* (EFM), que integra factores explícitos (aspectos y opiniones extraídos de reseñas) con factores latentes en un modelo unificado, demostrando mejoras tanto en predicción de calificaciones como en la calidad de las explicaciones generadas.

3.1.4. Problema del arranque en frío y dispersión

Dos desafíos fundamentales afectan el rendimiento de los SR, particularmente relevantes en el dominio turístico (Sarkar y cols., 2023): el *cold-start* y la dispersión de la matriz de utilidad. La primera se manifiesta en dos variantes:

- **De usuario:** usuarios nuevos sin historial de calificaciones, para los cuales el FC no puede calcular similitudes. El FBC puede mitigar este problema si se dispone de información demográfica o preferencias explícitas iniciales.
- **De ítem:** ítems nuevos sin calificaciones, invisibles para el FC. En este trabajo,

el pipeline de ABSA permite generar un perfil de aspectos para un nuevo Pueblo Mágico a partir de sus reseñas textuales, habilitando recomendaciones basadas en contenido sin historial de calificaciones numéricas.

La dispersión del 90.32 % en el dataset REST-MEX implica que cada usuario ha calificado, en promedio, menos de 5 de los 48 pueblos disponibles. Este nivel de dispersión degrada significativamente el rendimiento de los métodos basados en memoria, ya que la cantidad de ítems co-calificados entre pares de usuarios ($|\mathcal{I}_{uv}|$) tiende a ser pequeña, resultando en estimaciones de similitud poco confiables (Raza y cols., 2025). Las principales estrategias de mitigación incluyen: (i) factorización matricial, que generaliza patrones a partir de factores latentes aun con matrices dispersas; (ii) incorporación de información lateral (*side information*), como las reseñas textuales; y (iii) sistemas híbridos que combinan señales complementarias (Payandenick, Othman, y Payandenick, 2025).

3.2. Procesamiento de lenguaje natural

3.2.1. Representación de texto

3.2.2. Arquitectura Transformer

3.3. Análisis de sentimientos basado en aspectos

3.3.1. Subtareas del ABSA

3.3.2. Clasificación Zero-Shot

3.3.3. Análisis de sentimientos con modelos pre-entrenados

3.4. Optimización metaheurística

3.4.1. Optimización por enjambre de partículas (PSO)

3.4.2. Optimización bayesiana

3.4.3. Evolución diferencial

3.5. Métricas de evaluación

3.5.1. Métricas de ranking

Precision@K y Recall@K

NDCG@K

MRR (Mean Reciprocal Rank)

3.5.2. Métricas beyond-accuracy

Diversidad

Cobertura

3.6. Explicabilidad en sistemas de recomendación

Capítulo 4

Análisis Exploratorio

4.1. Bases de datos



Figura 4.1: Selección de 7 estados de la República Mexicana para la modelación. Este mapa fue construido con el uso de ggmap (?) y requirió la activación de los servicios de Google Maps.

Capítulo 5

Modelación espacio-temporal

5.1. Modelos espaciales

Modelo Poisson-Gamma

Para este tipo de modelos es posible utilizar representaciones gráficas que reflejen la estructura de dependencias en la jerarquía. Esta representación es conocida como *Grafo Acíclico Dirigido* (DAG). Las aristas conectan los niveles de la jerarquía y los parámetros son los vértices al final de las aristas (flechas). Es importante establecer un límite en la jerarquía ya que no es posible asumir una jerarquía de parámetros infinita. Usualmente el punto de corte se elige donde la variación de los hiperparámetros ya no afecta al nivel más bajo del modelo (primer nivel). En este punto los parámetros se asumen como valores fijos. Por ejemplo en el modelo *Poisson-Gamma* si se fijan α y β entonces la distribución a priori *Gamma* será fija y los datos no nos darán información acerca de la distribución en lo absoluto. Sin embargo podemos permitir un nivel mayor de variación asignando hiperdistribuciones a priori para α y β , fijando los valores de ν y ρ sin afectar radicalmente el nivel más bajo de variación. La [Figura 5.1](#) muestra el DAG para el modelo *Poisson-Gamma* de dos niveles (?).




Figura 5.1: Gráfica Acíclica Dirigida de la representación jerárquica del modelo Poisson-Gamma.

Capítulo 6

Conclusiones y trabajo futuro

Referencias

- Adomavicius, G., y Tuzhilin, A. (2005, junio). Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6), 734–749. doi: 10.1109/TKDE.2005.99
- Álvarez-Carmona, M. Á., Arce-Cardenas, S., Fajardo-Delgado, D., Guerrero-Rodríguez, R., López-Monroy, A. P., Martínez-Miranda, J., ... Rodríguez-González, A. Y. (2021). Overview of REST-MEX at IberLEF 2021: Recommendation System for Mexican Tourist Texts. En *Procesamiento del Lenguaje Natural*.
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Bustio-Martínez, L., y Herrera-Semenets, V. (2025, septiembre). Overview of Rest-Mex at IberLEF 2025: Researching Sentiment Evaluation in Text for Mexican Magical Towns. *Procesamiento del Lenguaje Natural*, 75, 499–511. doi: 10.26342/2025-75-37
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Muñiz-Sánchez, V., López-Monroy, A. P., ... Bustio-Martínez, L. (2022). Overview of REST-MEX at IberLEF 2022: Recommendation System, Sentiment Analysis and COVID Semaphore Prediction for Mexican Tourist Texts. *Procesamiento del Lenguaje Natural*, 69, 289–299.
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Muñiz-Sánchez, V., López-Monroy, A. P., ... Bustio-Martínez, L. (2023). Overview of REST-MEX at IberLEF 2023: Research on Sentiment Analysis Task for Mexican Tourist Texts. *Procesamiento del Lenguaje Natural*, 71, 425–436.

- Burke, R. (2002, noviembre). Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, 12(4), 331–370. doi: 10.1023/A:1021240730564
- Hug, N. (2020). Surprise: A Python library for recommender systems. *Journal of Open Source Software*, 5(52), 2174. doi: 10.21105/joss.02174
- Koren, Y. (2008). Factorization Meets the Neighborhood: a Multifaceted Collaborative Filtering Model. En *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 426–434). New York, NY, USA: Association for Computing Machinery. doi: 10.1145/1401890.1401944
- Koren, Y., Bell, R., y Volinsky, C. (2009, agosto). Matrix Factorization Techniques for Recommender Systems. *Computer*, 42(8), 30–37. doi: 10.1109/MC.2009.263
- Linden, G., Smith, B., y York, J. (2003). Amazon.com Recommendations: Item-to-Item Collaborative Filtering. *IEEE Internet Computing*, 7(1), 76–80. doi: 10.1109/MIC.2003.1167344
- Musto, C., de Gemmis, M., Semeraro, G., y Lops, P. (2017, agosto). A Multi-criteria Recommender System Exploiting Aspect-based Sentiment Analysis of Users' Reviews. En *Proceedings of the Eleventh ACM Conference on Recommender Systems* (pp. 321–325). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/3109859.3109905> doi: 10.1145/3109859.3109905
- Payandenick, M., Othman, M. K., y Payandenick, M. (2025, noviembre). A multi-criteria recommendation system for personalised tourism experiences with user query analysis. *Information Technology & Tourism*, 28(1), 3. Descargado de <https://doi.org/10.1007/s40558-025-00348-w> doi: 10.1007/s40558-025-00348-w
- Pazzani, M. J., y Billsus, D. (2007). Content-Based Recommendation Systems. En *The Adaptive Web* (pp. 325–341). Springer. doi: 10.1007/978-3-540-72079-9_10
- Raza, S., Rahman, M., Kamawal, S., Toroghi, A., Raval, A., Navah, F., y Kazeemini, A. (2025, octubre). *A Comprehensive Review of Recommender Sys-*

- tems: Transitioning from Theory to Practice*. arXiv. Descargado de <http://arxiv.org/abs/2407.13699> (arXiv:2407.13699 [cs]) doi: 10.48550/arXiv.2407.13699
- Sarkar, J. L., Majumder, A., Panigrahi, C. R., Roy, S., y Pati, B. (2023, marzo). Tourism recommendation system: a survey and future research directions. *Multimedia Tools and Applications*, 82(6), 8983–9027. Descargado de <https://doi.org/10.1007/s11042-022-12167-w> doi: 10.1007/s11042-022-12167-w
- Zhang, Y., Lai, G., Zhang, M., Zhang, Y., Liu, Y., y Ma, S. (2014, julio). Explicit factor models for explainable recommendation based on phrase-level sentiment analysis. En *Proceedings of the 37th international ACM SIGIR conference on Research & development in information retrieval* (pp. 83–92). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/2600428.2609579> doi: 10.1145/2600428.2609579

Apéndice A

Anexo

