

SISTEMA DE RECOMENDACIÓN HÍBRIDO EN PUEBLOS MÁGICOS: INTEGRACIÓN DE ANÁLISIS DE ASPECTOS Y OPTIMIZACIÓN

T E S I S

Que para obtener el grado de
Maestro en Cómputo Estadístico

Presenta

Gustavo Hernández Angeles

Director de Tesis:

Dr. Norberto Alejandro Hernández Leandro

Autorización de la versión final

Agradecimientos

Expreso mi agradecimiento al Dr. Norberto Alejandro Hernández Leandro por su asesoría, así como a los doctores Alejandro Rosales Pérez y Miguel Ángel Álvarez Carmona, integrantes de mi comité, cuyo acompañamiento fue fundamental para este proyecto.

Al Centro de Investigación en Matemáticas (CIMAT), le agradezco el haberme recibido para realizar mis estudios de posgrado y al profesorado por la sólida formación técnica recibida en diversas áreas.

Asimismo, reconozco a la Secretaría de Ciencia, Humanidades, Tecnología e Innovación (SECIHTI) por el financiamiento otorgado, el cual permitió la conclusión exitosa de mi maestría.

A mis padres Octavio y Abigail. Su amor y sacrificio han sido fundamentales para cumplir mis metas. Gracias por ser un ejemplo de que cualquier obstáculo puede superarse. Espero que mis logros académicos sean un reflejo de su dedicación.

A mis hermanos, Arael y Javier. Han sido siempre un modelo a seguir para mí, sé que siempre puedo aprender más de ustedes. Gracias por siempre mostrar su apoyo y comprensión.

A Yazmin. Tu apoyo incondicional ha sido una fuente de fortaleza para mí. Gracias por ser la mejor compañía tanto en los momentos difíciles como en los felices.

Finalmente, a mis amigos y compañeros de clase, por hacer este camino mucho más ameno y por su apoyo constante.

Resumen

Índice general

Agradecimientos	I
Resumen	III
Índice de figuras	VII
Índice de tablas	IX
1. Introducción	1
1.1. Motivación	1
1.2. Hipótesis de trabajo	2
1.3. Objetivos	3
1.4. Contribución	3
1.5. Organización de la tesis	4
2. Conjunto de datos	5
2.1. La tarea compartida REST-MEX	5
2.2. Corpus	6
2.3. Estructura y limpieza	6
2.4. Filtrado para densidad de interacciones	7
2.5. Dataset de trabajo	8
3. Marco teórico	11
3.1. Sistemas de recomendación	11
3.1.1. Filtrado colaborativo	12
3.1.2. Filtrado basado en contenido	14
3.1.3. Sistemas híbridos	16
3.1.4. Problema del arranque en frío y dispersión	18
3.1.5. Evaluación	19
3.2. Procesamiento de Lenguaje Natural	22
3.2.1. Representación de texto	22
3.2.2. Análisis de sentimientos basado en aspectos	23
3.2.3. Detección de fronteras de oración	24
3.2.4. Clasificación zero-shot vía NLI	26
3.2.5. Transformers para clasificación de sentimiento	27
3.3. Sistemas de recomendación con ABSA	28

3.3.1. Filtrado colaborativo multicriterio (Musto et al., 2017)	28
3.3.2. Modelo de Factores Explícitos — EFM (Zhang et al., 2014) . .	29
3.4. Optimización metaheurística	30
3.4.1. Evolución diferencial	30
3.4.2. Optimización por enjambre de partículas (PSO)	30
3.4.3. Optimización bayesiana	30
3.5. Explicabilidad en sistemas de recomendación	30
4. Metodología y Resultados	31
5. Conclusiones y trabajo futuro	33
Referencias	35
A. Anexo	39

Índice de figuras

3.1. Taxonomía de las tareas de ABSA. Reconstruido de W. Zhang, Li, Deng, Bing, y Lam (2023).	25
---	----

Índice de tablas

2.1. Esquema del dataset crudo de reseñas turísticas.	7
2.2. Estadísticas del dataset antes y después del filtrado de densidad. . . .	8

Capítulo 1

Introducción

Los Sistemas de Recomendación (SR) se han convertido en una herramienta fundamental en la era digital tanto para las empresas como para los usuarios, facilitando la toma de decisiones en un entorno saturado de información y mejorando la interacción del usuario con el producto o servicio. Estos beneficios se extienden a diversos sectores, incluyendo el comercio electrónico, el entretenimiento, aplicaciones móviles, entre otros (Raza y cols., 2025). En particular, en el sector turístico, los usuarios se enfrentan a un amplio catálogo de opciones aun cuando se restringen a su propio país, lo que hace que los SR sean cruciales para ayudar a los turistas a encontrar sus Puntos de Interés (PI) ideales (She, Haw, y Chew, 2020). Este escenario es especialmente relevante en México, donde la diversidad de destinos turísticos y la riqueza cultural hacen que la elección de un destino sea una tarea compleja para los turistas. Este es el problema que abordaremos en esta tesis.

1.1. Motivación

Actualmente, el sector turístico representa un pilar importante para la economía de México, impulsando el desarrollo regional y contribuyendo de manera directa al bienestar de la población. Este impacto se refleja en contribuciones considerables al Producto Interno Bruto del país (8.7% en 2024), generando empleo y atrayendo inversiones tanto nacionales como extranjeras (SECTUR, 2025). Uno de los programas turísticos más emblemáticos propuesto por la Secretaría de Turismo (SECTUR), es el programa de Pueblos Mágicos (PM), que busca promover destinos turísticos en localidades pequeñas con características culturales, históricas o naturales únicas. Se ha observado que la iniciativa de los PM ha resultado ser beneficioso para estas comunidades tanto económica como culturalmente (Fernández Poncela, 2016). Es por esto que desarrollar un SR efectivo para recomendar Pueblos Mágicos a los turistas no solo tiene el potencial de mejorar la experiencia del usuario, sino también de contribuir al desarrollo sostenible de estas comunidades y a la promoción del turismo nacional.

Sin embargo, los turistas se enfrentan a un problema de elección considerable: a

inicios del año 2026, el programa contempla 177 localidades distribuidas a lo largo del territorio nacional. Los SR basados únicamente en el historial de valoraciones presentan limitaciones estructurales en este contexto: los datos de reseñas de Pueblos Mágicos exhiben una alta dispersión y un marcado sesgo positivo en las calificaciones, estos rasgos degradan la capacidad predictiva del filtrado colaborativo clásico (Koren, Bell, y Volinsky, 2009). Múltiples propuestas de Sistemas de Recomendación Híbridos (SRH) han demostrado ser efectivos para suavizar la limitación de la dispersión, añadiendo módulos de recomendación basados en contenido o en conocimiento que puedan complementar la predicción de preferencias (Hossain, Sikder, y Andreou, 2025), por lo que esta dirección se presenta como una solución prometedora para el caso de los Pueblos Mágicos.

Al mismo tiempo, las reseñas textuales que acompañan a las valoraciones contienen información semántica valiosa sobre aspectos específicos del destino que los enfoques basados exclusivamente en calificaciones numéricas no aprovechan. El Análisis de Sentimientos Basado en Aspectos (*Aspect-Based Sentiment Analysis*, ABSA) ha surgido como una alternativa para extraer preferencias a nivel fino a partir de texto (W. Zhang y cols., 2023). Integrar ABSA en un SR permite construir perfiles de usuario y de destino multidimensionales que capturan la importancia relativa de cada aspecto turístico para cada viajero y la calidad asociada a cada aspecto en cada destino.

Es por esto que en este trabajo se propone un SRH para Pueblos Mágicos que integra cuatro componentes complementarios: CF clásico mediante factorización de matrices (SVD), CF multicriterio basado en perfiles de sentimiento por aspecto, y dos variantes de recomendación basada en contenido que explotan la atención del usuario y la calidad del destino a nivel de aspecto. La información aspecto-sentimiento se extrae mediante una cadena de procesamiento ABSA aplicada al corpus de reseñas del conjunto de datos REST-MEX (Álvarez-Carmona y cols., 2021), que registra opiniones sobre hoteles, restaurantes y atractivos de Pueblos Mágicos. Los pesos de fusión entre componentes se optimizan mediante búsqueda metaheurística con el objetivo de maximizar métricas de calidad o diversidad, produciendo así recomendaciones más precisas, diversas y explicables que las ofrecidas por cualquier componente individual (Burke, 2002).

1.2. Hipótesis de trabajo

La hipótesis de esta tesis es que la integración de información aspecto-sentimiento extraída de reseñas textuales en un sistema de recomendación híbrido mejora la precisión, diversidad y explicabilidad de las recomendaciones de Pueblos Mágicos respecto a enfoques basados únicamente en calificaciones numéricas.

1.3. Objetivos

Objetivo general

Diseñar, implementar y evaluar un sistema de recomendación híbrido para Pueblos Mágicos de México, que integre múltiples componentes colaborativos y basados en contenido, cuyos pesos de fusión se calibren mediante algoritmos metaheurísticos.

Objetivos específicos

1. Preparar el corpus de trabajo a partir del dataset REST-MEX 2025 (Álvarez-Carmona y cols., 2025), realizando una limpieza de datos y aplicando un filtrado iterativo que garantice una densidad mínima en la matriz de interacciones.
2. Implementar una cadena de procesamiento ABSA en español para el dominio turístico, compuesta por segmentación de reseñas, clasificación *Zero-Shot* de aspectos turísticos y clasificación de sentimiento.
3. Derivar las matrices estructurales del sistema que relacionen los usuarios y los items, además de evaluar matrices propuestas por la literatura que relacionan tanto usuarios como items con los aspectos y su sentimiento asociado (Musto, de Gemmis, Semeraro, y Lops, 2017).
4. Implementar cuatro componentes de recomendación complementarios: (i) filtrado colaborativo clásico mediante factorización matricial con sesgos (Koren y cols., 2009), (ii) filtrado colaborativo multicriterio basado en perfiles sentimentales por aspecto, (iii) filtrado basado en contenido por correspondencia entre atención de usuario y calidad de pueblo, y (iv) filtrado basado en contenido sobre perfiles de atención.
5. Formular la fusión de componentes como un problema de optimización continua, y compararla mediante al menos dos metaheurísticas representativas: Evolución Diferencial, Enjambre de Partículas y/o Optimización Bayesiana.
6. Evaluar el sistema bajo un protocolo de validación por *leave-one-out* por usuario, reportando métricas de precisión de ranking y de diversidad.
7. Diseñar un módulo de explicabilidad que, aprovechando los perfiles aspecto-sentimiento, genere justificaciones interpretables de cada recomendación en términos de aspectos valorados por el usuario y aspectos destacados del pueblo recomendado.

1.4. Contribución

Las contribuciones de este trabajo se organizan en cuatro planos:

Contribución metodológica. Se propone una arquitectura híbrida de cuatro componentes cuyas señales son complementarias por construcción. La fusión se formula como problema de optimización continua, lo cual permite adaptar el sistema a diferentes objetivos operativos (precisión o diversidad) sin rediseñar los componentes.

Contribución técnica. Se libera el framework *mtrs*, una implementación modular y reproducible que incluye: (i) el pipeline ABSA productivo para español turístico con dos estrategias de segmentación (*Punkt* y *char-based*), (ii) las rutinas de construcción de las matrices estructurales del sistema, y (iii) las implementaciones de los cuatro recomendadores.

Contribución aplicada. El sistema desarrollado constituye una herramienta potencialmente útil para el sector turístico mexicano al producir recomendaciones de Pueblos Mágicos. Al permitir modular la diversidad del catálogo expuesto, el sistema contribuye al objetivo de la SECTUR de distribuir los flujos turísticos hacia destinos menos visibles pero igualmente valiosos (SECTUR, 2025).

1.5. Organización de la tesis

Capítulo 2

Conjunto de datos

En este capítulo se describe el origen, estructura y preprocesamiento del conjunto de datos utilizado en este trabajo. El corpus proviene de la tarea compartida REST-MEX 2025 (Álvarez-Carmona y cols., 2025), organizada en el marco de IberLEF 2025 (González-Barba, Chiruzzo, y Jiménez-Zafra, 2025). Se detalla el contexto del evento, la composición del dataset original, y el proceso de filtrado aplicado para obtener una matriz de interacciones con densidad suficiente para el entrenamiento de sistemas de recomendación.

2.1. La tarea compartida REST-MEX

REST-MEX (*Research on Sentiment Analysis Task for Mexican Tourist Texts*) es una tarea compartida organizada dentro del foro de evaluación IberLEF (*Iberian Languages Evaluation Forum*), cuyo objetivo es establecer referencias comparativas (*benchmarks*) para sistemas de procesamiento de lenguaje natural en el ámbito del turismo mexicano.

La tarea se lanzó en 2021 con un enfoque en la predicción de polaridad de reseñas turísticas en español (Álvarez-Carmona y cols., 2021). En ediciones subsecuentes, se incorporó la clasificación del tipo de servicio reseñado (hotel, restaurante o atractivo) (Álvarez-Carmona y cols., 2022) y la identificación del país de origen de la reseña (Álvarez-Carmona y cols., 2023). La edición 2025 marca la cuarta iteración del evento e introduce cambios significativos: (i) la clasificación geográfica se refina a nivel de Pueblo Mágico específico (40 pueblos predefinidos), (ii) el corpus se amplía considerablemente, y (iii) se fomenta el uso de técnicas avanzadas como ingeniería de *prompts*, binarización de clases y selección de instancias basada en centroides.

En esta edición, 32 equipos participantes enviaron un total de 70 sistemas válidos, explorando una amplia variedad de enfoques que incluyen modelos basados en Transformers, aprendizaje por transferencia, esquemas de binarización y estrategias de selección de instancias (Álvarez-Carmona y cols., 2025). La tarea se estructura en

tres subtareas simultáneas que, dada una reseña turística, requieren determinar:

1. La **polaridad** del sentimiento, en una escala ordinal de 1 (muy malo) a 5 (muy bueno).
2. El **tipo de servicio** reseñado: *Attractive*, *Hotel* o *Restaurant*.
3. El **Pueblo Mágico** específico al que refiere la reseña, seleccionado de una lista predefinida de 40 destinos.

2.2. Corpus

El corpus REST-MEX 2025 consta de 297,217 escritas por turistas que visitaron destinos representativos de México y compartieron sus opiniones en la plataforma TripAdvisor entre 2001 y 2023. Cada reseña está etiquetada con una calificación de polaridad en una escala ordinal de cinco puntos $\{1, 2, 3, 4, 5\}$, el tipo de negocio (*Attractive*, *Hotel*, *Restaurant*) y el Pueblo Mágico correspondiente.

El corpus presenta un notable desbalance de clases en los tres ejes de clasificación. En el eje de polaridad, la clase 5 (muy bueno) concentra el 65.6 % de las instancias de entrenamiento (136,561 de 208,051), mientras que las clases 1 y 2 representan conjuntamente menos del 5.3 %. En el eje geográfico, tres pueblos (Tulum, Isla Mujeres y San Cristóbal de las Casas) concentran el 42.2 % de las instancias.

Para los fines de esta tesis, se recopiló un conjunto extendido de reseñas a partir de los archivos fuente del evento, resultando en un conjunto de datos crudo de 313,836 registros con 12 columnas originales.

2.3. Estructura y limpieza

Cada registro del dataset crudo contiene los siguientes campos:

El proceso de limpieza consistió en:

- **Eliminación de columnas redundantes:** se descartó el origen del autor (53.5 % de valores nulos), la fecha de la opinión (redundante con la fecha de la estadía) y el país (valor constante “Mexico”).
- **Eliminación de registros incompletos:** se eliminaron filas con valores nulos en los campos *Author*, *Calificacion*, *Review* o *FechaEstadia*, reduciendo el dataset de 313,836 a **306,854 registros**.
- **Conversión de fechas:** el campo *FechaEstadia*, originalmente en formato textual en español (e.g., “enero de 2023”), se convirtió a formato *datetime* mediante un mapeo de nombres de meses en español a sus equivalentes numéricos.

Tabla 2.1: Esquema del dataset crudo de reseñas turísticas.

Campo	Tipo	Descripción
Author	Texto	Seudónimo del usuario en TripAdvisor
Titulo	Texto	Título de la reseña
Review	Texto	Cuerpo de la reseña
Calificacion	Númeroico	Calificación numérica (1–5)
OrigenAutor	Texto	País de origen del autor
FechaOpinion	Fecha	Fecha de publicación de la reseña
FechaEstadia	Fecha	Mes y año de la estancia
Pueblo	Texto	Pueblo Mágico del establecimiento
Estado	Texto	Estado de la república
Pais	Texto	País del establecimiento
Tipo	Texto	Tipo de servicio (Hotel/Restaurant/Attractive)
Lugar	Texto	Nombre del establecimiento

El dataset limpio resultante contiene 9 columnas y abarca estancias desde 2001 hasta 2023.

2.4. Filtrado para densidad de interacciones

Para el entrenamiento de algoritmos de filtrado colaborativo, es necesario que la matriz de interacciones usuario-ítem presente una densidad mínima que permita calcular similitudes confiables entre usuarios o entre ítems. El dataset limpio de 306,854 reseñas contiene un gran número de usuarios que han reseñado establecimientos en un solo Pueblo Mágico, lo cual resulta insuficiente para la tarea de recomendación a nivel de pueblos.

Se diseñó un procedimiento de filtrado iterativo con dos criterios de densidad (Algoritmo 1):

- **Usuarios activos:** retener únicamente usuarios que hayan reseñado establecimientos en al menos $\tau_u = 3$ Pueblos Mágicos distintos.
- **Pueblos con cobertura:** retener únicamente Pueblos Mágicos que contengan al menos $\tau_p = 10$ establecimientos (*Lugares*) distintos con reseñas.

Dado que la eliminación de usuarios puede dejar pueblos sin cobertura suficiente (y viceversa), el filtrado se aplica de forma iterativa hasta convergencia, es decir, hasta que ningún registro adicional sea eliminado. El Algoritmo 1 formaliza este procedimiento.

Algorithm 1 Filtrado iterativo para densidad de interacciones.

Require: Dataset $\mathcal{D}$, umbrales τ_u, τ_p **Ensure:** Dataset filtrado $\mathcal{D}'$

```

1:  $\mathcal{D}' \leftarrow \mathcal{D}$ 
2: repeat
3:    $n_{\text{prev}} \leftarrow |\mathcal{D}'|$ 
4:    $\mathcal{U}_{\text{dense}} \leftarrow \{u \in \mathcal{U} \mid |\{p : \exists r \in \mathcal{D}' \text{ con } r.\text{Author} = u, r.\text{Pueblo} = p\}| \geq \tau_u\}$ 
5:    $\mathcal{D}' \leftarrow \{r \in \mathcal{D}' \mid r.\text{Author} \in \mathcal{U}_{\text{dense}}\}$ 
6:    $\mathcal{P}_{\text{dense}} \leftarrow \{p \in \mathcal{P} \mid |\{l : \exists r \in \mathcal{D}' \text{ con } r.\text{Pueblo} = p, r.\text{Lugar} = l\}| \geq \tau_p\}$ 
7:    $\mathcal{D}' \leftarrow \{r \in \mathcal{D}' \mid r.\text{Pueblo} \in \mathcal{P}_{\text{dense}}\}$ 
8: until  $|\mathcal{D}'| = n_{\text{prev}}$ 
9: return  $\mathcal{D}'$ 

```

2.5. Dataset de trabajo

La aplicación del filtrado iterativo con $\tau_u = 3$ y $\tau_p = 10$ reduce el dataset de 306,854 a **79,264 registros**, correspondientes a **9,582 usuarios** y **48 Pueblos Mágicos**. La Tabla 2.2 resume las estadísticas principales antes y después del filtrado.

Tabla 2.2: Estadísticas del dataset antes y después del filtrado de densidad.

Métrica	Dataset limpio	Dataset filtrado
Reseñas totales	306,854	79,264
Usuarios únicos	159,468	9,582
Pueblos Mágicos	95	48
Mín. pueblos/usuario	1	3
Máx. pueblos/usuario	35	28
Mín. lugares/pueblo	1	10
Máx. lugares/pueblo	103	103

La distribución de pueblos en el dataset filtrado presenta un marcado desbalance geográfico. Tulum es el pueblo con mayor representación (10,051 títulos únicos), seguido de Isla Mujeres (6,082) y San Cristóbal de las Casas (4,902), mientras que pueblos como Tecate (175), San Sebastián del Oeste (193) y Santiago (242) tienen una representación considerablemente menor.

En términos de la matriz de utilidad para el sistema de recomendación—donde las filas representan usuarios y las columnas Pueblos Mágicos—la dispersión (*sparsity*) se calcula como:

$$\text{sparsity} = 1 - \frac{|\{(u, p) : \exists r \in \mathcal{D}'\}|}{|\mathcal{U}| \times |\mathcal{P}|} = 1 - \frac{n_{\text{interacciones}}}{9,582 \times 48} \approx 90.32\% \quad (2.1)$$

Esta dispersión del 90.32 % implica que cada usuario ha interactuado, en promedio, con menos de 5 de los 48 pueblos disponibles. En cuanto a las calificaciones, la media

global es $\bar{r} = 4.41$ con el 61.3 % de las calificaciones siendo de 5 estrellas, reflejando el sesgo positivo característico de las plataformas de reseñas turísticas. Estos desafíos—alta dispersión y desbalance en calificaciones—motivan la adopción de un enfoque híbrido que combine señales colaborativas con información semántica extraída de las reseñas textuales, como se detalla en los capítulos subsecuentes.

Capítulo 3

Marco teórico

En este capítulo se presentan los fundamentos teóricos que sustentan el desarrollo de la metodología en este trabajo. Se abordan cinco ejes principales: los sistemas de recomendación junto con sus métricas de evaluación (Sección 3.1); los fundamentos de procesamiento de lenguaje natural sobre los que se construye la extracción de aspectos y sentimientos a partir de las reseñas (Sección 3.2); los modelos de recomendación que incorporan la información extraída por ABSA como señal explícita (Sección 3.3); las técnicas de optimización metaheurística empleadas para la fusión de componentes (Sección 3.4); y los fundamentos de explicabilidad en sistemas de recomendación (Sección 3.5).

3.1. Sistemas de recomendación

Un sistema de recomendación (SR) es un sistema de filtrado de información diseñado para predecir una puntuación que refleje la experiencia real de un usuario con respecto a un ítem con el cual no ha interactuado previamente. Formalmente, el problema se define como la estimación de una función de utilidad:

$$\hat{r}_{u,i} = f(u, i; \Theta) \quad (3.1)$$

donde $f : \mathcal{U} \times \mathcal{I} \rightarrow \mathbb{R}$ es un escalar, $u \in \mathcal{U}$ representa un usuario, $i \in \mathcal{I}$ un ítem, Θ los parámetros del modelo y $\hat{r}_{u,i} \in \mathbb{R}$ es la puntuación que el SR asigna al ítem i para el usuario u . De forma general, el conjunto de interacciones observadas $\mathcal{O} = \{(u, i) \mid a_{u,i} \neq 0\}$ se organiza en una *matriz de interacciones* $\mathbf{A} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|}$, donde $a_{u,i}$ denota la interacción entre el usuario u y el ítem i , y las mayoría de las entradas permanecen desconocidas (Adomavicius y Tuzhilin, 2005).

Además, la interacción $a_{u,i}$ entre un usuario y un ítem puede ser definida de distintas formas, siendo la más común como una *calificación asignada*. La escala de la calificación varía conforme a los sistemas, la mayoría utilizan la escala 1-5 estrellas, mientras que otros pueden utilizar escalas binarias (interesado/no interesado). La

interacción también puede ser definida como una *retroalimentación implícita*, haciendo referencia a variables de acción por parte del usuario con respecto a un ítem (Oard, Kim, y cols., 1998). En este caso, las escalas de las interacciones pueden ser muy diversas, prácticamente, podría ser cualquier interacción usuario - ítem que funcione como señal del gusto o disgusto del usuario (e.g. tiempo de lectura en un libro, número de reproducciones de una canción, etc.).

El problema de inferencia en los SR consiste en estimar $\hat{r}_{u,i}$ para todo par $(u, i) \notin \mathcal{O}$. A partir de estas predicciones, las recomendaciones para el usuario u se obtienen seleccionando los K ítems no visitados con mayor puntuación estimada:

$$\text{Top-}K(u) = \arg \text{top-}K \hat{r}_{u,i} \quad (3.2)$$

$$i \in \mathcal{I} \setminus \mathcal{I}_u$$

donde $\mathcal{I}_u = \{i \in \mathcal{I} \mid a_{u,i} \neq 0\}$ es el conjunto de ítems con los que el usuario u ya ha interactuado.

Los SR se clasifican tradicionalmente en tres familias: filtrado colaborativo, filtrado basado en contenido y sistemas híbridos (Sarkar, Majumder, Panigrahi, Roy, y Pati, 2023). La diferencia entre los enfoques radica en cómo se parametriza f y qué información se utiliza para estimar Θ . A continuación se formalizan cada una de estas aproximaciones.

3.1.1. Filtrado colaborativo

El filtrado colaborativo (FC) se fundamenta en la hipótesis de que usuarios con comportamientos similares en el pasado tendrán preferencias similares en el futuro. El FC no requiere información sobre las características de los ítems; opera exclusivamente sobre la matriz de calificaciones $R \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|}$. Los métodos de FC se dividen en dos categorías: basados en memoria y basados en modelo.

Basado en memoria

Los métodos basados en memoria generan predicciones directamente a partir de las interacciones históricas, sin aprender un modelo paramétrico explícito ($\Theta = \emptyset$). Se distinguen dos variantes: basado en usuarios y basado en ítems.

- **FC basado en usuarios.** La predicción para un usuario u sobre un ítem i se calcula como el promedio ponderado de las calificaciones de los usuarios más similares a u que han calificado el ítem i :

$$\hat{r}_{u,i} = \bar{r}_u + \frac{\sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v) \cdot (r_{v,i} - \bar{r}_v)}{\sum_{v \in \mathcal{N}_k(u)} |\text{sim}(u, v)|} \quad (3.3)$$

donde $\bar{r}_u$ es la calificación promedio del usuario u , $\mathcal{N}_k(u)$ denota los k vecinos más similares a u que han calificado el ítem i , y $\text{sim}(u, v)$ es una medida de similitud entre usuarios. Las medidas más utilizadas son la similitud coseno (Eq. 3.4) y la correlación de Pearson (Eq. 3.5):

$$\text{sim}_{\cos}(u, v) = \frac{\sum_{i \in \mathcal{I}_{u,v}} r_{u,i} \cdot r_{v,i}}{\sqrt{\sum_{i \in \mathcal{I}_{u,v}} r_{u,i}^2} \cdot \sqrt{\sum_{i \in \mathcal{I}_{u,v}} r_{v,i}^2}} \quad (3.4)$$

$$\text{sim}_{\text{Pearson}}(u, v) = \frac{\sum_{i \in \mathcal{I}_{u,v}} (r_{u,i} - \bar{r}_u)(r_{v,i} - \bar{r}_v)}{\sqrt{\sum_{i \in \mathcal{I}_{u,v}} (r_{u,i} - \bar{r}_u)^2} \cdot \sqrt{\sum_{i \in \mathcal{I}_{u,v}} (r_{v,i} - \bar{r}_v)^2}} \quad (3.5)$$

donde $\mathcal{I}_{uv} = \{i \in \mathcal{I} \mid r_{ui} \neq 0 \wedge r_{vi} \neq 0\}$ es el conjunto de ítems co-calificados por ambos usuarios.

- **FC basado en ítems.** De manera análoga, la similitud se calcula entre ítems en lugar de entre usuarios. La predicción se obtiene como:

$$\hat{r}_{ui} = \frac{\sum_{j \in \mathcal{N}_k(i)} \text{sim}(i, j) \cdot r_{uj}}{\sum_{j \in \mathcal{N}_k(i)} |\text{sim}(i, j)|} \quad (3.6)$$

donde $\mathcal{N}_k(i)$ son los k ítems más similares a i que el usuario u ha calificado. Este enfoque tiende a ser más escalable que el basado en usuarios cuando $|\mathcal{U}| \gg |\mathcal{I}|$, ya que las similitudes entre ítems son más estables en el tiempo.

Ambas variantes enfrentan limitaciones inherentes: la complejidad computacional para el cálculo de similitudes es $O(|\mathcal{U}|^2 \cdot |\mathcal{I}|)$ u $O(|\mathcal{I}|^2 \cdot |\mathcal{U}|)$, su rendimiento se degrada en matrices con alta dispersión, y no pueden generar recomendaciones para usuarios o ítems nuevos (este problema es conocido como *cold-start*, se abordará en la sección 3.1.4).

Basado en modelo

Los métodos basados en modelo aprenden una representación paramétrica compacta de los patrones de interacción. La técnica más establecida es la **factorización matricial** (FM), que descompone la matriz de utilidad en el producto de dos matrices de menor dimensionalidad (Koren y cols., 2009):

$$\mathbf{R} \approx \mathbf{P}\mathbf{Q}^\top \quad (3.7)$$

donde $\mathbf{P} \in \mathbb{R}^{|\mathcal{U}| \times k}$ y $\mathbf{Q} \in \mathbb{R}^{|\mathcal{I}| \times k}$ representan las matrices de factores latentes de usuarios e ítems, respectivamente, y $k \ll \min(|\mathcal{U}|, |\mathcal{I}|)$ es la dimensionalidad del espacio latente. Cada fila $\mathbf{p}_u \in \mathbb{R}^k$ codifica las preferencias del usuario u , y cada fila $\mathbf{q}_i \in \mathbb{R}^k$ las características latentes del ítem i , de modo que la predicción se obtiene como:

$$\hat{r}_{ui} = \mathbf{p}_u^\top \mathbf{q}_i \quad (3.8)$$

Para estimar los parámetros, se minimiza el error cuadrático regularizado sobre las interacciones observadas $\mathcal{K}$:

$$\min_{\mathbf{P}, \mathbf{Q}} \sum_{(u,i) \in \mathcal{K}} (r_{ui} - \mathbf{p}_u^\top \mathbf{q}_i)^2 + \lambda (\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2) \quad (3.9)$$

donde $\lambda > 0$ es el coeficiente de regularización que previene el sobreajuste. Esta optimización se resuelve típicamente mediante descenso por gradiente estocástico (SGD) o mínimos cuadrados alternados (ALS).

Se consideran las siguientes variantes relevantes para este trabajo:

- **SVD** (*Singular Value Decomposition*): Extiende la Ecuación (3.8) incorporando sesgos de usuario e ítem:

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^\top \mathbf{q}_i \quad (3.10)$$

donde μ es la media global de calificaciones, b_u el sesgo del usuario y b_i el sesgo del ítem.

- **SVD++**: Incorpora retroalimentación implícita al modelo SVD, enriqueciendo la representación del usuario con información de los ítems que ha calificado (Koren, 2008):

$$\hat{r}_{ui} = \mu + b_u + b_i + \left(\mathbf{p}_u + |\mathcal{I}_u|^{-\frac{1}{2}} \sum_{j \in \mathcal{I}_u} \mathbf{y}_j \right)^\top \mathbf{q}_i \quad (3.11)$$

donde $\mathcal{I}_u$ es el conjunto de ítems calificados por u y $\mathbf{y}_j \in \mathbb{R}^k$ son vectores que capturan la influencia implícita de haber interactuado con el ítem j .

- **NMF** (*Non-negative Matrix Factorization*): Impone la restricción $\mathbf{P} \geq 0$, $\mathbf{Q} \geq 0$, lo que produce representaciones aditivas más interpretables, donde cada factor latente contribuye exclusivamente de forma positiva a la predicción.

3.1.2. Filtrado basado en contenido

El filtrado basado en contenido (FBC) recomienda ítems cuyas características son similares a las de ítems previamente preferidos por el usuario (Pazzani y Billsus, 2007). A diferencia del FC, el FBC opera sobre una descripción explícita de los atributos de

los ítems y no requiere información de otros usuarios. Arquitectónicamente, un sistema de FBC se compone de tres módulos (Lops, de Gemmis, y Semeraro, 2011): (1) un *analizador de contenido* que extrae características de los ítems a partir de su descripción, (2) un *aprendiz de perfil* que construye y actualiza el modelo de preferencias del usuario a partir de su historial de interacciones, y (3) un *componente de filtrado* que genera recomendaciones comparando el perfil del usuario con las representaciones de los ítems candidatos.

Representación de ítems

Cuando los ítems se describen mediante texto no estructurado (reseñas, artículos, descripciones de productos), la representación más empleada es el **Modelo de Espacio Vectorial** (VSM) con ponderación TF-IDF (Aggarwal, 2016; Lops y cols., 2011). Dado un corpus de N documentos y un diccionario $T = \{t_1, \dots, t_n\}$, el peso del término t_k en el documento d_j se define como:

$$\text{TF-IDF}(t_k, d_j) = \frac{f_{k,j}}{\max_z f_{z,j}} \cdot \log \frac{N}{n_k} \quad (3.12)$$

donde $f_{k,j}$ es la frecuencia de t_k en d_j , $\max_z f_{z,j}$ normaliza por el término más frecuente del documento, y n_k es el número de documentos en los que t_k aparece al menos una vez. El ítem i queda representado como el vector normalizado $\phi(i) \in \mathbb{R}^{|T|}$ de sus pesos TF-IDF. Cuando los ítems poseen atributos estructurados (e.g. género cinematográfico, valoración numérica por categoría, sentimiento promedio por aspecto derivado de reseñas), el perfil del ítem se construye directamente como un vector $\phi(i) \in \mathbb{R}^d$ de d características, produciendo representaciones más compactas e interpretables (Y. Zhang y cols., 2014).

Perfil del usuario y predicción

El perfil del usuario $\theta(u) \in \mathbb{R}^d$ se construye como el promedio ponderado por calificación de los perfiles de ítems con los que ha interactuado:

$$\theta(u) = \frac{\sum_{i \in \mathcal{I}_u} r_{u,i} \cdot \phi(i)}{\sum_{i \in \mathcal{I}_u} r_{u,i}} \quad (3.13)$$

donde $r_{u,i}$ es la calificación del usuario u sobre el ítem i e $\mathcal{I}_u$ el conjunto de ítems con los que el usuario ha interactuado. La predicción para un par $(u, i) \notin \mathcal{O}$ se obtiene entonces mediante la similitud coseno entre ambos perfiles:

$$\hat{r}_{u,i} = \text{sim}(\theta(u), \phi(i)) = \frac{\theta(u)^\top \phi(i)}{\|\theta(u)\| \cdot \|\phi(i)\|} \quad (3.14)$$

Ventajas y limitaciones

El FBC presenta ventajas estructurales sobre el FC:

- **Independencia del usuario.** Las recomendaciones se generan a partir del perfil del usuario activo sin depender de las interacciones de terceros, eliminando el problema de vecindad escasa.
- **Transparencia.** Las recomendaciones pueden justificarse enumerando las características del ítem que coinciden con el perfil del usuario, a diferencia del FC que opera como caja negra.
- **Cold-start de ítems.** Un ítem nuevo puede recomendarse en cuanto se disponga de su representación de características, sin requerir calificaciones previas de otros usuarios.

No obstante, el FBC presenta limitaciones inherentes:

- **Sobre-especialización.** El sistema recomienda ítems similares a los ya preferidos, reduciendo la diversidad y dificultando la aparición de recomendaciones sorpresivas (*serendipity*).
- **Análisis de contenido limitado.** La calidad de las recomendaciones está acotada por la riqueza de la representación de características; atributos latentes o cualidades subjetivas no capturadas por los descriptores quedan fuera del alcance del modelo (Aggarwal, 2016).
- **Cold-start de usuario.** Se requiere un número mínimo de interacciones para construir un perfil informativo; con pocas calificaciones disponibles, las predicciones son poco confiables.

3.1.3. Sistemas híbridos

Los sistemas híbridos combinan múltiples estrategias de recomendación para compensar las debilidades individuales de cada enfoque (Raza y cols., 2025; Sarkar y cols., 2023). (Burke, 2002) propuso una taxonomía ampliamente adoptada que identifica siete clases de hibridación: *ponderada*, *conmutación*, *mixto*, *combinación de características*, *cascada*, *aumento de características* y *meta-nivel*. La revisión sistemática de Çano y Morisio (2017) sobre 76 publicaciones del periodo 2005–2015 confirma la vigencia de esta taxonomía y reporta que la mayoría de los sistemas combinan FC con otra técnica, siendo la hibridación ponderada la estrategia predominante (28.9% de los estudios) seguida por la combinación de características (15.8%).

Ponderada. La puntuación final se obtiene mediante una combinación lineal de las predicciones de cada recomendador individual, asignando pesos que pueden

ser globales, por usuario o adaptativos según retroalimentación. de Campos, Fernández-Luna, Huete, y Rueda-Morales (2010) ejemplifican esta estrategia integrando un módulo de FC y otro de FBC mediante una red bayesiana cuyos parámetros condicionales actúan como factores de ponderación, alcanzando mejoras frente a cada componente individual. La sencillez de su formulación y la facilidad para ajustar la influencia relativa de cada componente explican su popularidad.

Combinación de características. Las salidas de un recomendador se incorporan como características adicionales al conjunto de datos sobre el que opera el segundo recomendador (típicamente un FBC, que explota intensivamente atributos del ítem). De esta forma, la información colaborativa se integra como una variable explicativa más, reduciendo la sensibilidad a la dispersión de la matriz original.

Cascada. El proceso de recomendación es secuencial: una primera técnica genera un conjunto preliminar de candidatos y una segunda técnica refina dicho conjunto. Es sensible al orden de aplicación de los recomendadores, ya que la segunda etapa solo opera sobre los ítems supervivientes de la primera, lo que la hace eficiente computacionalmente y robusta frente a clasificaciones imprecisas en las primeras posiciones.

Conmutación. El sistema alterna dinámicamente entre distintas técnicas de acuerdo con un criterio (e.g., confianza de la predicción, disponibilidad de datos, contexto del usuario). El recomendador de noticias DailyLearner (Billsus, Pazzani, y Chen, 2000) ilustra esta clase: emplea un modelo CBF de corto plazo basado en clasificación por vecinos cercanos y, cuando una noticia carece de vecinos cercanos, conmuta a un modelo de largo plazo basado en un clasificador Naive Bayes que captura las preferencias generales del usuario.

Aumento de características. Una técnica genera predicciones o clasificaciones que enriquecen las características procesadas por la segunda. A diferencia de *feature combination*, los datos originales del segundo recomendador no se modifican; en su lugar, se le añaden atributos sintéticos. Libra (Mooney y Roy, 2000) es un recomendador de libros basado en contenido que aumenta las características textuales con los campos “autores relacionados” y “títulos relacionados” obtenidos del recomendador colaborativo de Amazon, mejorando así la calidad sin modificar el clasificador Naive Bayes subyacente.

Meta-nivel. El modelo aprendido por la primera técnica se utiliza íntegramente como entrada de la segunda. La distinción respecto al aumento de características es que aquí no se transfieren atributos individuales, sino una representación compacta del modelo. Fab (Balabanović y Shoham, 1997), uno de los primeros recomendadores web, construye perfiles vectoriales de usuario con un componente CBF que luego son consumidos por agentes colaborativos para identificar comunidades de intereses afines.

Mixto. Las listas de recomendaciones generadas por cada técnica se presentan simultáneamente al usuario, sin ser fusionadas en una única puntuación. Es la forma más simple de hibridación y resulta apropiada cuando se dispone de múltiples recomendadores complementarios. PTV (Smyth y Cotter, 2000), un sistema de recomendación de programación televisiva, presenta de manera conjunta los resultados de un módulo CBF basado en perfiles de programa y un módulo FC basado en similitud entre usuarios.

En esta tesis se adopta una estrategia de **combinación ponderada**, donde la predicción final es una combinación lineal convexa de las predicciones de los componentes colaborativo y basado en contenido:

$$\hat{r}_{ui} = \alpha \cdot \hat{r}_{ui}^{\text{CF}} + (1 - \alpha) \cdot \hat{r}_{ui}^{\text{CBF}} \quad (3.15)$$

donde $\alpha \in [0, 1]$ controla la contribución relativa de cada componente. Esta formulación se extiende naturalmente a un vector de pesos $\boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_M)$ cuando se combinan M señales de recomendación, sujeto a $\sum_{m=1}^M \alpha_m = 1$.

La determinación de los pesos óptimos constituye en sí un problema de optimización no convexo, cuya solución se aborda mediante técnicas metaheurísticas (Sección 3.4). Esta aproximación, donde los aspectos y sentimientos extraídos por el componente NLP enriquecen las características del sistema colaborativo, ha demostrado ser efectiva en dominios donde la información textual complementa las calificaciones numéricas. (Musto y cols., 2017) mostraron que un FC multi-criterio alimentado con sentimientos por aspecto extraídos automáticamente de reseñas supera tanto a algoritmos de un solo criterio como a técnicas de factorización matricial. De manera similar, (Y. Zhang y cols., 2014) propusieron el *Explicit Factor Model* (EFM), que integra factores explícitos (aspectos y opiniones extraídos de reseñas) con factores latentes en un modelo unificado, demostrando mejoras tanto en predicción de calificaciones como en la calidad de las explicaciones generadas.

3.1.4. Problema del arranque en frío y dispersión

Dos desafíos fundamentales afectan el rendimiento de los SR, particularmente relevantes en el dominio turístico (Sarkar y cols., 2023): el arranque en frío y la dispersión de la matriz de interacciones. La primera se manifiesta en dos variantes:

- **De usuario:** usuarios nuevos sin historial de calificaciones, para los cuales el FC no puede calcular similitudes. El FBC puede mitigar este problema si se dispone de información demográfica o preferencias explícitas iniciales.
- **De ítem:** ítems nuevos sin calificaciones, invisibles para el FC. En este trabajo, el pipeline de ABSA permite generar un perfil de aspectos para un nuevo Pueblo Mágico a partir de sus reseñas textuales, habilitando recomendaciones basadas en contenido sin historial de calificaciones numéricas.

La dispersión del 90.32 % en el dataset REST-MEX implica que cada usuario ha calificado, en promedio, menos de 5 de los 48 pueblos disponibles. Este nivel de dispersión degrada significativamente el rendimiento de los métodos basados en memoria, ya que la cantidad de ítems co-calificados entre pares de usuarios ($|\mathcal{I}_{uv}|$) tiende a ser pequeña, resultando en estimaciones de similitud poco confiables (Raza y cols., 2025). Las principales estrategias de mitigación incluyen: (i) factorización matricial, que generaliza patrones a partir de factores latentes aun con matrices dispersas; (ii) incorporación de información lateral (*side information*), como las reseñas textuales; y (iii) sistemas híbridos que combinan señales complementarias (Payandenick, Othman, y Payandenick, 2025).

3.1.5. Evaluación

La evaluación de un SR es un problema multifacético cuya configuración requiere decisiones explícitas sobre el tipo de experimento, los datos empleados, el protocolo de partición y el conjunto de métricas reportadas (Zangerle y Bauer, 2022). Tradicionalmente se distinguen tres modalidades: *evaluación en línea* (despliegue del sistema sobre usuarios reales y medición de señales como CTR o tasa de conversión), *estudios de usuario* (sujetos reclutados que interactúan con el sistema en un entorno controlado) y *evaluación fuera de línea* (uso de un *snapshot* histórico de interacciones para simular el comportamiento de los usuarios). En la práctica, la evaluación fuera de línea es predominante por su bajo costo, su reproducibilidad y la posibilidad de comparar de forma controlada múltiples configuraciones algorítmicas sobre los mismos datos. Su principal limitación es que mide la capacidad del modelo para reconstruir interacciones ya observadas, no la utilidad percibida por el usuario en un escenario real. La metodología adoptada en este trabajo es de tipo fuera de línea sobre el corpus REST-MEX descrito en el Capítulo 2.

Separación de conjuntos de entrenamiento y prueba

Toda evaluación fuera de línea requiere particionar el conjunto de interacciones $\mathcal{O}$ en un subconjunto de entrenamiento $\mathcal{O}_{\text{train}}$, sobre el que el SR ajusta sus parámetros, y un subconjunto de prueba $\mathcal{O}_{\text{test}}$, sobre el que se evalúa la capacidad predictiva. Aunque a primera vista parece una decisión secundaria, Cañamares, Castells, y Moffat (2020) muestran experimentalmente que la elección del protocolo de partición puede invertir el orden relativo de dos algoritmos comparados sobre el mismo conjunto de datos, lo que convierte a esta etapa en un componente metodológico crítico. Las estrategias más empleadas en la literatura son:

- **División aleatoria.** Cada interacción se asigna a $\mathcal{O}_{\text{train}}$ o $\mathcal{O}_{\text{test}}$ con una probabilidad fija (típicamente 80:20 o 50:50), eventualmente bajo un esquema de validación cruzada de k pliegues. Es la opción más simple, pero ignora la dependencia temporal y permite que interacciones futuras de un usuario aparezcan en entrenamiento.

- **Leave- ℓ -out por usuario.** Para cada usuario con al menos ℓ interacciones, se reservan ℓ aleatoriamente para prueba. Garantiza que todo usuario participe en la evaluación; el caso $\ell = 1$ se conoce como *leave-one-out*.
- **Asignación por ítem.** Se reserva un número fijo de calificaciones por ítem para entrenamiento, mitigando el sesgo de popularidad que se produce cuando los ítems con muchas calificaciones también tienden a tener muchas en el conjunto de prueba.
- **División temporal.** Las interacciones se ordenan por su *timestamp* y se asignan las más antiguas a $\mathcal{O}_{\text{train}}$ y las más recientes a $\mathcal{O}_{\text{test}}$, ya sea con un punto de corte global o por usuario. Esta estrategia es la única que reproduce el escenario realista en el que el SR predice interacciones futuras a partir de información estrictamente pasada, evitando la fuga temporal de información.

Métricas

La evaluación de un SR Top- K no se reduce a la fidelidad numérica de la predicción de calificaciones (RMSE, MAE), pues estas métricas no reflejan la calidad del ordenamiento que el usuario realmente percibe. Por ello, las métricas dominantes en la literatura actual operan sobre la lista recomendada y se agrupan en al menos siete familias: precisión predictiva, predicción de uso, *ranking*, novedad, diversidad, cobertura y serendipia. Una configuración de evaluación rigurosa debe reportar simultáneamente varias de estas dimensiones, ya que un SR optimizado para una métrica puede degradar otras sin que ello sea evidente en una evaluación unidimensional.

Sea $\mathcal{R}_u^K = (i_1, \dots, i_K)$ la lista de los K ítems con mayor puntuación predicha para el usuario u que no pertenecen a $\mathcal{I}_u$, y sea $\text{Rel}(u) \subseteq \mathcal{I}$ el conjunto de ítems considerados relevantes para u en $\mathcal{O}_{\text{test}}$.

Métricas de ranking

Precision@K y Recall@K La *precisión* a profundidad K es la fracción de ítems recomendados que son relevantes, mientras que la *exhaustividad* (*recall*) mide la fracción de ítems relevantes que el sistema logra recuperar entre los primeros K :

$$\text{P@K}(u) = \frac{|\mathcal{R}_u^K \cap \text{Rel}(u)|}{K}, \quad \text{R@K}(u) = \frac{|\mathcal{R}_u^K \cap \text{Rel}(u)|}{|\text{Rel}(u)|}. \quad (3.16)$$

Ambas se promedian sobre el conjunto de usuarios. Existe un compromiso natural entre ambas: aumentar K incrementa R@K a costa de P@K , pues los ítems añadidos al final de la lista tienden a ser menos relevantes.

NDCG@K La *Normalized Discounted Cumulative Gain* pondera la posición del ítem en la lista, penalizando los ítems relevantes que aparezcan en posiciones bajas:

$$\text{DCG@K}(u) = \sum_{i=1}^K \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)}, \quad \text{NDCG@K}(u) = \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}, \quad (3.17)$$

donde rel_i es la relevancia del ítem en la i -ésima posición y $\text{IDCG@K}(u)$ es el DCG del ordenamiento ideal sobre los ítems de prueba del usuario, lo que normaliza el valor al intervalo $[0, 1]$. Cuando las calificaciones se emplean como juicios graduados, la transformación $g(r) = 2^r - 1$ amplifica la contribución de las calificaciones altas frente a las moderadas. NDCG@K es la métrica principal de optimización en esta tesis por dos motivos: (i) es sensible al orden, lo que se alinea con el carácter de *ranking* de la tarea; y (ii) es la métrica más reportada en la literatura de SR turísticos, lo que facilita la comparación con trabajos relacionados.

MRR (Mean Reciprocal Rank) El *rango recíproco medio* mide qué tan arriba aparece el primer ítem relevante en la lista recomendada:

$$\text{MRR} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{1}{\text{rank}_u}, \quad (3.18)$$

donde rank_u es la posición del primer ítem de $\text{Rel}(u)$ en $\mathcal{R}_u^K$ (con $1/\text{rank}_u = 0$ si ningún ítem relevante aparece en los primeros K). MRR es informativa cuando solo el primer acierto importa, pero ignora el resto de la lista.

Métricas beyond-accuracy

Diversidad La *intra-list diversity* (ILD) mide la disimilitud promedio entre pares de ítems dentro de una misma lista recomendada:

$$\text{ILD}(\mathcal{R}_u^K) = \frac{2}{K(K-1)} \sum_{1 \leq i < j \leq K} (1 - \text{sim}(\phi(i), \phi(j))), \quad (3.19)$$

donde $\text{sim}(\cdot, \cdot)$ es típicamente la similitud coseno sobre representaciones de ítems. En el contexto turístico, esta métrica es especialmente relevante para evitar recomendar K pueblos pertenecientes al mismo estado o categoría, lo que reduciría el valor experiencial de la recomendación.

Cobertura La *cobertura de catálogo* cuantifica la fracción de ítems del sistema que aparecen al menos una vez en alguna recomendación:

$$\text{Coverage} = \frac{|\bigcup_{u \in \mathcal{U}} \mathcal{R}_u^K|}{|\mathcal{I}|}. \quad (3.20)$$

Esta métrica es relevante dado el desbalance del dataset REST-MEX, en el que un subconjunto reducido de pueblos concentra la mayoría de las reseñas: un SR podría obtener valores aceptables de $\text{NDCG}@K$ recomendando casi exclusivamente esos pueblos populares, sacrificando la exposición del catálogo en su conjunto.

3.2. Procesamiento de Lenguaje Natural

El texto de las reseñas constituye una fuente de información semántica complementaria a las calificaciones numéricas, y suele contener juicios diferenciados sobre múltiples atributos del ítem que la puntuación global agrega en un único escalar. El procesamiento de lenguaje natural (NLP) provee la infraestructura para extraer dicha estructura: codifica el texto en representaciones manipulables algorítmicamente y, sobre ellas, formula tareas de clasificación, etiquetado o generación. Esta sección presenta los fundamentos sobre los que se apoyan los componentes textuales del recomendador propuesto. Se introducen primero las representaciones distribuidas y contextuales sobre las que opera el NLP moderno (Sección 3.2.1); a continuación se formaliza el análisis de sentimientos basado en aspectos (ABSA) y sus sub tareas (Sección 3.2.2); y por último se describen los dos paradigmas instrumentales empleados en este trabajo: la clasificación zero-shot vía inferencia textual para detectar categorías de aspecto (Sección 3.2.4) y la clasificación supervisada con codificadores Transformer ajustados al dominio para inferir polaridad (Sección 3.2.5).

3.2.1. Representación de texto

Las primeras representaciones empleadas en NLP discretizaban el texto mediante esquemas de *bag-of-words* y ponderación TF-IDF (Eq. 3.12), produciendo vectores de muy alta dimensionalidad y dispersos que descartaban el orden de las palabras y la ambigüedad semántica (Aggarwal, 2016). Los *word embeddings* densos (e.g. Word2Vec (Mikolov, Chen, Corrado, y Dean, 2013), GloVe (Pennington, Socher, y Manning, 2014)) introdujeron representaciones de baja dimensionalidad $\mathbf{e}_w \in \mathbb{R}^d$ ($d \approx 50\text{--}300$) entrenadas para preservar relaciones distribucionales entre palabras: vocablos que aparecen en contextos similares quedan cercanos en el espacio vectorial. No obstante, son *embeddings* estáticos: una palabra ambigua como “banco” recibe un único vector independientemente de si la oración refiere a una entidad financiera o a un asiento. Los modelos contextuales basados en Transformer (Vaswani y cols., 2017) subsanan esta limitación produciendo $\mathbf{e}_{w,t} \in \mathbb{R}^d$ condicionado al contexto t en el que aparece la palabra (Devlin, Chang, Lee, y Toutanova, 2019).

La arquitectura Transformer modela las dependencias entre tokens mediante un mecanismo de *self-attention* escalado:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (3.21)$$

donde $\mathbf{Q} \in \mathbb{R}^{n \times d_k}$, $\mathbf{K} \in \mathbb{R}^{n \times d_k}$ y $\mathbf{V} \in \mathbb{R}^{n \times d_v}$ son proyecciones lineales aprendidas de la entrada (*queries*, *keys*, *values*) sobre los n tokens de la secuencia, y $\sqrt{d_k}$ es un factor de escala que estabiliza los gradientes. La operación se aplica en paralelo en múltiples *heads* (*multi-head attention*), permitiendo capturar relaciones de tipos heterogéneos. Como la atención es invariante a permutaciones, se añaden *embeddings* posicionales para inyectar el orden de la secuencia.

Modelos basados en el módulo codificador de la arquitectura Transformer como BERT (Devlin y cols., 2019) y RoBERTa (Y. Liu y cols., 2019) preentrenan apilamientos profundos de bloques Transformer sobre corpora masivos en la tarea de *masked language modeling* (MLM). Una consecuencia de este enfoque es que los *embeddings* de palabras aprendidos durante el preentrenamiento son transferibles a tareas *downstream* realizando un ajuste fino adicional. A este paradigma se le conoce como *transfer learning* y ha establecido el estado del arte en prácticamente todas las subtareas del NLP supervisado (Do, Prasad, Maag, y Alsadoon, 2019; W. Zhang y cols., 2023), resultando especialmente ventajoso en dominios con escasos datos etiquetados, como el turismo en español.

3.2.2. Análisis de sentimientos basado en aspectos

El *análisis de sentimientos basado en aspectos* (ABSA, por sus siglas en inglés) tiene por objeto recuperar la estructura aspectual del juicio expresado en un texto: dado un texto t , identificar un conjunto de tuplas $\{(a_k, s_k)\}_{k=1}^K$ donde a_k denota un aspecto del ítem y s_k su polaridad asociada (B. Liu, 2012; W. Zhang y cols., 2023). A diferencia del análisis de sentimientos a nivel de documento, que atribuye una sola etiqueta s a la totalidad del texto, el ABSA opera con granularidad fina y reconoce la coexistencia de juicios opuestos sobre aspectos distintos en una misma reseña.

Siguiendo a W. Zhang y cols. (2023), el ABSA se articula en torno a cuatro elementos de sentimiento: la *categoría de aspecto* $c \in \mathcal{C}$ (clase predefinida del aspecto, e.g., *comida*, *servicio*), el *término de aspecto* a (mención explícita en el texto, e.g., “*pizza*” como instancia de *comida*), el *término de opinión* o (expresión que vehicula el juicio, e.g., “*deliciosa*”) y la *polaridad* $p \in \{\text{POS}, \text{NEU}, \text{NEG}\}$ (o, en escalas de granularidad fina, $p \in \{1, \dots, 5\}$). La Figura 3.1 muestra una taxonomía de las tareas de ABSA, donde las distintas combinaciones de elementos definen tareas: tareas *simples* predicen un único elemento (e.g., extracción del término de aspecto, ATE), mientras que tareas *compuestas* predicen tuplas (a, p) , (c, p) , (a, o, p) o el cuádruple (c, a, o, p) . En particular, las tres subtareas históricamente establecidas en SemEval (Do y cols., 2019; Pontiki y cols., 2016) son:

- **Aspect Term Extraction (ATE).** Tarea de etiquetado a nivel de *token* (típicamente con esquema BIO o similar) que identifica las menciones explícitas de aspectos en el texto. Dada la frase “*La pizza es deliciosa pero el servicio terrible.*”, se extraen $\{\text{pizza}, \text{servicio}\}$.
- **Aspect Category Detection (ACD).** Clasificación multi-etiqueta del texto

sobre un conjunto cerrado $\mathcal{C}$ de categorías predefinidas, dependiente del dominio. A diferencia de ATE, ACD captura aspectos *implícitos* no mencionados explícitamente; por ejemplo, “*Está muy sobrevalorado y no estaba sabroso.*” se clasifica en $\{\text{precio, comida}\}$ aunque ninguno aparezca como término.

- **Aspect Sentiment Classification (ASC).** Predicción de la polaridad asociada a un aspecto dado, condicionando la clasificación al contexto aspecto-específico de la frase. Es comúnmente formulada como clasificación a nivel de oración con un par (s, a) como entrada.

En la presente tesis se adopta el paradigma **ACD + ASC**: la categoría de aspecto se predice mediante clasificación zero-shot vía NLI (Sección 3.2.4) y, condicionalmente al aspecto detectado, se aplica un clasificador de sentimiento basado en un codificador Transformer con ajuste fino sobre reseñas en español (Sección 3.2.5). Esta elección está motivada por dos consideraciones: (i) la ausencia de datos etiquetados a nivel de aspecto para Pueblos Mágicos hace inviables los enfoques supervisados, y (ii) el conjunto de aspectos relevantes varía entre tipos de establecimiento, lo cual se acomoda naturalmente a un esquema condicional en el que el conjunto de etiquetas candidatas se ajusta dinámicamente sin reentrenar.

3.2.3. Detección de fronteras de oración

Antes de aplicar cualquier modelo de clasificación a las reseñas, el texto debe segmentarse en unidades coherentes sobre las que se predicen los aspectos. Esta tarea, conocida como *Sentence Boundary Detection* (SBD) o *Sentence Boundary Disambiguation*, consiste en identificar el conjunto de posiciones del texto que corresponden a finales de oración. Aunque suele tratarse como un paso de preprocesamiento trivial, los errores en SBD se propagan a las etapas posteriores de la cadena de NLP, degradando el rendimiento de etiquetadores morfosintácticos, analizadores semánticos y clasificadores (Read, Dridan, Oepen, y Solberg, 2012). Para el caso del ABSA, una segmentación deficiente puede unir en un mismo fragmento juicios de polaridad opuesta sobre aspectos distintos, frustrando el principio de granularidad fina sobre el que se sustenta la tarea.

La dificultad principal del SBD reside en la *ambigüedad del punto*: el grafema ‘.’ actúa simultáneamente como marcador de final de oración, parte de abreviaturas (e.g., *Sr.*, *Av.*), separador de números ordinales o decimales e indicador de iniciales. Las aproximaciones a esta tarea se agrupan en tres familias: (i) sistemas *basados en reglas*, que combinan heurísticas con listas curadas de abreviaturas; (ii) sistemas *supervisados*, entrenados sobre corpus con fronteras anotadas mediante clasificadores de máxima entropía, SVM o redes neuronales; y (iii) sistemas *no supervisados*, que infieren las fronteras a partir de regularidades distribucionales del propio corpus, sin requerir anotación manual. La revisión empírica de Read y cols. (2012) sobre nueve sistemas y cuatro corpus muestra una variabilidad de rendimiento considerable entre dominios y tipos de texto, y advierte que las evaluaciones tradicionales sobre prosa




Figura 3.1: Taxonomía de las tareas de ABSA. Reconstruido de W. Zhang y cols. (2023).

formal (Wall Street Journal, Brown) sobrestiman la robustez de los segmentadores cuando se aplican a contenido generado por usuarios, donde la puntuación es irregular y el registro es informal.

En este trabajo se adopta el segmentador no supervisado **Punkt** (Kiss y Strunk, 2006). La hipótesis central de Punkt es que la mayor parte de las ambigüedades del punto puede resolverse identificando primero las abreviaturas presentes en el corpus, ya que toda posición que no siga a una abreviatura se clasifica directamente como frontera. Una abreviatura se caracteriza, sin información contextual, mediante tres propiedades del tipo léxico:

- **Colocación con el punto.** La palabra truncada y el punto final forman una colocación estricta; se cuantifica con la verosimilitud logarítmica

$$\log \lambda(w, \cdot) = -2 \log \frac{L(p_0; k_1, n_1) L(p_0; k_2, n_2)}{L(p_1; k_1, n_1) L(p_2; k_2, n_2)} \quad (3.22)$$

donde $L(\cdot)$ es la verosimilitud bajo el modelo binomial, k_i, n_i son conteos de coocurrencia y p_0, p_1, p_2 son las estimaciones bajo independencia y dependencia, respectivamente.

- **Brevedad del tipo.** Las abreviaturas tienden a ser cortas; la probabilidad de que un tipo w sea abreviatura decae con su longitud.
- **Puntos internos.** Los tipos que contienen puntos en su interior (e.g., *a.m.*) son fuertes candidatos a abreviatura.

La combinación multiplicativa de estos tres factores produce un *score* de abreviatura por tipo, sobre el que un umbral global decide la clasificación. Una segunda fase a nivel de *token* resuelve los casos restantes (números ordinales, iniciales y palabras que pueden ser tanto abreviaturas como ordinarias) usando rasgos contextuales como la capitalización de la palabra siguiente. Kiss y Strunk (2006) reportan una precisión media del 98.74 % sobre corpus periodísticos en once idiomas — incluido el español — sin ninguna adaptación específica al idioma, lo que justifica su elección como segmentador en este trabajo, dado el carácter multilingüe-agnóstico de su entrenamiento y la ausencia de un corpus de reseñas turísticas en español con fronteras de oración anotadas. La salida de Punkt define los fragmentos $\{t_1, \dots, t_F\}$ sobre los que se aplican posteriormente la detección de aspecto y la clasificación de sentimiento.

3.2.4. Clasificación zero-shot vía NLI

La clasificación zero-shot tiene por objetivo asignar etiquetas a un texto sin disponer de ejemplos anotados para las clases objetivo (Yin, Hay, y Roth, 2019). Formalmente, se considera el escenario *label-fully-unseen*: aprender un clasificador $f : \mathcal{X} \rightarrow \mathcal{Y}$ tal que f no observa ningún dato etiquetado específico para las clases en $\mathcal{Y}$ durante su entrenamiento. Esta formulación es particularmente adecuada para ACD en dominios

sin *benchmarks* curados, ya que permite definir el conjunto de aspectos $\mathcal{C}$ post-hoc y modificarlo sin reentrenamiento.

Yin y cols. (2019) proponen tratar la clasificación zero-shot como un problema de *Natural Language Inference* (NLI). La tarea de NLI es una tarea de clasificación supervisada que consiste en determinar la relación entre una premisa t y una hipótesis h mediante tres clases: implicación, contradicción y neutralidad (MacCartney, 2009). La idea consiste en convertir cada etiqueta candidata $c \in \mathcal{C}$ en una hipótesis h_c mediante una plantilla parametrizada (e.g., “*Este texto habla sobre {c}.*”) y, dada una premisa t (la oración o reseña), evaluar la probabilidad de implicación usando un modelo NLI preentrenado. La etiqueta predicha es entonces:

$$\hat{c} = \arg \max_{c \in \mathcal{C}} \Pr(\text{entailment} \mid t, h_c) \quad (3.23)$$

En el caso multi-etiqueta, se aplica un umbral τ y se devuelven $\{c \in \mathcal{C} : \Pr(\text{entailment} \mid t, h_c) > \tau\}$. Yin y cols. (2019) muestran que un modelo BERT ajustado finamente sobre MNLI (Williams, Nangia, y Bowman, 2018) generaliza competitivamente a tareas de detección de aspectos no vistas, superando enfoques basados en *embeddings* estáticos (Word2Vec, ESA) por márgenes significativos en clases no vistas.

3.2.5. Transformers para clasificación de sentimiento

La subtarea ASC se formula como un problema de clasificación supervisada sobre representaciones contextuales producidas por un codificador Transformer. Dada una secuencia de entrada $t = (w_1, \dots, w_n)$, los modelos tipo BERT/RoBERTa anteponen un token especial [CLS] y producen, tras L capas de *self-attention*, una matriz de *embeddings* contextuales $\mathbf{H} \in \mathbb{R}^{(n+1) \times d}$. Para tareas de clasificación a nivel de oración se adopta el vector $\mathbf{h}_{[\text{CLS}]} \in \mathbb{R}^d$ asociado al token especial como representación agregada de la secuencia, y se añade una cabeza de clasificación lineal:

$$\Pr(s \mid t) = \text{softmax}(\mathbf{W} \mathbf{h}_{[\text{CLS}]} + \mathbf{b}), \quad \mathbf{W} \in \mathbb{R}^{|\mathcal{S}| \times d}, \mathbf{b} \in \mathbb{R}^{|\mathcal{S}|} \quad (3.24)$$

donde $\mathcal{S}$ es el conjunto de clases. Los parámetros de la cabeza, junto con los del codificador, se ajustan minimizando la entropía cruzada sobre un corpus etiquetado de la tarea *downstream*. Este esquema transfiere el conocimiento lingüístico capturado durante el preentrenamiento a tareas con relativamente pocos ejemplos etiquetados, superando consistentemente a las arquitecturas recurrentes y a los enfoques léxicos en clasificación de sentimiento (Do y cols., 2019).

Para el español existen varios modelos base ampliamente utilizados — BETO, MarIA, RoBERTuito — que difieren en el corpus de preentrenamiento (Wikipedia, BNE, Twitter) y, consecuentemente, en el dominio en el que mejor generalizan (Do y cols., 2019). El modelo seleccionado en este trabajo, VG055/ROBERTA-BASE-BNE-FINETUNED-TRIPADVISORDOMAINADAPTATION, parte de un RoBERTa-base preentrenado sobre la Biblioteca Nacional de España (BNE) y posteriormente adaptado

al dominio TripAdvisor mediante *fine-tuning* para clasificación de sentimiento de granularidad fina, produciendo cinco clases ordinales:

$$\mathcal{S} = \{\text{Muy Negativo, Negativo, Neutral, Positivo, Muy Positivo}\}$$

La granularidad de cinco clases preserva información que un esquema ternario $\{\text{NEG, NEU, POS}\}$ colapsaría — en particular, el contraste entre satisfacción moderada y entusiasmo — y resulta consistente con la escala de 1 a 5 estrellas del *dataset* REST-MEX, lo que facilita análisis posteriores de coherencia entre $a_{u,i}$ (calificación numérica) y los sentimientos extraídos.

3.3. Sistemas de recomendación con ABSA

Una vez que el *pipeline* de NLP descrito en la Sección 3.2 produce, para cada par (usuario, ítem) y reseña, un conjunto de pares (aspecto, sentimiento), se vuelve posible enriquecer las arquitecturas clásicas de SR con esta información de granularidad fina. La literatura ha explorado dos vías complementarias para integrar las salidas de ABSA en el recomendador: (i) tratar las polaridades aspecto-específicas como *ratings multidimensionales* dentro de un esquema de filtrado colaborativo multicriterio, y (ii) construir representaciones explícitas de *usuario* y de *ítem* en el espacio de aspectos que se combinan con factores latentes en una factorización híbrida. Las dos referencias canónicas que materializan estas vías — Musto y cols. (2017) y Y. Zhang y cols. (2014) — constituyen los pilares teóricos de la propuesta híbrida desarrollada en el capítulo de metodología.

3.3.1. Filtrado colaborativo multicriterio (Musto et al., 2017)

Musto y cols. (2017) extienden el FC clásico al sustituir el escalar de calificación $r_{u,i}$ por un vector de *micro-calificaciones* aspecto-específicas $\mathbf{r}_{u,i} = (r_{u,i,1}, \dots, r_{u,i,|\mathcal{A}|})$, donde $r_{u,i,a} \in [-1, 1]$ se deriva del sentimiento promedio extraído por ABSA sobre las menciones del aspecto a en las reseñas de u acerca de i . El conjunto de interacciones queda así organizado como un tensor $\mathbf{R} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}| \times |\mathcal{A}|}$.

La predicción se realiza por aspecto mediante FC basado en usuario sobre la rebanada $\mathbf{R}_{:,i,a}$:

$$\hat{r}_{u,i,a} = \bar{r}_{u,a} + \frac{\sum_{v \in \mathcal{N}_k(u)} \text{sim}_a(u, v) \cdot (r_{v,i,a} - \bar{r}_{v,a})}{\sum_{v \in \mathcal{N}_k(u)} |\text{sim}_a(u, v)|} \quad (3.25)$$

donde sim_a se computa en el subespacio aspecto-específico (e.g., correlación de Pearson sobre $\{(r_{u,j,a}, r_{v,j,a}) : j \in \mathcal{I}_{u,v}\}$) y $\bar{r}_{u,a}$ es la media del usuario en dicho aspecto.

La predicción agregada se obtiene como el promedio (eventualmente ponderado por importancia del aspecto) sobre $\mathcal{A}$:

$$\hat{r}_{u,i} = \frac{1}{|\mathcal{A}|} \sum_{a \in \mathcal{A}} \hat{r}_{u,i,a} \quad (3.26)$$

Musto y cols. (2017) reportan que este esquema supera tanto al FC de criterio único como a la factorización matricial clásica en *datasets* de TripAdvisor y Yelp, beneficio atribuible al hecho de que las micro-calificaciones aspectuales descomponen el ruido propio de la calificación global y exponen patrones de preferencia multidimensionales.

3.3.2. Modelo de Factores Explícitos — EFM (Zhang et al., 2014)

Y. Zhang y cols. (2014) proponen el *Explicit Factor Model* (EFM), que conjuga factores *explícitos* (extraídos de ABSA) con factores latentes en una factorización unificada que produce, simultáneamente, predicción de *rating* y explicabilidad. El modelo se construye sobre dos matrices derivadas del *pipeline* ABSA:

- **Matriz de atención del usuario** $\mathbf{X} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{A}|}$: codifica la importancia que el usuario u asigna al aspecto a , escalando la frecuencia de mención mediante una sigmoide acotada en $[1, N]$:

$$X_{u,a} = 1 + (N - 1) \left(\frac{2}{1 + \exp(-t_{u,a})} - 1 \right) \quad (3.27)$$

donde $t_{u,a}$ es el conteo de menciones del aspecto a por parte del usuario u y N es el rango superior de la escala.

- **Matriz de calidad del ítem** $\mathbf{Y} \in \mathbb{R}^{|\mathcal{I}| \times |\mathcal{A}|}$: codifica la calidad del ítem i en el aspecto a , ponderando el sentimiento promedio $s_{i,a}$ por el volumen de menciones $t_{i,a}$:

$$Y_{i,a} = 1 + \frac{N - 1}{1 + \exp(-t_{i,a} \cdot s_{i,a})} \quad (3.28)$$

La predicción híbrida combina un término explícito — producto interno entre la atención del usuario y la calidad del ítem en el espacio de aspectos — con un término latente análogo al de SVD:

$$\hat{r}_{u,i} = \alpha \cdot \frac{\mathbf{X}_u^\top \mathbf{Y}_i}{|\mathcal{A}|} + (1 - \alpha) \cdot \mathbf{p}_u^\top \mathbf{q}_i \quad (3.29)$$

donde $\alpha \in [0, 1]$ regula la contribución relativa de cada término. La fortaleza estructural del EFM radica en que el componente explícito permite generar justificaciones interpretables del tipo “*se recomienda Taxco porque valoras positivamente la **cultura***”

y la *naturaleza*, aspectos altamente evaluados por la comunidad en este pueblo”, conectando directamente la salida del recomendador con la representación aspectual extraída por ABSA (cf. Sección 3.5). La integración de las dos referencias — el FC multicriterio de Musto y el EFM de Zhang — como componentes ortogonales del recomendador híbrido propuesto se desarrolla en el capítulo de metodología.

3.4. Optimización metaheurística

3.4.1. Evolución diferencial

3.4.2. Optimización por enjambre de partículas (PSO)

3.4.3. Optimización bayesiana

3.5. Explicabilidad en sistemas de recomendación

Capítulo 4

Metodología y Resultados

Capítulo 5

Conclusiones y trabajo futuro

Referencias

- Adomavicius, G., y Tuzhilin, A. (2005, junio). Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6), 734–749. doi: 10.1109/TKDE.2005.99
- Aggarwal, C. C. (2016). *Recommender Systems: The Textbook*. Springer. doi: 10.1007/978-3-319-29659-3
- Álvarez-Carmona, M. Á., Arce-Cardenas, S., Fajardo-Delgado, D., Guerrero-Rodríguez, R., López-Monroy, A. P., Martínez-Miranda, J., ... Rodríguez-González, A. Y. (2021). Overview of REST-MEX at IberLEF 2021: Recommendation System for Mexican Tourist Texts. En *Procesamiento del Lenguaje Natural*.
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Bustio-Martínez, L., y Herrera-Semenets, V. (2025, septiembre). Overview of Rest-Mex at IberLEF 2025: Researching Sentiment Evaluation in Text for Mexican Magical Towns. *Procesamiento del Lenguaje Natural*, 75, 499–511. doi: 10.26342/2025-75-37
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Muñiz-Sánchez, V., López-Monroy, A. P., ... Bustio-Martínez, L. (2022). Overview of REST-MEX at IberLEF 2022: Recommendation System, Sentiment Analysis and COVID Semaphore Prediction for Mexican Tourist Texts. *Procesamiento del Lenguaje Natural*, 69, 289–299.
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Muñiz-Sánchez, V., López-Monroy, A. P., ... Bustio-Martínez, L. (2023). Overview of REST-MEX at IberLEF 2023: Research on Sentiment Analysis Task for Mexican Tourist Texts. *Procesamiento del Lenguaje Natural*, 71, 425–436.
- Balabanović, M., y Shoham, Y. (1997). Fab: Content-based, collaborative recommendation. *Communications of the ACM*, 40(3), 66–72. doi: 10.1145/245108.245124
- Billsus, D., Pazzani, M. J., y Chen, J. (2000). A learning agent for wireless news access. En *Proceedings of the 5th international conference on intelligent user interfaces (iui '00)* (pp. 33–36). ACM. doi: 10.1145/325737.325768
- Burke, R. (2002, noviembre). Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, 12(4), 331–370. doi: 10.1023/A:1021240730564

- Cañamares, R., Castells, P., y Moffat, A. (2020). Offline evaluation options for recommender systems. *Information Retrieval Journal*, 23(4), 387–410. doi: 10.1007/s10791-020-09371-3
- Çano, E., y Morisio, M. (2017). Hybrid recommender systems: A systematic literature review. *Intelligent Data Analysis*, 21(6), 1487–1524. doi: 10.3233/IDA-163209
- de Campos, L. M., Fernández-Luna, J. M., Huete, J. F., y Rueda-Morales, M. A. (2010). Combining content-based and collaborative recommendations: A hybrid approach based on Bayesian networks. *International Journal of Approximate Reasoning*, 51(7), 785–799. doi: 10.1016/j.ijar.2010.04.001
- Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 4171–4186). Association for Computational Linguistics. Descargado de <https://aclanthology.org/N19-1423> doi: 10.18653/v1/N19-1423
- Do, H. H., Prasad, P. W. C., Maag, A., y Alsadoon, A. (2019). Deep Learning for Aspect-Based Sentiment Analysis: A Comparative Review. *Expert Systems with Applications*, 118, 272–299. doi: 10.1016/j.eswa.2018.10.003
- Fernández Poncela, A. M. (2016). Una revisión del programa pueblos mágicos. *CULTUR: Revista de Cultura e Turismo*, 10(1 (Febrero)), 3–34.
- González-Barba, J. Á., Chiruzzo, L., y Jiménez-Zafra, S. M. (2025). Overview of IberLEF 2025: Natural Language Processing Challenges for Spanish and other Iberian Languages. En *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025), co-located with the 41st Conference of the Spanish Society for Natural Language Processing (SEPLN 2025)*.
- Hossain, A., Sikder, A., y Andreou, P. (2025, diciembre). Concf: A hybrid deep learning model for semantic-aware collaborative filtering in recommender systems. En *2025 7th international conference on electrical information and communication technology (eict)* (p. 1–6). Descargado de <https://ieeexplore.ieee.org/document/11355628> doi: 10.1109/EICT68394.2025.11355628
- Kiss, T., y Strunk, J. (2006). Unsupervised Multilingual Sentence Boundary Detection. *Computational Linguistics*, 32(4), 485–525. Descargado de <https://aclanthology.org/J06-4003/> doi: 10.1162/coli.2006.32.4.485
- Koren, Y. (2008). Factorization Meets the Neighborhood: a Multifaceted Collaborative Filtering Model. En *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 426–434). New York, NY, USA: Association for Computing Machinery. doi: 10.1145/1401890.1401944
- Koren, Y., Bell, R., y Volinsky, C. (2009, agosto). Matrix Factorization Techniques for Recommender Systems. *Computer*, 42(8), 30–37. doi: 10.1109/MC.2009.263
- Liu, B. (2012). Sentiment Analysis and Opinion Mining. *Synthesis Lectures on Human Language Technologies*, 5(1), 1–167. doi: 10.2200/S00416ED1V01Y201204HLT016
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., ... Stoyanov, V. (2019). Roberta: A robustly optimized bert pretraining approach. *arXiv preprint ar-*

Xiv:1907.11692.

- Lops, P., de Gemmis, M., y Semeraro, G. (2011). Content-based Recommender Systems: State of the Art and Trends. En F. Ricci, L. Rokach, B. Shapira, y P. B. Kantor (Eds.), *Recommender Systems Handbook* (pp. 73–105). Springer. doi: 10.1007/978-0-387-85820-3_3
- MacCartney, B. (2009). *Natural language inference*. Stanford University.
- Mikolov, T., Chen, K., Corrado, G., y Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space*. arXiv:1301.3781 [cs]. arXiv. Descargado de <http://arxiv.org/abs/1301.3781> doi: 10.48550/arXiv.1301.3781
- Mooney, R. J., y Roy, L. (2000). Content-based book recommending using learning for text categorization. En *Proceedings of the fifth acm conference on digital libraries (dl '00)* (pp. 195–204). ACM. doi: 10.1145/336597.336662
- Musto, C., de Gemmis, M., Semeraro, G., y Lops, P. (2017, agosto). A Multi-criteria Recommender System Exploiting Aspect-based Sentiment Analysis of Users' Reviews. En *Proceedings of the Eleventh ACM Conference on Recommender Systems* (pp. 321–325). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/3109859.3109905> doi: 10.1145/3109859.3109905
- Oard, D. W., Kim, J., y cols. (1998). Implicit feedback for recommender systems. En *Proceedings of the aaai workshop on recommender systems* (Vol. 83, pp. 81–83).
- Payandenick, M., Othman, M. K., y Payandenick, M. (2025, noviembre). A multi-criteria recommendation system for personalised tourism experiences with user query analysis. *Information Technology & Tourism*, 28(1), 3. Descargado de <https://doi.org/10.1007/s40558-025-00348-w> doi: 10.1007/s40558-025-00348-w
- Pazzani, M. J., y Billsus, D. (2007). Content-Based Recommendation Systems. En *The Adaptive Web* (pp. 325–341). Springer. doi: 10.1007/978-3-540-72079-9_10
- Pennington, J., Socher, R., y Manning, C. D. (2014). Glove: Global vectors for word representation. En *Proceedings of the 2014 conference on empirical methods in natural language processing (emnlp)* (pp. 1532–1543).
- Pontiki, M., Galanis, D., Papageorgiou, H., Androutsopoulos, I., Manandhar, S., Al-Smadi, M., ... Eryigit, G. (2016). SemEval-2016 Task 5: Aspect Based Sentiment Analysis. En *Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval-2016)* (pp. 19–30). Association for Computational Linguistics. doi: 10.18653/v1/S16-1002
- Raza, S., Rahman, M., Kamawal, S., Toroghi, A., Raval, A., Navah, F., y Kazeemini, A. (2025, octubre). *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*. arXiv. Descargado de <http://arxiv.org/abs/2407.13699> (arXiv:2407.13699 [cs]) doi: 10.48550/arXiv.2407.13699
- Read, J., Dridan, R., Oepen, S., y Solberg, L. J. (2012). Sentence Boundary Detection: A Long Solved Problem? En *Proceedings of COLING 2012: Posters* (pp. 985–994). Descargado de <https://aclanthology.org/C12-2096/>
- Sarkar, J. L., Majumder, A., Panigrahi, C. R., Roy, S., y Pati, B. (2023, marzo). Tourism recommendation system: a survey and future research directions. *Mul-*

- timedia Tools and Applications*, 82(6), 8983–9027. Descargado de <https://doi.org/10.1007/s11042-022-12167-w> doi: 10.1007/s11042-022-12167-w
- SECTUR. (2025). *Pib turístico contribuyó con 8.7 % del total de la economía y alcanzó más de 2.71 billones de pesos en 2024*. Descargado de <http://www.gob.mx/sectur/articulos/pib-turistico-contribuyo-con-8-7-del-total-de-la-economia-y-alcanzo-mas-de-2-71-billones-de-pesos-en-2024>
- She, K.-S., Haw, S.-C., y Chew, L.-J. (2020, agosto). Tourism recommender system utilising property graph ontology as knowledge base. En *Proceedings of the 12th international conference on computer modeling and simulation* (p. 14–18). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/3408066.3408102> doi: 10.1145/3408066.3408102
- Smyth, B., y Cotter, P. (2000). A personalised TV listings service for the digital TV age. *Knowledge-Based Systems*, 13(2–3), 53–59. doi: 10.1016/S0950-7051(00)00046-0
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is All you Need. En *Advances in Neural Information Processing Systems* (Vol. 30). Curran Associates, Inc.
- Williams, A., Nangia, N., y Bowman, S. (2018). A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference. En *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 1112–1122). Association for Computational Linguistics. doi: 10.18653/v1/N18-1101
- Yin, W., Hay, J., y Roth, D. (2019). Benchmarking Zero-shot Text Classification: Datasets, Evaluation and Entailment Approach. En *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (pp. 3914–3923). Association for Computational Linguistics. Descargado de <https://aclanthology.org/D19-1404> doi: 10.18653/v1/D19-1404
- Zangerle, E., y Bauer, C. (2022). Evaluating recommender systems: survey and framework. *ACM Computing Surveys*, 55(8), 1–38. doi: 10.1145/3556536
- Zhang, W., Li, X., Deng, Y., Bing, L., y Lam, W. (2023, noviembre). A Survey on Aspect-Based Sentiment Analysis: Tasks, Methods, and Challenges. *IEEE Transactions on Knowledge and Data Engineering*, 35(11), 11019–11038. Descargado de <https://ieeexplore.ieee.org/abstract/document/9996141> doi: 10.1109/TKDE.2022.3230975
- Zhang, Y., Lai, G., Zhang, M., Zhang, Y., Liu, Y., y Ma, S. (2014, julio). Explicit factor models for explainable recommendation based on phrase-level sentiment analysis. En *Proceedings of the 37th international ACM SIGIR conference on Research & development in information retrieval* (pp. 83–92). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/2600428.2609579> doi: 10.1145/2600428.2609579

Apéndice A

Anexo

