

SISTEMA DE RECOMENDACIÓN HÍBRIDO EN PUEBLOS MÁGICOS: INTEGRACIÓN DE ANÁLISIS DE SENTIMIENTOS BASADO EN ASPECTOS

T E S I S

Que para obtener el grado de
Maestro en Cómputo Estadístico

Presenta

Gustavo Hernández Angeles

Director de Tesis:

Dr. Norberto Alejandro Hernández Leandro

Autorización de la versión final

Agradecimientos

Expreso mi agradecimiento al Dr. Norberto Alejandro Hernández Leandro por su asesoría, así como a los doctores Alejandro Rosales Pérez y Miguel Ángel Álvarez Carmona, integrantes de mi comité, cuyo acompañamiento fue fundamental para este proyecto.

Al Centro de Investigación en Matemáticas (CIMAT), le agradezco el haberme recibido para realizar mis estudios de posgrado y al profesorado por la sólida formación técnica recibida en diversas áreas.

Asimismo, reconozco a la Secretaría de Ciencia, Humanidades, Tecnología e Innovación (SECIHTI) por el financiamiento otorgado, el cual permitió la conclusión exitosa de mi maestría.

A mis padres Octavio y Abigail. Su amor y sacrificio han sido fundamentales para cumplir mis metas. Gracias por ser un ejemplo de que cualquier obstáculo puede superarse. Espero que mis logros académicos sean un reflejo de su dedicación.

A mis hermanos, Arael y Javier. Han sido siempre un modelo a seguir para mí, sé que siempre puedo aprender más de ustedes. Gracias por siempre mostrar su apoyo y comprensión.

A Yazmin. Tu apoyo incondicional ha sido una fuente de fortaleza para mí. Gracias por ser la mejor compañía tanto en los momentos difíciles como en los felices.

Finalmente, a mis amigos y compañeros de clase, por hacer este camino mucho más ameno y por su apoyo constante.

Resumen

Índice general

Agradecimientos	I
Resumen	III
Índice de figuras	VII
Índice de tablas	IX
1. Introducción	1
1.1. Motivación	1
1.2. Hipótesis de trabajo	2
1.3. Objetivos	3
1.4. Contribución	3
1.5. Organización de la tesis	4
2. Conjunto de datos	5
2.1. La tarea compartida REST-MEX	5
2.2. Corpus	6
2.3. Estructura y limpieza	6
2.4. Filtrado para densidad de interacciones	7
2.5. Dataset de trabajo	8
3. Marco teórico	11
3.1. Sistemas de recomendación	11
3.1.1. Filtrado colaborativo	12
3.1.2. Filtrado basado en contenido	14
3.1.3. Sistemas híbridos	16
3.1.4. Problema del arranque en frío y dispersión	18
3.1.5. Evaluación	19
3.2. Optimización multiobjetivo y eficiencia de Pareto	22
3.2.1. Planteamiento del problema multiobjetivo	22
3.2.2. Dominancia y optimalidad de Pareto	23
3.2.3. Escalarización por suma ponderada	23
3.2.4. Aplicación al trade-off relevancia–cobertura	25
3.3. Procesamiento de Lenguaje Natural	25
3.3.1. Representación de texto	26

3.3.2.	Análisis de sentimientos basado en aspectos	27
3.3.3.	Detección de fronteras de oración	29
3.3.4.	Clasificación zero-shot vía NLI	30
3.3.5.	Transformers para clasificación de sentimiento	31
3.4.	Sistemas de recomendación con ABSA	31
4.	Metodología	35
4.1.	Partición del conjunto de datos	35
4.2.	Canalización de análisis basado en aspectos	37
4.3.	Construcción de las matrices estructurales	40
4.4.	Modelos de recomendación	42
4.5.	Modelo híbrido y compromiso relevancia–cobertura	43
5.	Resultados	45
5.1.	Perfiles de aspecto de los usuarios	45
5.2.	Coherencia de los perfiles con las visitas	48
5.3.	Evaluación de los modelos individuales	49
5.4.	Distribución de las recomendaciones sobre el catálogo	50
5.5.	Rendimiento por segmento de actividad	52
5.6.	El híbrido y el compromiso relevancia–cobertura	53
5.7.	Estudio de caso: recomendaciones explicables	54
5.8.	Usuarios nuevos: perfil por encuesta	56
6.	Conclusiones y trabajo futuro	59
	Referencias	61
A.	Anexo	67

Índice de figuras

3.1. Frente de Pareto de un problema biobjetivo	24
3.2. Taxonomía de las tareas de ABSA. Reconstruido de W. Zhang, Li, Deng, Bing, y Lam (2023).	28
4.1. Fracción de pueblos por usuario asignada a prueba	36
4.2. Número de pueblos por usuario asignado a prueba	37
4.3. Canalización de análisis basado en aspectos	38
4.4. Confianza de los clasificadores de aspecto y sentimiento	40
4.5. Composición de aspectos por tipo de establecimiento	40
5.1. Selección del número de clusters	46
5.2. Centroides de los clusters de intensidad	46
5.3. Centroides de los clusters temáticos	47
5.4. Proyección PCA de los perfiles temáticos	47
5.5. Coherencia perfil-visitas	48
5.6. Curvas de Lorenz de la exposición	51
5.7. Exposición frente a popularidad	51
5.8. Rendimiento por segmento de actividad	52
5.9. Barrido del peso de fusión	53
5.10. Análisis de sensibilidad del óptimo	54
5.11. Frente de Pareto realizado	55
5.12. Perfiles de los usuarios del estudio de caso	55
5.13. Simulación del perfil por encuesta	57

Índice de tablas

2.1.	Esquema del dataset crudo de reseñas turísticas.	7
2.2.	Estadísticas del dataset antes y después del filtrado de densidad. . . .	8
4.1.	Comparación entre la segmentación por oraciones (Punkt) y por bloques de caracteres de longitud fija, sobre el conjunto completo de reseñas.	39
4.2.	Ablación de la construcción de $\mathbf{X}$ e $\mathbf{Y}$. La columna de saturación indica la fracción de entradas de $\mathbf{Y}$ que superan 4.5 sobre un máximo de 5. Resultados del modelo de contenido a $K = 20$	42
5.1.	Rendimiento de los modelos individuales para distintos cortes K . P, R y NDCG denotan precisión, exhaustividad y <i>ranking</i> ; MRR el rango recíproco medio; ILD la diversidad intra-lista; y Cov la cobertura de catálogo.	50
5.2.	Pruebas de Wilcoxon pareadas por usuario sobre el NDCG@10 de los modelos individuales. Δ es la diferencia de medias; los p-valores incluyen la corrección de Holm; r es el tamaño de efecto.	50
5.3.	Top-3 de CBQuality para los tres usuarios del estudio de caso, con la fracción del puntaje aportada por los aspectos dominantes. La última columna indica si el pueblo apareció en las visitas futuras del usuario.	56
5.4.	Simulación del perfil por encuesta: métricas a $K = 10$ al sustituir el perfil continuo por su versión cuantizada. El híbrido se evalúa en $\alpha^*(\beta = 0.5)$	57

Capítulo 1

Introducción

Los Sistemas de Recomendación (SR) se han convertido en una herramienta fundamental en la era digital tanto para las empresas como para los usuarios, facilitando la toma de decisiones en un entorno saturado de información y mejorando la interacción del usuario con el producto o servicio. Estos beneficios se extienden a diversos sectores, incluyendo el comercio electrónico, el entretenimiento, aplicaciones móviles, entre otros (Raza y cols., 2025). En particular, en el sector turístico, los usuarios se enfrentan a un amplio catálogo de opciones aun cuando se restringen a su propio país, lo que hace que los SR sean cruciales para ayudar a los turistas a encontrar sus Puntos de Interés (PI) ideales (She, Haw, y Chew, 2020). Este escenario es especialmente relevante en México, donde la diversidad de destinos turísticos y la riqueza cultural hacen que la elección de un destino sea una tarea compleja para los turistas. Este es el problema que abordaremos en esta tesis.

1.1. Motivación

Actualmente, el sector turístico representa un pilar importante para la economía de México, impulsando el desarrollo regional y contribuyendo de manera directa al bienestar de la población. Este impacto se refleja en contribuciones considerables al Producto Interno Bruto del país (8.7% en 2024), generando empleo y atrayendo inversiones tanto nacionales como extranjeras (SECTUR, 2025). Uno de los programas turísticos más emblemáticos propuesto por la Secretaría de Turismo (SECTUR), es el programa de Pueblos Mágicos (PM), que busca promover destinos turísticos en localidades pequeñas con características culturales, históricas o naturales únicas. Se ha observado que la iniciativa de los PM ha resultado ser beneficioso para estas comunidades tanto económica como culturalmente (Fernández Poncela, 2016). Es por esto que desarrollar un SR efectivo para recomendar Pueblos Mágicos a los turistas no solo tiene el potencial de mejorar la experiencia del usuario, sino también de contribuir al desarrollo sostenible de estas comunidades y a la promoción del turismo nacional.

Sin embargo, los turistas se enfrentan a un problema de elección considerable: a

inicios del año 2026, el programa contempla 177 localidades distribuidas a lo largo del territorio nacional. Los SR basados únicamente en el historial de valoraciones presentan limitaciones estructurales en este contexto: los datos de reseñas de Pueblos Mágicos exhiben una alta dispersión y un marcado sesgo positivo en las calificaciones, estos rasgos degradan la capacidad predictiva del filtrado colaborativo clásico (Koren, Bell, y Volinsky, 2009). Múltiples propuestas de Sistemas de Recomendación Híbridos (SRH) han demostrado ser efectivos para suavizar la limitación de la dispersión, añadiendo módulos de recomendación basados en contenido o en conocimiento que puedan complementar la predicción de preferencias (Hossain, Sikder, y Andreou, 2025), por lo que esta dirección se presenta como una solución prometedora para el caso de los Pueblos Mágicos.

Al mismo tiempo, las reseñas textuales que acompañan a las valoraciones contienen información semántica valiosa sobre aspectos específicos del destino que los enfoques basados exclusivamente en calificaciones numéricas no aprovechan. El Análisis de Sentimientos Basado en Aspectos (*Aspect-Based Sentiment Analysis*, ABSA) ha surgido como una alternativa para extraer preferencias a nivel fino a partir de texto (W. Zhang y cols., 2023). Integrar ABSA en un SR permite construir perfiles de usuario y de destino multidimensionales que capturan la importancia relativa de cada aspecto turístico para cada viajero y la calidad asociada a cada aspecto en cada destino.

Es por esto que en este trabajo se propone un SRH para Pueblos Mágicos que fusiona dos modelos complementarios basados en aspectos: un componente colaborativo, que estima preferencias a partir de la similitud entre usuarios en el espacio de aspectos, y un componente basado en contenido, que empareja la atención del usuario con la calidad del destino a nivel de aspecto. Ambos se combinan mediante una combinación convexa gobernada por un único peso de fusión; el filtrado colaborativo clásico mediante factorización de matrices con sesgos (Koren y cols., 2009) se conserva únicamente como baseline individual de referencia. La información aspecto-sentimiento se extrae mediante una cadena de procesamiento ABSA aplicada al corpus de reseñas del conjunto de datos REST-MEX (Álvarez-Carmona y cols., 2021), que registra opiniones sobre hoteles, restaurantes y atractivos de Pueblos Mágicos. Al ajustar el peso de fusión, el sistema modula el compromiso entre la precisión y la diversidad de las recomendaciones, ofreciendo un control operativo del que carece cualquier componente individual (Burke, 2002).

1.2. Hipótesis de trabajo

La hipótesis de esta tesis es que la integración de información aspecto-sentimiento extraída de reseñas textuales en un sistema de recomendación híbrido mejora la precisión y la diversidad de las recomendaciones de Pueblos Mágicos respecto a enfoques basados únicamente en calificaciones numéricas.

1.3. Objetivos

Objetivo general

Diseñar, implementar y evaluar un sistema de recomendación híbrido para Pueblos Mágicos de México, que integre componentes colaborativos y basados en contenido, con un esquema de fusión que permita ajustar el compromiso entre la precisión y la diversidad de las recomendaciones.

Objetivos específicos

1. Preparar el corpus de trabajo a partir del dataset REST-MEX 2025 (Álvarez-Carmona y cols., 2025), realizando una limpieza de datos y aplicando un filtrado iterativo que garantice una densidad mínima en la matriz de interacciones.
2. Implementar una cadena de procesamiento ABSA en español para el dominio turístico, compuesta por segmentación de reseñas, clasificación *Zero-Shot* de aspectos turísticos y clasificación de sentimiento.
3. Derivar las matrices estructurales del sistema: una matriz de calificaciones usuario-pueblo, una matriz de atención usuario-aspecto y una matriz de calidad destino-aspecto, estas dos últimas construidas a partir de la información aspecto-sentimiento.
4. Implementar tres modelos de recomendación: (i) un baseline de filtrado colaborativo clásico mediante factorización matricial con sesgos (Koren y cols., 2009), (ii) un componente colaborativo basado en la similitud entre usuarios en el espacio de aspectos, y (iii) un componente basado en contenido por correspondencia entre la atención del usuario y la calidad del destino a nivel de aspecto.
5. Calibrar el peso de fusión del híbrido mediante un barrido sobre su rango admisible, caracterizando el compromiso entre la precisión y la diversidad de las recomendaciones a lo largo de dicho barrido.
6. Evaluar el sistema bajo un protocolo de validación por *leave-one-out* por usuario, reportando métricas de precisión de ranking y de diversidad.

1.4. Contribución

Las contribuciones de este trabajo se organizan en cuatro planos:

Contribución metodológica. Se propone una arquitectura híbrida de dos componentes complementarios por construcción, fusionados mediante un único peso ajustable. Este esquema permite adaptar el sistema a diferentes objetivos operativos (precisión o diversidad) sin rediseñar los componentes.

Contribución técnica. Se libera el framework *mtrs*, una implementación modular y reproducible que incluye: (i) el pipeline ABSA productivo para español turístico con dos estrategias de segmentación (*Punkt* y *char-based*), (ii) las rutinas de construcción de las matrices estructurales del sistema, y (iii) las implementaciones de los tres recomendadores.

Contribución aplicada. El sistema desarrollado constituye una herramienta potencialmente útil para el sector turístico mexicano al producir recomendaciones de Pueblos Mágicos. Al permitir modular el compromiso entre la precisión y la diversidad del catálogo expuesto, el sistema contribuye al objetivo de la SECTUR de distribuir los flujos turísticos hacia destinos menos visibles pero igualmente valiosos (SECTUR, 2025).

1.5. Organización de la tesis

Capítulo 2

Conjunto de datos

En este capítulo se describe el origen, estructura y preprocesamiento del conjunto de datos utilizado en este trabajo. El corpus proviene de la tarea compartida REST-MEX 2025 (Álvarez-Carmona y cols., 2025), organizada en el marco de IberLEF 2025 (González-Barba, Chiruzzo, y Jiménez-Zafra, 2025). Se detalla el contexto del evento, la composición del dataset original, y el proceso de filtrado aplicado para obtener una matriz de interacciones con densidad suficiente para el entrenamiento de sistemas de recomendación.

2.1. La tarea compartida REST-MEX

REST-MEX (*Research on Sentiment Analysis Task for Mexican Tourist Texts*) es una tarea compartida organizada dentro del foro de evaluación IberLEF (*Iberian Languages Evaluation Forum*), cuyo objetivo es establecer referencias comparativas (*benchmarks*) para sistemas de procesamiento de lenguaje natural en el ámbito del turismo mexicano.

La tarea se lanzó en 2021 con un enfoque en la predicción de polaridad de reseñas turísticas en español (Álvarez-Carmona y cols., 2021). En ediciones subsecuentes, se incorporó la clasificación del tipo de servicio reseñado (hotel, restaurante o atractivo) (Álvarez-Carmona y cols., 2022) y la identificación del país de origen de la reseña (Álvarez-Carmona y cols., 2023). La edición 2025 marca la cuarta iteración del evento e introduce cambios significativos: (i) la clasificación geográfica se refina a nivel de Pueblo Mágico específico (40 pueblos predefinidos), (ii) el corpus se amplía considerablemente, y (iii) se fomenta el uso de técnicas avanzadas como ingeniería de *prompts*, binarización de clases y selección de instancias basada en centroides.

En esta edición, 32 equipos participantes enviaron un total de 70 sistemas válidos, explorando una amplia variedad de enfoques que incluyen modelos basados en Transformers, aprendizaje por transferencia, esquemas de binarización y estrategias de selección de instancias (Álvarez-Carmona y cols., 2025). La tarea se estructura en

tres subtareas simultáneas que, dada una reseña turística, requieren determinar:

1. La **polaridad** del sentimiento, en una escala ordinal de 1 (muy malo) a 5 (muy bueno).
2. El **tipo de servicio** reseñado: *Attractive*, *Hotel* o *Restaurant*.
3. El **Pueblo Mágico** específico al que refiere la reseña, seleccionado de una lista predefinida de 40 destinos.

2.2. Corpus

El corpus REST-MEX 2025 consta de 297,217 escritas por turistas que visitaron destinos representativos de México y compartieron sus opiniones en la plataforma TripAdvisor entre 2001 y 2023. Cada reseña está etiquetada con una calificación de polaridad en una escala ordinal de cinco puntos $\{1, 2, 3, 4, 5\}$, el tipo de negocio (*Attractive*, *Hotel*, *Restaurant*) y el Pueblo Mágico correspondiente.

El corpus presenta un notable desbalance de clases en los tres ejes de clasificación. En el eje de polaridad, la clase 5 (muy bueno) concentra el 65.6 % de las instancias de entrenamiento (136,561 de 208,051), mientras que las clases 1 y 2 representan conjuntamente menos del 5.3 %. En el eje geográfico, tres pueblos (Tulum, Isla Mujeres y San Cristóbal de las Casas) concentran el 42.2 % de las instancias.

Para los fines de esta tesis, se recopiló un conjunto extendido de reseñas a partir de los archivos fuente del evento, resultando en un conjunto de datos crudo de 313,836 registros con 12 columnas originales.

2.3. Estructura y limpieza

Cada registro del dataset crudo contiene los siguientes campos:

El proceso de limpieza consistió en:

- **Eliminación de columnas redundantes:** se descartó el origen del autor (53.5 % de valores nulos), la fecha de la opinión (redundante con la fecha de la estadía) y el país (valor constante “Mexico”).
- **Eliminación de registros incompletos:** se eliminaron filas con valores nulos en los campos *Author*, *Calificacion*, *Review* o *FechaEstadia*, reduciendo el dataset de 313,836 a **306,854 registros**.
- **Conversión de fechas:** el campo *FechaEstadia*, originalmente en formato textual en español (e.g., “enero de 2023”), se convirtió a formato *datetime* mediante un mapeo de nombres de meses en español a sus equivalentes numéricos.

Tabla 2.1: Esquema del dataset crudo de reseñas turísticas.

Campo	Tipo	Descripción
Author	Texto	Seudónimo del usuario en TripAdvisor
Titulo	Texto	Título de la reseña
Review	Texto	Cuerpo de la reseña
Calificacion	Númerico	Calificación numérica (1–5)
OrigenAutor	Texto	País de origen del autor
FechaOpinion	Fecha	Fecha de publicación de la reseña
FechaEstadia	Fecha	Mes y año de la estancia
Pueblo	Texto	Pueblo Mágico del establecimiento
Estado	Texto	Estado de la república
Pais	Texto	País del establecimiento
Tipo	Texto	Tipo de servicio (Hotel/Restaurant/Attractive)
Lugar	Texto	Nombre del establecimiento

El dataset limpio resultante contiene 9 columnas y abarca estancias desde 2001 hasta 2023.

2.4. Filtrado para densidad de interacciones

Para el entrenamiento de algoritmos de filtrado colaborativo, es necesario que la matriz de interacciones usuario-ítem presente una densidad mínima que permita calcular similitudes confiables entre usuarios o entre ítems. El dataset limpio de 306,854 reseñas contiene un gran número de usuarios que han reseñado establecimientos en un solo Pueblo Mágico, lo cual resulta insuficiente para la tarea de recomendación a nivel de pueblos.

Se diseñó un procedimiento de filtrado iterativo con dos criterios de densidad (Algoritmo 1):

- **Usuarios activos:** retener únicamente usuarios que hayan reseñado establecimientos en al menos $\tau_u = 3$ Pueblos Mágicos distintos.
- **Pueblos con cobertura:** retener únicamente Pueblos Mágicos que contengan al menos $\tau_p = 10$ establecimientos (*Lugares*) distintos con reseñas.

Dado que la eliminación de usuarios puede dejar pueblos sin cobertura suficiente (y viceversa), el filtrado se aplica de forma iterativa hasta convergencia, es decir, hasta que ningún registro adicional sea eliminado. El Algoritmo 1 formaliza este procedimiento.

Algorithm 1 Filtrado iterativo para densidad de interacciones.

Require: Dataset $\mathcal{D}$, umbrales τ_u, τ_p **Ensure:** Dataset filtrado $\mathcal{D}'$

```

1:  $\mathcal{D}' \leftarrow \mathcal{D}$ 
2: repeat
3:    $n_{\text{prev}} \leftarrow |\mathcal{D}'|$ 
4:    $\mathcal{U}_{\text{dense}} \leftarrow \{u \in \mathcal{U} \mid |\{p : \exists r \in \mathcal{D}' \text{ con } r.\text{Author} = u, r.\text{Pueblo} = p\}| \geq \tau_u\}$ 
5:    $\mathcal{D}' \leftarrow \{r \in \mathcal{D}' \mid r.\text{Author} \in \mathcal{U}_{\text{dense}}\}$ 
6:    $\mathcal{P}_{\text{dense}} \leftarrow \{p \in \mathcal{P} \mid |\{l : \exists r \in \mathcal{D}' \text{ con } r.\text{Pueblo} = p, r.\text{Lugar} = l\}| \geq \tau_p\}$ 
7:    $\mathcal{D}' \leftarrow \{r \in \mathcal{D}' \mid r.\text{Pueblo} \in \mathcal{P}_{\text{dense}}\}$ 
8: until  $|\mathcal{D}'| = n_{\text{prev}}$ 
9: return  $\mathcal{D}'$ 

```

2.5. Dataset de trabajo

La aplicación del filtrado iterativo con $\tau_u = 3$ y $\tau_p = 10$ reduce el dataset de 306,854 a **79,264 registros**, correspondientes a **9,582 usuarios** y **48 Pueblos Mágicos**. La Tabla 2.2 resume las estadísticas principales antes y después del filtrado.

Tabla 2.2: Estadísticas del dataset antes y después del filtrado de densidad.

Métrica	Dataset limpio	Dataset filtrado
Reseñas totales	306,854	79,264
Usuarios únicos	159,468	9,582
Pueblos Mágicos	95	48
Mín. pueblos/usuario	1	3
Máx. pueblos/usuario	35	28
Mín. lugares/pueblo	1	10
Máx. lugares/pueblo	103	103

La distribución de pueblos en el dataset filtrado presenta un marcado desbalance geográfico. Tulum es el pueblo con mayor representación (10,051 títulos únicos), seguido de Isla Mujeres (6,082) y San Cristóbal de las Casas (4,902), mientras que pueblos como Tecate (175), San Sebastián del Oeste (193) y Santiago (242) tienen una representación considerablemente menor.

En términos de la matriz de utilidad para el sistema de recomendación, la dispersión (*sparsity*) se calcula como:

$$\text{sparsity} = 1 - \frac{|\{(u, p) : \exists r \in \mathcal{D}'\}|}{|\mathcal{U}| \times |\mathcal{P}|} = 1 - \frac{n_{\text{interacciones}}}{9,582 \times 48} \approx 90.32 \% \quad (2.1)$$

Esta dispersión del 90.32 % implica que cada usuario ha interactuado, en promedio, con menos de 5 de los 48 pueblos disponibles. En cuanto a las calificaciones, la

media global es $\bar{r} = 4.41$ con el 61.3 % de las calificaciones siendo de 5 estrellas, reflejando el sesgo positivo característico de las plataformas de reseñas turísticas. Este desafío motiva a la adopción de un enfoque híbrido que combine señales colaborativas con información semántica extraída de las reseñas textuales, como se detalla en los capítulos subsecuentes.

Capítulo 3

Marco teórico

En este capítulo se presentan los fundamentos teóricos que sustentan el desarrollo de la metodología en este trabajo. Se abordan cuatro frentes: los sistemas de recomendación junto con sus métricas de evaluación (Sección 3.1); la optimización multiobjetivo y la eficiencia de Pareto, marco en el que se formaliza el *trade-off* relevancia–cobertura que persigue este trabajo (Sección 3.2); los fundamentos de procesamiento de lenguaje natural sobre los que se construye la extracción de aspectos y sentimientos a partir de las reseñas (Sección 3.3); y los modelos de recomendación que incorporan la información extraída por ABSA como señal explícita (Sección 3.4).

3.1. Sistemas de recomendación

Un sistema de recomendación (SR) es un sistema de filtrado de información diseñado para predecir una puntuación que refleje la experiencia real de un usuario con respecto a un ítem con el cual no ha interactuado previamente. Formalmente, el problema se define como la estimación de una función de utilidad:

$$\hat{r}_{u,i} = f(u, i; \Theta) \quad (3.1)$$

donde $f : \mathcal{U} \times \mathcal{I} \rightarrow \mathbb{R}$ es un escalar, $u \in \mathcal{U}$ representa un usuario, $i \in \mathcal{I}$ un ítem, Θ los parámetros del modelo y $\hat{r}_{u,i} \in \mathbb{R}$ es la puntuación que el SR asigna al ítem i para el usuario u . De forma general, el conjunto de interacciones observadas $\mathcal{O} = \{(u, i) \mid a_{u,i} \neq 0\}$ se organiza en una *matriz de interacciones* $\mathbf{A} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|}$, donde $a_{u,i}$ denota la interacción entre el usuario u y el ítem i , y las mayoría de las entradas permanecen desconocidas (Adomavicius y Tuzhilin, 2005).

Además, la interacción $a_{u,i}$ entre un usuario y un ítem puede ser definida de distintas formas, siendo la más común como una *calificación asignada*. La escala de la calificación varía conforme a los sistemas, la mayoría utilizan la escala 1-5 estrellas, mientras que otros pueden utilizar escalas binarias (interesado/no interesado). La interacción también puede ser definida como una *retroalimentación implícita*, haciendo

referencia a variables de acción por parte del usuario con respecto a un ítem (Oard, Kim, y cols., 1998). En este caso, las escalas de las interacciones pueden ser muy diversas, prácticamente, podría ser cualquier interacción usuario - ítem que funcione como señal del gusto o disgusto del usuario (e.g. tiempo de lectura en un libro, número de reproducciones de una canción, etc.).

El problema de inferencia en los SR consiste en estimar $\hat{r}_{u,i}$ para todo par $(u, i) \notin \mathcal{O}$. A partir de estas predicciones, las recomendaciones para el usuario u se obtienen seleccionando los K ítems no visitados con mayor puntuación estimada:

$$\text{Top-}K(u) = \arg \text{top-}K \hat{r}_{u,i} \quad (3.2)$$

donde $\mathcal{I}_u = \{i \in \mathcal{I} \mid a_{u,i} \neq 0\}$ es el conjunto de ítems con los que el usuario u ya ha interactuado.

Los SR se clasifican tradicionalmente en tres familias: filtrado colaborativo, filtrado basado en contenido y sistemas híbridos (Sarkar, Majumder, Panigrahi, Roy, y Pati, 2023). La diferencia entre los enfoques radica en cómo se parametriza f y qué información se utiliza para estimar Θ . A continuación se formalizan cada una de estas aproximaciones.

3.1.1. Filtrado colaborativo

El filtrado colaborativo (FC) se fundamenta en la hipótesis de que usuarios con comportamientos similares en el pasado tendrán preferencias similares en el futuro. El FC no requiere información sobre las características de los ítems; opera exclusivamente sobre la matriz de calificaciones $R \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|}$. Los métodos de FC se dividen en dos categorías: basados en memoria y basados en modelo.

Basado en memoria

Los métodos basados en memoria generan predicciones directamente a partir de las interacciones históricas, sin aprender un modelo paramétrico explícito ($\Theta = \emptyset$). Se distinguen dos variantes: basado en usuarios y basado en ítems.

- **FC basado en usuarios.** La predicción para un usuario u sobre un ítem i se calcula como el promedio ponderado de las calificaciones de los usuarios más similares a u que han calificado el ítem i :

$$\hat{r}_{u,i} = \bar{r}_u + \frac{\sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v) \cdot (r_{v,i} - \bar{r}_v)}{\sum_{v \in \mathcal{N}_k(u)} |\text{sim}(u, v)|} \quad (3.3)$$

donde $\bar{r}_u$ es la calificación promedio del usuario u , $\mathcal{N}_k(u)$ denota los k vecinos más similares a u que han calificado el ítem i , y $\text{sim}(u, v)$ es una medida de similitud entre usuarios. Las medidas más utilizadas son la similitud coseno (Eq. 3.4) y la correlación de Pearson (Eq. 3.5):

$$\text{sim}_{\cos}(u, v) = \frac{\sum_{i \in \mathcal{I}_{u,v}} r_{u,i} \cdot r_{v,i}}{\sqrt{\sum_{i \in \mathcal{I}_{u,v}} r_{u,i}^2} \cdot \sqrt{\sum_{i \in \mathcal{I}_{u,v}} r_{v,i}^2}} \quad (3.4)$$

$$\text{sim}_{\text{Pearson}}(u, v) = \frac{\sum_{i \in \mathcal{I}_{u,v}} (r_{u,i} - \bar{r}_u)(r_{v,i} - \bar{r}_v)}{\sqrt{\sum_{i \in \mathcal{I}_{u,v}} (r_{u,i} - \bar{r}_u)^2} \cdot \sqrt{\sum_{i \in \mathcal{I}_{u,v}} (r_{v,i} - \bar{r}_v)^2}} \quad (3.5)$$

donde $\mathcal{I}_{uv} = \{i \in \mathcal{I} \mid r_{ui} \neq 0 \wedge r_{vi} \neq 0\}$ es el conjunto de ítems co-calificados por ambos usuarios.

- **FC basado en ítems.** De manera análoga, la similitud se calcula entre ítems en lugar de entre usuarios. La predicción se obtiene como:

$$\hat{r}_{ui} = \frac{\sum_{j \in \mathcal{N}_k(i)} \text{sim}(i, j) \cdot r_{uj}}{\sum_{j \in \mathcal{N}_k(i)} |\text{sim}(i, j)|} \quad (3.6)$$

donde $\mathcal{N}_k(i)$ son los k ítems más similares a i que el usuario u ha calificado. Este enfoque tiende a ser más escalable que el basado en usuarios cuando $|\mathcal{U}| \gg |\mathcal{I}|$, ya que las similitudes entre ítems son más estables en el tiempo.

Ambas variantes enfrentan limitaciones inherentes: la complejidad computacional para el cálculo de similitudes es $O(|\mathcal{U}|^2 \cdot |\mathcal{I}|)$ u $O(|\mathcal{I}|^2 \cdot |\mathcal{U}|)$, su rendimiento se degrada en matrices con alta dispersión, y no pueden generar recomendaciones para usuarios o ítems nuevos (este problema es conocido como *cold-start*, se abordará en la sección 3.1.4).

Basado en modelo

Los métodos basados en modelo aprenden una representación paramétrica compacta de los patrones de interacción. La técnica más establecida es la **factorización matricial** (FM), que descompone la matriz de utilidad en el producto de dos matrices de menor dimensionalidad (Koren y cols., 2009):

$$\mathbf{R} \approx \mathbf{P}\mathbf{Q}^\top \quad (3.7)$$

donde $\mathbf{P} \in \mathbb{R}^{|\mathcal{U}| \times k}$ y $\mathbf{Q} \in \mathbb{R}^{|\mathcal{I}| \times k}$ representan las matrices de factores latentes de usuarios e ítems, respectivamente, y $k \ll \min(|\mathcal{U}|, |\mathcal{I}|)$ es la dimensionalidad del espacio latente. Cada fila $\mathbf{p}_u \in \mathbb{R}^k$ codifica las preferencias del usuario u , y cada fila $\mathbf{q}_i \in \mathbb{R}^k$ las características latentes del ítem i , de modo que la predicción se obtiene como:

$$\hat{r}_{ui} = \mathbf{p}_u^\top \mathbf{q}_i \quad (3.8)$$

Para estimar los parámetros, se minimiza el error cuadrático regularizado sobre las interacciones observadas $\mathcal{K}$:

$$\min_{\mathbf{P}, \mathbf{Q}} \sum_{(u,i) \in \mathcal{K}} (r_{ui} - \mathbf{p}_u^\top \mathbf{q}_i)^2 + \lambda (\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2) \quad (3.9)$$

donde $\lambda > 0$ es el coeficiente de regularización que previene el sobreajuste. Esta optimización se resuelve típicamente mediante descenso por gradiente estocástico (SGD) o mínimos cuadrados alternados (ALS).

Se consideran las siguientes variantes relevantes para este trabajo:

- **SVD** (*Singular Value Decomposition*): Extiende la Ecuación (3.8) incorporando sesgos de usuario e ítem:

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^\top \mathbf{q}_i \quad (3.10)$$

donde μ es la media global de calificaciones, b_u el sesgo del usuario y b_i el sesgo del ítem.

- **SVD++**: Incorpora retroalimentación implícita al modelo SVD, enriqueciendo la representación del usuario con información de los ítems que ha calificado (Koren, 2008):

$$\hat{r}_{ui} = \mu + b_u + b_i + \left(\mathbf{p}_u + |\mathcal{I}_u|^{-\frac{1}{2}} \sum_{j \in \mathcal{I}_u} \mathbf{y}_j \right)^\top \mathbf{q}_i \quad (3.11)$$

donde $\mathcal{I}_u$ es el conjunto de ítems calificados por u y $\mathbf{y}_j \in \mathbb{R}^k$ son vectores que capturan la influencia implícita de haber interactuado con el ítem j .

- **NMF** (*Non-negative Matrix Factorization*): Impone la restricción $\mathbf{P} \geq 0$, $\mathbf{Q} \geq 0$, lo que produce representaciones aditivas más interpretables, donde cada factor latente contribuye exclusivamente de forma positiva a la predicción.

3.1.2. Filtrado basado en contenido

El filtrado basado en contenido (FBC) recomienda ítems cuyas características son similares a las de ítems previamente preferidos por el usuario (Pazzani y Billsus, 2007). A diferencia del FC, el FBC opera sobre una descripción explícita de los atributos de

los ítems y no requiere información de otros usuarios. Arquitectónicamente, un sistema de FBC se compone de tres módulos (Lops, de Gemmis, y Semeraro, 2011): (1) un *analizador de contenido* que extrae características de los ítems a partir de su descripción, (2) un *aprendiz de perfil* que construye y actualiza el modelo de preferencias del usuario a partir de su historial de interacciones, y (3) un *componente de filtrado* que genera recomendaciones comparando el perfil del usuario con las representaciones de los ítems candidatos.

Representación de ítems

Cuando los ítems se describen mediante texto no estructurado (reseñas, artículos, descripciones de productos), la representación más empleada es el **Modelo de Espacio Vectorial** (VSM) con ponderación TF-IDF (Aggarwal, 2016; Lops y cols., 2011). Dado un corpus de N documentos y un diccionario $T = \{t_1, \dots, t_n\}$, el peso del término t_k en el documento d_j se define como:

$$\text{TF-IDF}(t_k, d_j) = \frac{f_{k,j}}{\max_z f_{z,j}} \cdot \log \frac{N}{n_k} \quad (3.12)$$

donde $f_{k,j}$ es la frecuencia de t_k en d_j , $\max_z f_{z,j}$ normaliza por el término más frecuente del documento, y n_k es el número de documentos en los que t_k aparece al menos una vez. El ítem i queda representado como el vector normalizado $\phi(i) \in \mathbb{R}^{|T|}$ de sus pesos TF-IDF. Cuando los ítems poseen atributos estructurados (e.g. género cinematográfico, valoración numérica por categoría, sentimiento promedio por aspecto derivado de reseñas), el perfil del ítem se construye directamente como un vector $\phi(i) \in \mathbb{R}^d$ de d características, produciendo representaciones más compactas e interpretables (Y. Zhang y cols., 2014).

Perfil del usuario y predicción

El perfil del usuario $\theta(u) \in \mathbb{R}^d$ se construye como el promedio ponderado por calificación de los perfiles de ítems con los que ha interactuado:

$$\theta(u) = \frac{\sum_{i \in \mathcal{I}_u} r_{u,i} \cdot \phi(i)}{\sum_{i \in \mathcal{I}_u} r_{u,i}} \quad (3.13)$$

donde $r_{u,i}$ es la calificación del usuario u sobre el ítem i e $\mathcal{I}_u$ el conjunto de ítems con los que el usuario ha interactuado. La predicción para un par $(u, i) \notin \mathcal{O}$ se obtiene entonces mediante la similitud coseno entre ambos perfiles:

$$\hat{r}_{u,i} = \text{sim}(\theta(u), \phi(i)) = \frac{\theta(u)^\top \phi(i)}{\|\theta(u)\| \cdot \|\phi(i)\|} \quad (3.14)$$

Ventajas y limitaciones

El FBC presenta ventajas estructurales sobre el FC:

- **Independencia del usuario.** Las recomendaciones se generan a partir del perfil del usuario activo sin depender de las interacciones de terceros, eliminando el problema de vecindad escasa.
- **Transparencia.** Las recomendaciones pueden justificarse enumerando las características del ítem que coinciden con el perfil del usuario, a diferencia del FC que opera como caja negra.
- **Cold-start de ítems.** Un ítem nuevo puede recomendarse en cuanto se disponga de su representación de características, sin requerir calificaciones previas de otros usuarios.

No obstante, el FBC presenta limitaciones inherentes:

- **Sobre-especialización.** El sistema recomienda ítems similares a los ya preferidos, reduciendo la diversidad y dificultando la aparición de recomendaciones sorpresivas (*serendipity*).
- **Análisis de contenido limitado.** La calidad de las recomendaciones está acotada por la riqueza de la representación de características; atributos latentes o cualidades subjetivas no capturadas por los descriptores quedan fuera del alcance del modelo (Aggarwal, 2016).
- **Cold-start de usuario.** Se requiere un número mínimo de interacciones para construir un perfil informativo; con pocas calificaciones disponibles, las predicciones son poco confiables.

3.1.3. Sistemas híbridos

Los sistemas híbridos combinan múltiples estrategias de recomendación para compensar las debilidades individuales de cada enfoque (Raza y cols., 2025; Sarkar y cols., 2023). (Burke, 2002) propuso una taxonomía ampliamente adoptada que identifica siete clases de hibridación: *ponderada*, *conmutación*, *mixto*, *combinación de características*, *cascada*, *aumento de características* y *meta-nivel*. La revisión sistemática de Çano y Morisio (2017) sobre 76 publicaciones del periodo 2005–2015 confirma la vigencia de esta taxonomía y reporta que la mayoría de los sistemas combinan FC con otra técnica, siendo la hibridación ponderada la estrategia predominante (28.9% de los estudios) seguida por la combinación de características (15.8%).

Ponderada. La puntuación final se obtiene mediante una combinación lineal de las predicciones de cada recomendador individual, asignando pesos que pueden

ser globales, por usuario o adaptativos según retroalimentación. [de Campos, Fernández-Luna, Huete, y Rueda-Morales \(2010\)](#) ejemplifican esta estrategia integrando un módulo de FC y otro de FBC mediante una red bayesiana cuyos parámetros condicionales actúan como factores de ponderación, alcanzando mejoras frente a cada componente individual. La sencillez de su formulación y la facilidad para ajustar la influencia relativa de cada componente explican su popularidad.

Combinación de características. Las salidas de un recomendador se incorporan como características adicionales al conjunto de datos sobre el que opera el segundo recomendador (típicamente un FBC, que explota intensivamente atributos del ítem). De esta forma, la información colaborativa se integra como una variable explicativa más, reduciendo la sensibilidad a la dispersión de la matriz original.

Cascada. El proceso de recomendación es secuencial: una primera técnica genera un conjunto preliminar de candidatos y una segunda técnica refina dicho conjunto. Es sensible al orden de aplicación de los recomendadores, ya que la segunda etapa solo opera sobre los ítems supervivientes de la primera, lo que la hace eficiente computacionalmente y robusta frente a clasificaciones imprecisas en las primeras posiciones.

Conmutación. El sistema alterna dinámicamente entre distintas técnicas de acuerdo con un criterio (e.g., confianza de la predicción, disponibilidad de datos, contexto del usuario). El recomendador de noticias DailyLearner ([Billsus, Pazzani, y Chen, 2000](#)) ilustra esta clase: emplea un modelo CBF de corto plazo basado en clasificación por vecinos cercanos y, cuando una noticia carece de vecinos cercanos, conmuta a un modelo de largo plazo basado en un clasificador Naive Bayes que captura las preferencias generales del usuario.

Aumento de características. Una técnica genera predicciones o clasificaciones que enriquecen las características procesadas por la segunda. A diferencia de *feature combination*, los datos originales del segundo recomendador no se modifican; en su lugar, se le añaden atributos sintéticos. Libra ([Mooney y Roy, 2000](#)) es un recomendador de libros basado en contenido que aumenta las características textuales con los campos “autores relacionados” y “títulos relacionados” obtenidos del recomendador colaborativo de Amazon, mejorando así la calidad sin modificar el clasificador Naive Bayes subyacente.

Meta-nivel. El modelo aprendido por la primera técnica se utiliza íntegramente como entrada de la segunda. La distinción respecto al aumento de características es que aquí no se transfieren atributos individuales, sino una representación compacta del modelo. Fab ([Balabanović y Shoham, 1997](#)), uno de los primeros recomendadores web, construye perfiles vectoriales de usuario con un componente CBF que luego son consumidos por agentes colaborativos para identificar comunidades de intereses afines.

Mixto. Las listas de recomendaciones generadas por cada técnica se presentan simultáneamente al usuario, sin ser fusionadas en una única puntuación. Es la forma más simple de hibridación y resulta apropiada cuando se dispone de múltiples recomendadores complementarios. PTV (Smyth y Cotter, 2000), un sistema de recomendación de programación televisiva, presenta de manera conjunta los resultados de un módulo CBF basado en perfiles de programa y un módulo FC basado en similitud entre usuarios.

En esta tesis se adopta una estrategia de **combinación ponderada**, donde la predicción final es una combinación lineal convexa de las predicciones de los componentes colaborativo y basado en contenido:

$$\hat{r}_{ui} = \alpha \cdot \hat{r}_{ui}^{\text{CF}} + (1 - \alpha) \cdot \hat{r}_{ui}^{\text{CBF}} \quad (3.15)$$

donde $\alpha \in [0, 1]$ controla la contribución relativa de cada componente. Esta formulación se extiende naturalmente a un vector de pesos $\boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_M)$ cuando se combinan M señales de recomendación, sujeto a $\sum_{m=1}^M \alpha_m = 1$.

En esta tesis el híbrido se restringe a la combinación de $M = 2$ componentes basados en aspectos, de modo que el vector de pesos puede ser reducido a un único escalar $\alpha \in [0, 1]$. Esta reducción dimensional es determinante: la calibración del peso óptimo no constituye un problema de optimización en un espacio de alta dimensión que demande técnicas metaheurísticas, sino un barrido unidimensional sobre α del que el óptimo se lee directamente. Más aún, la selección de α no responde a un único criterio, sino al compromiso entre relevancia y cobertura, lo que sitúa el problema en el marco de la optimización multiobjetivo desarrollado en la Sección 3.2.

La integración de señales aspecto-sentimiento en el recomendador, donde los aspectos y sentimientos extraídos por el componente NLP enriquecen tanto los perfiles de usuario como los de ítem, ha demostrado ser efectiva en dominios donde la información textual complementa las calificaciones numéricas. Musto, de Gemmis, Semeraro, y Lops (2017) mostraron que un FC multi-criterio alimentado con sentimientos por aspecto extraídos automáticamente de reseñas supera tanto a algoritmos de un solo criterio como a técnicas de factorización matricial. Por su parte, Y. Zhang y cols. (2014) propusieron el *Explicit Factor Model* (EFM), que integra factores explícitos derivados de los aspectos y las opiniones de las reseñas con factores latentes en un modelo unificado. Este último enfoque, que sustenta la propuesta de esta tesis, se analiza en detalle en la Sección 3.4.

3.1.4. Problema del arranque en frío y dispersión

Dos desafíos fundamentales afectan el rendimiento de los SR, particularmente relevantes en el dominio turístico (Sarkar y cols., 2023): el arranque en frío y la dispersión de la matriz de interacciones. La primera se manifiesta en dos variantes:

- **De usuario:** usuarios nuevos sin historial de calificaciones, para los cuales el

FC no puede calcular similitudes. El FBC puede mitigar este problema si se dispone de información demográfica o preferencias explícitas iniciales.

- **De ítem:** ítems nuevos sin calificaciones, invisibles para el FC. En este trabajo, el pipeline de ABSA permite generar un perfil de aspectos para un nuevo Pueblo Mágico a partir de sus reseñas textuales, habilitando recomendaciones basadas en contenido sin historial de calificaciones numéricas.

La dispersión del 90.32 % en el dataset REST-MEX implica que cada usuario ha calificado, en promedio, menos de 5 de los 48 pueblos disponibles. Este nivel de dispersión degrada significativamente el rendimiento de los métodos basados en memoria, ya que la cantidad de ítems co-calificados entre pares de usuarios ($|\mathcal{I}_{uv}|$) tiende a ser pequeña, resultando en estimaciones de similitud poco confiables (Raza y cols., 2025). Las principales estrategias de mitigación incluyen: (i) factorización matricial, que generaliza patrones a partir de factores latentes aun con matrices dispersas; (ii) incorporación de información lateral (*side information*), como las reseñas textuales; y (iii) sistemas híbridos que combinan señales complementarias (Payandenick, Othman, y Payandenick, 2025).

3.1.5. Evaluación

La evaluación de un SR es un problema multifacético cuya configuración requiere decisiones explícitas sobre el tipo de experimento, los datos empleados, el protocolo de partición y el conjunto de métricas reportadas (Zangerle y Bauer, 2022). Tradicionalmente se distinguen tres modalidades: *evaluación en línea* (despliegue del sistema sobre usuarios reales y medición de señales como CTR o tasa de conversión), *estudios de usuario* (sujetos reclutados que interactúan con el sistema en un entorno controlado) y *evaluación fuera de línea* (uso de un *snapshot* histórico de interacciones para simular el comportamiento de los usuarios). En la práctica, la evaluación fuera de línea es predominante por su bajo costo, su reproducibilidad y la posibilidad de comparar de forma controlada múltiples configuraciones algorítmicas sobre los mismos datos. Su principal limitación es que mide la capacidad del modelo para reconstruir interacciones ya observadas, no la utilidad percibida por el usuario en un escenario real. La metodología adoptada en este trabajo es de tipo fuera de línea sobre el corpus REST-MEX descrito en el Capítulo 2.

Separación de conjuntos de entrenamiento y prueba

Toda evaluación fuera de línea requiere particionar el conjunto de interacciones $\mathcal{O}$ en un subconjunto de entrenamiento $\mathcal{O}_{\text{train}}$, sobre el que el SR ajusta sus parámetros, y un subconjunto de prueba $\mathcal{O}_{\text{test}}$, sobre el que se evalúa la capacidad predictiva. Aunque a primera vista parece una decisión secundaria, Cañamares, Castells, y Moffat (2020) muestran experimentalmente que la elección del protocolo de partición puede invertir el orden relativo de dos algoritmos comparados sobre el mismo conjunto de datos, lo

que convierte a esta etapa en un componente metodológico crítico. Las estrategias más empleadas en la literatura son:

- **División aleatoria.** Cada interacción se asigna a $\mathcal{O}_{\text{train}}$ o $\mathcal{O}_{\text{test}}$ con una probabilidad fija (típicamente 80:20 o 50:50), eventualmente bajo un esquema de validación cruzada de k pliegues. Es la opción más simple, pero ignora la dependencia temporal y permite que interacciones futuras de un usuario aparezcan en entrenamiento.
- **Leave- ℓ -out por usuario.** Para cada usuario con al menos ℓ interacciones, se reservan ℓ aleatoriamente para prueba. Garantiza que todo usuario participe en la evaluación; el caso $\ell = 1$ se conoce como *leave-one-out*.
- **Asignación por ítem.** Se reserva un número fijo de calificaciones por ítem para entrenamiento, mitigando el sesgo de popularidad que se produce cuando los ítems con muchas calificaciones también tienden a tener muchas en el conjunto de prueba.
- **División temporal.** Las interacciones se ordenan por su *timestamp* y se asignan las más antiguas a $\mathcal{O}_{\text{train}}$ y las más recientes a $\mathcal{O}_{\text{test}}$, ya sea con un punto de corte global o por usuario. Esta estrategia es la única que reproduce el escenario realista en el que el SR predice interacciones futuras a partir de información estrictamente pasada, evitando la fuga temporal de información.

Métricas

La evaluación de un SR Top- K no se reduce a la fidelidad numérica de la predicción de calificaciones (RMSE, MAE), pues estas métricas no reflejan la calidad del ordenamiento que el usuario realmente percibe. Por ello, las métricas dominantes en la literatura actual operan sobre la lista recomendada y se agrupan en al menos siete familias: precisión predictiva, predicción de uso, *ranking*, novedad, diversidad, cobertura y serendipia. Una configuración de evaluación rigurosa debe reportar simultáneamente varias de estas dimensiones, ya que un SR optimizado para una métrica puede degradar otras sin que ello sea evidente en una evaluación unidimensional.

Sea $\mathcal{R}_u^K = (i_1, \dots, i_K)$ la lista de los K ítems con mayor puntuación predicha para el usuario u que no pertenecen a $\mathcal{I}_u$, y sea $\text{Rel}(u) \subseteq \mathcal{I}$ el conjunto de ítems considerados relevantes para u en $\mathcal{O}_{\text{test}}$.

Métricas de ranking

Precision@K y Recall@K La *precisión* a profundidad K es la fracción de ítems recomendados que son relevantes, mientras que la *exhaustividad* (*recall*) mide la frac-

ción de ítems relevantes que el sistema logra recuperar entre los primeros K :

$$\text{P@}K(u) = \frac{|\mathcal{R}_u^K \cap \text{Rel}(u)|}{K}, \quad \text{R@}K(u) = \frac{|\mathcal{R}_u^K \cap \text{Rel}(u)|}{|\text{Rel}(u)|}. \quad (3.16)$$

Ambas se promedian sobre el conjunto de usuarios. Existe un compromiso natural entre ambas: aumentar K incrementa $\text{R@}K$ a costa de $\text{P@}K$, pues los ítems añadidos al final de la lista tienden a ser menos relevantes.

NDCG@K La *Normalized Discounted Cumulative Gain* pondera la posición del ítem en la lista, penalizando los ítems relevantes que aparezcan en posiciones bajas:

$$\text{DCG@}K(u) = \sum_{i=1}^K \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)}, \quad \text{NDCG@}K(u) = \frac{\text{DCG@}K(u)}{\text{IDCG@}K(u)}, \quad (3.17)$$

donde rel_i es la relevancia del ítem en la i -ésima posición y $\text{IDCG@}K(u)$ es el DCG del ordenamiento ideal sobre los ítems de prueba del usuario, lo que normaliza el valor al intervalo $[0, 1]$. Cuando las calificaciones se emplean como juicios graduados, la transformación $g(r) = 2^r - 1$ amplifica la contribución de las calificaciones altas frente a las moderadas. $\text{NDCG@}K$ es la métrica principal de optimización en esta tesis por dos motivos: (i) es sensible al orden, lo que se alinea con el carácter de *ranking* de la tarea; y (ii) es la métrica más reportada en la literatura de SR turísticos, lo que facilita la comparación con trabajos relacionados.

MRR (Mean Reciprocal Rank) El *rango recíproco medio* mide qué tan arriba aparece el primer ítem relevante en la lista recomendada:

$$\text{MRR} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{1}{\text{rank}_u}, \quad (3.18)$$

donde rank_u es la posición del primer ítem de $\text{Rel}(u)$ en $\mathcal{R}_u^K$ (con $1/\text{rank}_u = 0$ si ningún ítem relevante aparece en los primeros K). MRR es informativa cuando solo el primer acierto importa, pero ignora el resto de la lista.

Métricas beyond-accuracy

Diversidad La *intra-list diversity* (ILD) mide la disimilitud promedio entre pares de ítems dentro de una misma lista recomendada:

$$\text{ILD}(\mathcal{R}_u^K) = \frac{2}{K(K-1)} \sum_{1 \leq i < j \leq K} (1 - \text{sim}(\phi(i), \phi(j))), \quad (3.19)$$

donde $\text{sim}(\cdot, \cdot)$ es típicamente la similitud coseno sobre representaciones de ítems. En el contexto turístico, esta métrica es especialmente relevante para evitar recomen-

dar K pueblos pertenecientes al mismo estado o categoría, lo que reduciría el valor experiencial de la recomendación.

Cobertura La *cobertura de catálogo* cuantifica la fracción de ítems del sistema que aparecen al menos una vez en alguna recomendación:

$$\text{Coverage} = \frac{|\bigcup_{u \in \mathcal{U}} \mathcal{R}_u^K|}{|\mathcal{I}|}. \quad (3.20)$$

Esta métrica es relevante dado el desbalance del dataset REST-MEX, en el que un subconjunto reducido de pueblos concentra la mayoría de las reseñas: un SR podría obtener valores aceptables de $\text{NDCG}@K$ recomendando casi exclusivamente esos pueblos populares, sacrificando la exposición del catálogo en su conjunto.

3.2. Optimización multiobjetivo y eficiencia de Pareto

El análisis de las métricas de evaluación reveló que un SR no puede ser juzgado por un único criterio: la relevancia del *ranking* y la cobertura del catálogo son objetivos en conflicto que ningún sistema maximiza simultáneamente. Esta situación es un caso particular de un problema de **optimización multiobjetivo** (MOO), cuyo marco formal es la *eficiencia de Pareto*. Este marco proporciona las herramientas para razonar sobre soluciones de compromiso. El concepto fue introducido por el economista Vilfredo Pareto en el contexto de la economía del bienestar, donde una asignación de recursos se considera eficiente cuando no es posible mejorar la situación de un agente sin perjudicar la de otro (Barr, 2020), y posteriormente se generalizó como criterio de optimalidad en la teoría de la optimización vectorial (Miettinen, 1999). Esta sección formaliza el problema multiobjetivo, las nociones de dominancia y frente de Pareto, y el método de escalarización que se emplea en este trabajo para resolver el *trade-off* relevancia-cobertura.

3.2.1. Planteamiento del problema multiobjetivo

Un problema de optimización multiobjetivo busca optimizar de forma conjunta $k \geq 2$ funciones objetivo sobre un conjunto factible. Adoptando, sin pérdida de generalidad, la convención de minimización (todo objetivo a maximizar f_i se reescribe como $-f_i$), se formula como:

$$\min_{\mathbf{x} \in \Omega} \mathbf{F}(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_k(\mathbf{x})), \quad (3.21)$$

donde $\mathbf{x} = (x_1, \dots, x_n)$ es el *vector de decisión*, $\Omega \subseteq \mathbb{R}^n$ es el *espacio de decisión factible* (definido por las restricciones del problema) y $\mathbf{F} : \Omega \rightarrow \mathbb{R}^k$ aplica cada

solución a su *vector de objetivos*. La imagen $\mathcal{Z} = \mathbf{F}(\Omega) \subseteq \mathbb{R}^k$ se denomina *región objetivo factible* y es el espacio en el que se evalúan los compromisos entre criterios (Deb, 2011; Miettinen, 1999). A diferencia de la optimización escalar ($k = 1$), en la que el orden total de $\mathbb{R}$ induce un único óptimo, en $\mathbb{R}^k$ con $k \geq 2$ no existe un orden total natural entre vectores, por lo que el problema (3.21) carece, en general, de una solución única que minimice todos los objetivos a la vez.

3.2.2. Dominancia y optimalidad de Pareto

El orden parcial que sustituye al orden total escalar es la **relación de dominancia de Pareto**. Dados dos vectores de objetivos $\mathbf{u}, \mathbf{v} \in \mathbb{R}^k$, se dice que $\mathbf{u}$ *domina* a $\mathbf{v}$ (denotado $\mathbf{u} \prec \mathbf{v}$) si y solo si $\mathbf{u}$ no es peor en ningún objetivo y es estrictamente mejor en al menos uno:

$$\mathbf{u} \prec \mathbf{v} \iff (\forall i \in \{1, \dots, k\} : u_i \leq v_i) \wedge (\exists i_0 \in \{1, \dots, k\} : u_{i_0} < v_{i_0}). \quad (3.22)$$

A partir de esta relación, una solución $\mathbf{x}^* \in \Omega$ es **Pareto-óptima** (o eficiente) si no existe ninguna otra solución factible que la domine en el espacio de objetivos:

$$\mathbf{x}^* \text{ es Pareto-óptima} \iff \nexists \mathbf{x} \in \Omega : \mathbf{F}(\mathbf{x}) \prec \mathbf{F}(\mathbf{x}^*). \quad (3.23)$$

Intuitivamente, en una solución Pareto-óptima no es posible mejorar ningún objetivo sin degradar simultáneamente al menos otro. Se distingue además la **optimalidad débil de Pareto**, que relaja la condición exigiendo que no exista $\mathbf{x}$ con $f_i(\mathbf{x}) < f_i(\mathbf{x}^*)$ para *todos* los objetivos a la vez; toda solución Pareto-óptima es débilmente óptima, pero no a la inversa (Miettinen, 1999).

El conjunto de todas las soluciones Pareto-óptimas en el espacio de decisión se denomina **conjunto de Pareto**, $\mathcal{P} = \{\mathbf{x}^* \in \Omega : \mathbf{x}^* \text{ es Pareto-óptima}\}$, y su imagen en el espacio de objetivos constituye el **frente de Pareto**:

$$\mathcal{PF} = \mathbf{F}(\mathcal{P}) = \{\mathbf{F}(\mathbf{x}^*) : \mathbf{x}^* \in \mathcal{P}\} \subseteq \mathcal{Z}. \quad (3.24)$$

El frente de Pareto es el lugar geométrico de los compromisos eficientes: la frontera de la región factible $\mathcal{Z}$ más allá de la cual no existen soluciones alcanzables. La Figura 3.1 ilustra estos conceptos para un problema biobjetivo. Los puntos p_1 y p_2 pertenecen al frente (línea gruesa) y son no dominados; en cambio, el punto interior p_3 está dominado por p_1 , que para igual valor de f_1 alcanza un menor f_2 . Resolver un problema multiobjetivo consiste, entonces, en identificar (o aproximar) el frente de Pareto y seleccionar sobre él la solución que mejor refleje las preferencias del decisor.

3.2.3. Escalarización por suma ponderada

Dado que el frente de Pareto contiene, en general, infinitas soluciones, los métodos de resolución de problemas MOO deben incorporar información de preferencia para




Figura 3.1: Frente de Pareto (línea gruesa) de un problema con dos objetivos a minimizar. El área coloreada T es la imagen de la función objetivo; los puntos p_1 y p_2 son soluciones no dominadas sobre el frente, mientras que p_3 es dominado por p_1 . En este ejemplo se considera un caso de minimización. Fuente: [Wikimedia Commons](#), licencia CC BY-SA 3.0.

seleccionar puntos concretos. Las técnicas *a priori* de **escalarización** transforman el problema vectorial (3.21) en una familia de problemas escalares parametrizados, cada uno de los cuales puede resolverse con herramientas de optimización estándar (Marler y Arora, 2004; Miettinen, 1999). El método de escalarización más difundido es la **suma ponderada**, que agrega los objetivos en una combinación convexa:

$$\min_{\mathbf{x} \in \Omega} \sum_{i=1}^k w_i f_i(\mathbf{x}), \quad w_i \geq 0, \quad \sum_{i=1}^k w_i = 1, \quad (3.25)$$

donde los pesos w_i codifican la importancia relativa asignada a cada objetivo. La propiedad fundamental que justifica el método es que, si todos los pesos son estrictamente positivos ($w_i > 0$), la solución de (3.25) es Pareto-óptima; recíprocamente, cuando la región objetivo factible es *convexa*, todo punto del frente de Pareto puede obtenerse para alguna elección de pesos, de modo que barrer el espacio de pesos reconstruye el frente completo (Miettinen, 1999). Esta garantía deja de cumplirse en problemas no convexos: las porciones cóncavas del frente son inalcanzables por la suma ponderada, limitación bien documentada en la literatura (Marler y Arora, 2004). Pese a ello, la suma ponderada sigue siendo el método de escalarización de referencia por su transparencia interpretativa y su bajo costo computacional.

3.2.4. Aplicación al trade-off relevancia–cobertura

En esta tesis, el problema de seleccionar el peso de fusión del recomendador híbrido se formula como un problema biobjetivo ($k = 2$) en el que se busca *maximizar* simultáneamente la relevancia y la cobertura:

$$\max_{\alpha \in [0,1]} (\text{NDCG@}K(\alpha), \text{Cov@}K(\alpha)), \quad (3.26)$$

donde el vector de decisión se reduce a un *único escalar* α , el peso de la fusión convexa de la Ecuación (3.15). Aplicando la escalarización por suma ponderada (3.25) con un peso de preferencia $\beta \in [0, 1]$, el problema vectorial se convierte en la maximización del objetivo escalar:

$$f(\alpha; \beta) = \beta \text{NDCG@}K(\alpha) + (1 - \beta) \text{Cov@}K(\alpha), \quad (3.27)$$

en el que $\beta = 1$ recupera la optimización pura de relevancia y $\beta = 0$ la de cobertura. Como ambos objetivos se ponderan de forma no negativa, el maximizador de (3.27) es una solución Pareto-óptima del problema (3.26).

La particularidad que distingue este planteamiento es que el espacio de decisión es unidimensional. En consecuencia, el óptimo para cada nivel de preferencia,

$$\alpha^*(\beta) = \arg \max_{\alpha \in [0,1]} f(\alpha; \beta), \quad (3.28)$$

se obtiene mediante un **barrido unidimensional**: se evalúa $f(\alpha; \beta)$ sobre una rejilla de valores de α y se lee el máximo directamente de la curva. Este procedimiento es exacto hasta la resolución de la rejilla y computacionalmente trivial, por lo que *no se requiere recurrir a metaheurísticas* (algoritmos genéticos, enjambre de partículas, evolución diferencial u optimización bayesiana), reservadas para espacios de búsqueda de alta dimensión, multimodales o no diferenciables donde la enumeración exhaustiva es inviable. Finalmente, la trayectoria $\alpha^*(\beta)$ obtenida al variar $\beta \in [0, 1]$ recorre el frente de Pareto del sistema y constituye el resultado central del *trade-off* relevancia–cobertura que da título a este trabajo.

3.3. Procesamiento de Lenguaje Natural

El texto de las reseñas constituye una fuente de información semántica complementaria a las calificaciones numéricas, y suele contener juicios diferenciados sobre múltiples atributos del ítem que la puntuación global agrega en un único escalar. El procesamiento de lenguaje natural (NLP) provee la infraestructura para extraer dicha estructura: codifica el texto en representaciones manipulables algorítmicamente y, sobre ellas, formula tareas de clasificación, etiquetado o generación. Esta sección presenta los fundamentos sobre los que se apoyan los componentes textuales del recomendador propuesto. Se introducen primero las representaciones distribuidas y

contextuales sobre las que opera el NLP moderno (Sección 3.3.1); a continuación se formaliza el análisis de sentimientos basado en aspectos (ABSA) y sus subtareas (Sección 3.3.2); y por último se describen los dos paradigmas instrumentales empleados en este trabajo: la clasificación zero-shot vía inferencia textual para detectar categorías de aspecto (Sección 3.3.4) y la clasificación supervisada con codificadores Transformer ajustados al dominio para inferir polaridad (Sección 3.3.5).

3.3.1. Representación de texto

Las primeras representaciones empleadas en NLP discretizaban el texto mediante esquemas de *bag-of-words* y ponderación TF-IDF (Eq. 3.12), produciendo vectores de muy alta dimensionalidad y dispersos que descartaban el orden de las palabras y la ambigüedad semántica (Aggarwal, 2016). Los *word embeddings* densos (e.g. Word2Vec (Mikolov, Chen, Corrado, y Dean, 2013), GloVe (Pennington, Socher, y Manning, 2014)) introdujeron representaciones de baja dimensionalidad $\mathbf{e}_w \in \mathbb{R}^d$ ($d \approx 50\text{--}300$) entrenadas para preservar relaciones distribucionales entre palabras: vocablos que aparecen en contextos similares quedan cercanos en el espacio vectorial. No obstante, son *embeddings* estáticos: una palabra ambigua como “banco” recibe un único vector independientemente de si la oración refiere a una entidad financiera o a un asiento. Los modelos contextuales basados en Transformer (Vaswani y cols., 2017) subsanan esta limitación produciendo $\mathbf{e}_{w,t} \in \mathbb{R}^d$ *condicionado* al contexto t en el que aparece la palabra (Devlin, Chang, Lee, y Toutanova, 2019).

La arquitectura Transformer modela las dependencias entre tokens mediante un mecanismo de *self-attention* escalado:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (3.29)$$

donde $\mathbf{Q} \in \mathbb{R}^{n \times d_k}$, $\mathbf{K} \in \mathbb{R}^{n \times d_k}$ y $\mathbf{V} \in \mathbb{R}^{n \times d_v}$ son proyecciones lineales aprendidas de la entrada (*queries*, *keys*, *values*) sobre los n tokens de la secuencia, y $\sqrt{d_k}$ es un factor de escala que estabiliza los gradientes. La operación se aplica en paralelo en múltiples *heads* (*multi-head attention*), permitiendo capturar relaciones de tipos heterogéneos. Como la atención es invariante a permutaciones, se añaden *embeddings* posicionales para inyectar el orden de la secuencia.

Modelos basados en el módulo codificador de la arquitectura Transformer como BERT (Devlin y cols., 2019) y RoBERTa (Y. Liu y cols., 2019) preentrenan apilamientos profundos de bloques Transformer sobre corpora masivos en la tarea de *masked language modeling* (MLM). Una consecuencia de este enfoque es que los *embeddings* de palabras aprendidos durante el preentrenamiento son transferibles a tareas *downstream* realizando un ajuste fino adicional. A este paradigma se le conoce como *transfer learning* y ha establecido el estado del arte en prácticamente todas las subtareas del NLP supervisado (Do, Prasad, Maag, y Alsadoon, 2019; W. Zhang y cols., 2023), resultando especialmente ventajoso en dominios con escasos datos etiquetados, como

el turismo en español.

3.3.2. Análisis de sentimientos basado en aspectos

El *análisis de sentimientos basado en aspectos* (ABSA, por sus siglas en inglés) tiene por objeto recuperar la estructura aspectual del juicio expresado en un texto: dado un texto t , identificar un conjunto de tuplas $\{(a_k, s_k)\}_{k=1}^K$ donde a_k denota un aspecto del ítem y s_k su polaridad asociada (B. Liu, 2012; W. Zhang y cols., 2023). A diferencia del análisis de sentimientos a nivel de documento, que atribuye una sola etiqueta s a la totalidad del texto, el ABSA opera con granularidad fina y reconoce la coexistencia de juicios opuestos sobre aspectos distintos en una misma reseña.

Siguiendo a W. Zhang y cols. (2023), el ABSA se articula en torno a cuatro elementos de sentimiento: la *categoría de aspecto* $c \in \mathcal{C}$ (clase predefinida del aspecto, e.g., **comida**, **servicio**), el *término de aspecto* a (mención explícita en el texto, e.g., “*pizza*” como instancia de **comida**), el *término de opinión* o (expresión que vehicula el juicio, e.g., “*deliciosa*”) y la *polaridad* $p \in \{\text{POS}, \text{NEU}, \text{NEG}\}$ (o, en escalas de granularidad fina, $p \in \{1, \dots, 5\}$). La Figura 3.2 muestra una taxonomía de las tareas de ABSA, donde las distintas combinaciones de elementos definen tareas: tareas *simples* predicen un único elemento (e.g., extracción del término de aspecto, ATE), mientras que tareas *compuestas* predicen tuplas (a, p) , (c, p) , (a, o, p) o el cuádruple (c, a, o, p) . En particular, las tres subtareas históricamente establecidas en SemEval (Do y cols., 2019; Pontiki y cols., 2016) son:

- **Aspect Term Extraction (ATE)**. Tarea de etiquetado a nivel de *token* (típicamente con esquema BIO o similar) que identifica las menciones explícitas de aspectos en el texto. Dada la frase “*La pizza es deliciosa pero el servicio terrible.*”, se extraen $\{\text{pizza}, \text{servicio}\}$.
- **Aspect Category Detection (ACD)**. Clasificación multi-etiqueta del texto sobre un conjunto cerrado $\mathcal{C}$ de categorías predefinidas, dependiente del dominio. A diferencia de ATE, ACD captura aspectos *implícitos* no mencionados explícitamente; por ejemplo, “*Está muy sobrevalorado y no estaba sabroso.*” se clasifica en $\{\text{precio}, \text{comida}\}$ aunque ninguno aparezca como término.
- **Aspect Sentiment Classification (ASC)**. Predicción de la polaridad asociada a un aspecto dado, condicionando la clasificación al contexto aspecto-específico de la frase. Es comúnmente formulada como clasificación a nivel de oración con un par (s, a) como entrada.

En la presente tesis se adopta el paradigma **ACD + ASC**: la categoría de aspecto se predice mediante clasificación zero-shot vía NLI (Sección 3.3.4) y, condicionalmente al aspecto detectado, se aplica un clasificador de sentimiento basado en un codificador Transformer con ajuste fino sobre reseñas en español (Sección 3.3.5). Esta elección está motivada por dos consideraciones: (i) la ausencia de datos etiquetados a nivel de




Figura 3.2: Taxonomía de las tareas de ABSA. Reconstruido de W. Zhang y cols. (2023).

aspecto para Pueblos Mágicos hace inviables los enfoques supervisados, y (ii) el conjunto de aspectos relevantes varía entre tipos de establecimiento, lo cual se acomoda naturalmente a un esquema condicional en el que el conjunto de etiquetas candidatas se ajusta dinámicamente sin reentrenar.

3.3.3. Detección de fronteras de oración

Antes de aplicar cualquier modelo de clasificación a las reseñas, el texto debe segmentarse en unidades coherentes sobre las que se predican los aspectos. Esta tarea, conocida como *Sentence Boundary Detection* (SBD) o *Sentence Boundary Disambiguation*, consiste en identificar el conjunto de posiciones del texto que corresponden a finales de oración. Aunque suele tratarse como un paso de preprocesamiento trivial, los errores en SBD se propagan a las etapas posteriores de la cadena de NLP, degradando el rendimiento de etiquetadores morfosintácticos, analizadores semánticos y clasificadores (Read, Dridan, Oepen, y Solberg, 2012). Para el caso del ABSA, una segmentación deficiente puede unir en un mismo fragmento juicios de polaridad opuesta sobre aspectos distintos, frustrando el principio de granularidad fina sobre el que se sustenta la tarea.

La dificultad principal del SBD reside en la *ambigüedad del punto*: el grafema ‘.’ actúa simultáneamente como marcador de final de oración, parte de abreviaturas (e.g., *Sr.*, *Av.*), separador de números ordinales o decimales e indicador de iniciales. Las aproximaciones a esta tarea se agrupan en tres familias: (i) sistemas *basados en reglas*, que combinan heurísticas con listas curadas de abreviaturas; (ii) sistemas *supervisados*, entrenados sobre corpus con fronteras anotadas mediante clasificadores de máxima entropía, SVM o redes neuronales; y (iii) sistemas *no supervisados*, que infieren las fronteras a partir de regularidades distribucionales del propio corpus, sin requerir anotación manual. La revisión empírica de Read y cols. (2012) sobre nueve sistemas y cuatro corpus muestra una variabilidad de rendimiento considerable entre dominios y tipos de texto, y advierte que las evaluaciones tradicionales sobre prosa formal (Wall Street Journal, Brown) sobrestiman la robustez de los segmentadores cuando se aplican a contenido generado por usuarios, donde la puntuación es irregular y el registro es informal.

En este trabajo se adopta el segmentador no supervisado **Punkt** (Kiss y Strunk, 2006). La hipótesis central de Punkt es que la mayor parte de las ambigüedades del punto puede resolverse identificando primero las abreviaturas presentes en el corpus, ya que toda posición que no siga a una abreviatura se clasifica directamente como frontera. Una abreviatura se caracteriza, sin información contextual, mediante tres propiedades del tipo léxico:

- **Colocación con el punto.** La palabra truncada y el punto final forman una colocación estricta; se cuantifica con la verosimilitud logarítmica

$$\log \lambda(w, ‘.’) = -2 \log \frac{L(p_0; k_1, n_1) L(p_0; k_2, n_2)}{L(p_1; k_1, n_1) L(p_2; k_2, n_2)} \quad (3.30)$$

donde $L(\cdot)$ es la verosimilitud bajo el modelo binomial, k_i, n_i son conteos de coocurrencia y p_0, p_1, p_2 son las estimaciones bajo independencia y dependencia, respectivamente.

- **Brevedad del tipo.** Las abreviaturas tienden a ser cortas; la probabilidad de que un tipo w sea abreviatura decae con su longitud.
- **Puntos internos.** Los tipos que contienen puntos en su interior (e.g., *a.m.*) son fuertes candidatos a abreviatura.

La combinación multiplicativa de estos tres factores produce un *score* de abreviatura por tipo, sobre el que un umbral global decide la clasificación. Una segunda fase a nivel de *token* resuelve los casos restantes (números ordinales, iniciales y palabras que pueden ser tanto abreviaturas como ordinarias) usando rasgos contextuales como la capitalización de la palabra siguiente. Kiss y Strunk (2006) reportan una precisión media del 98.74 % sobre corpus periodísticos en once idiomas (incluyendo el español) sin ninguna adaptación específica al idioma, lo que justifica su elección como segmentador en este trabajo, dado el carácter multilingüe-agnóstico de su entrenamiento y la ausencia de un corpus de reseñas turísticas en español con fronteras de oración anotadas. La salida de Punkt define los fragmentos $\{t_1, \dots, t_F\}$ sobre los que se aplican posteriormente la detección de aspecto y la clasificación de sentimiento.

3.3.4. Clasificación zero-shot vía NLI

La clasificación zero-shot tiene por objetivo asignar etiquetas a un texto sin disponer de ejemplos anotados para las clases objetivo (Yin, Hay, y Roth, 2019). Formalmente, se considera el escenario *label-fully-unseen*: aprender un clasificador $f : \mathcal{X} \rightarrow \mathcal{Y}$ tal que f no observa ningún dato etiquetado específico para las clases en $\mathcal{Y}$ durante su entrenamiento. Esta formulación es particularmente adecuada para ACD en dominios sin *benchmarks* curados, ya que permite definir el conjunto de aspectos $\mathcal{C}$ post-hoc y modificarlo sin reentrenamiento.

Yin y cols. (2019) proponen tratar la clasificación zero-shot como un problema de *Natural Language Inference* (NLI). La tarea de NLI es una tarea de clasificación supervisada que consiste en determinar la relación entre una premisa t y una hipótesis h mediante tres clases: implicación, contradicción y neutralidad (MacCartney, 2009). La idea consiste en convertir cada etiqueta candidata $c \in \mathcal{C}$ en una hipótesis h_c mediante una plantilla parametrizada (e.g., “*Este texto habla sobre $\{c\}$.*”) y, dada una premisa t (la oración o reseña), evaluar la probabilidad de implicación usando un modelo NLI preentrenado. La etiqueta predicha es entonces:

$$\hat{c} = \arg \max_{c \in \mathcal{C}} \Pr(\text{entailment} \mid t, h_c) \quad (3.31)$$

En el caso multi-etiqueta, se aplica un umbral τ y se devuelven $\{c \in \mathcal{C} : \Pr(\text{entailment} \mid t, h_c) > \tau\}$. Yin y cols. (2019) muestran que un modelo BERT ajustado finamente

sobre MNLI (Williams, Nangia, y Bowman, 2018) generaliza competitivamente a tareas de detección de aspectos no vistas, superando enfoques basados en *embeddings* estáticos (Word2Vec, ESA) por márgenes significativos en clases no vistas.

3.3.5. Transformers para clasificación de sentimiento

La subtarea ASC se formula como un problema de clasificación supervisada sobre representaciones contextuales producidas por un codificador Transformer. Dada una secuencia de entrada $t = (w_1, \dots, w_n)$, los modelos tipo BERT/RoBERTa anteponen un token especial [CLS] y producen, tras L capas de *self-attention*, una matriz de *embeddings* contextuales $\mathbf{H} \in \mathbb{R}^{(n+1) \times d}$. Para tareas de clasificación a nivel de oración se adopta el vector $\mathbf{h}_{[\text{CLS}]} \in \mathbb{R}^d$ asociado al token especial como representación agregada de la secuencia, y se añade una cabeza de clasificación lineal:

$$\Pr(s \mid t) = \text{softmax}(\mathbf{W} \mathbf{h}_{[\text{CLS}]} + \mathbf{b}), \quad \mathbf{W} \in \mathbb{R}^{|\mathcal{S}| \times d}, \mathbf{b} \in \mathbb{R}^{|\mathcal{S}|} \quad (3.32)$$

donde $\mathcal{S}$ es el conjunto de clases. Los parámetros de la cabeza, junto con los del codificador, se ajustan minimizando la entropía cruzada sobre un corpus etiquetado de la tarea *downstream*. Este esquema transfiere el conocimiento lingüístico capturado durante el preentrenamiento a tareas con relativamente pocos ejemplos etiquetados, superando consistentemente a las arquitecturas recurrentes y a los enfoques léxicos en clasificación de sentimiento (Do y cols., 2019).

Para el español existen varios modelos base ampliamente utilizados — BETO (Cañete y cols., 2020), RoBERTuito (Pérez, Furman, Alonso Alemany, y Luque, 2022) — que difieren en el corpus de preentrenamiento y, consecuentemente, en el dominio en el que mejor generalizan (Do y cols., 2019). El modelo seleccionado en este trabajo¹ parte de un RoBERTa base (Conneau y cols., 2019) preentrenado sobre la Biblioteca Nacional de España (BNE) y posteriormente adaptado al dominio TripAdvisor mediante *fine-tuning* para clasificación de sentimiento de granularidad fina, produciendo cinco clases ordinales:

$$\mathcal{S} = \{\text{Muy Negativo, Negativo, Neutral, Positivo, Muy Positivo}\}$$

La granularidad de cinco clases preserva información entre diferentes niveles de satisfacción y resulta consistente con la escala de 1 a 5 estrellas que usualmente se asigna en el dominio turístico.

3.4. Sistemas de recomendación con ABSA

El análisis de sentimientos basado en aspectos produce, para cada reseña asociada a un par usuario-ítem, un conjunto de pares aspecto-sentimiento que indica qué atri-

¹<https://huggingface.co/vg055/roberta-base-bne-finetuned-TripAdvisorDomainAdaptation-finetuned-e2-RestMex2023-polaridadDA-V1>

butos del ítem menciona el usuario y con qué polaridad los valora. Esta información de granularidad fina permite enriquecer a los sistemas de recomendación clásicos, que por sí solos disponen únicamente de una calificación numérica global por interacción y descartan los matices expresados en el texto. El modelo de referencia para incorporar dichas señales es el *Explicit Factor Model* (EFM) propuesto por [Y. Zhang y cols. \(2014\)](#), cuyas representaciones aspectuales constituyen la base de la propuesta desarrollada en esta tesis.

El EFM organiza la información extraída por ABSA en dos matrices que describen, respectivamente, las preferencias de los usuarios y las cualidades de los ítems sobre un espacio común de aspectos. Se denota por $\mathcal{U}$ al conjunto de usuarios, por $\mathcal{I}$ al de ítems y por $\mathcal{A}$ al de aspectos considerados.

La *matriz de atención del usuario* $\mathbf{X} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{A}|}$ codifica la importancia que cada usuario u concede al aspecto a . Su valor crece con la frecuencia con que el usuario menciona ese aspecto en sus reseñas, frecuencia que se transforma mediante una sigmoide para acotar el resultado en el intervalo $[1, N]$, donde N es el extremo superior de la escala de calificación:

$$X_{u,a} = 1 + (N - 1) \left(\frac{2}{1 + \exp(-t_{u,a})} - 1 \right), \quad (3.33)$$

con $t_{u,a}$ el número de menciones del aspecto a por parte del usuario u . La intuición subyacente es que un aspecto mencionado con insistencia revela una preocupación genuina del usuario por ese atributo.

La *matriz de calidad del ítem* $\mathbf{Y} \in \mathbb{R}^{|\mathcal{I}| \times |\mathcal{A}|}$ codifica qué tan bien evaluado está cada ítem i en el aspecto a . Para ello combina el sentimiento promedio $s_{i,a}$ que la comunidad expresa sobre ese aspecto con el volumen de menciones $t_{i,a}$ que lo respaldan, de modo que una valoración positiva sostenida por muchas opiniones pesa más que un juicio aislado:

$$Y_{i,a} = 1 + \frac{N - 1}{1 + \exp(-t_{i,a} \cdot s_{i,a})}. \quad (3.34)$$

Con ambas matrices, el EFM predice la calificación que el usuario u otorgaría al ítem i sumando dos contribuciones. La primera es un término explícito, el producto interno entre la atención del usuario y la calidad del ítem en el espacio de aspectos, que resulta directamente interpretable. La segunda es un término latente al estilo de la factorización matricial, que captura patrones residuales no explicados por los aspectos:

$$\hat{r}_{u,i} = \alpha \frac{\mathbf{X}_u^\top \mathbf{Y}_i}{|\mathcal{A}|} + (1 - \alpha) \mathbf{p}_u^\top \mathbf{q}_i, \quad (3.35)$$

donde $\mathbf{p}_u$ y $\mathbf{q}_i$ son los vectores latentes de usuario e ítem, y el escalar $\alpha \in [0, 1]$ regula el peso relativo de cada contribución. La virtud del término explícito es que vincula la salida del recomendador con la representación aspectual extraída del texto. En el modelo original esto habilita justificaciones legibles de la recomendación, como afirmar que se sugiere Taxco porque el usuario valora la *cultura* y la *naturaleza*,

dos aspectos que la comunidad evalúa de forma sobresaliente en ese pueblo.

Conviene precisar el alcance con el que esta tesis adopta el EFM. De este modelo se reutilizan las dos matrices de aspectos, la de atención del usuario $\mathbf{X}$ y la de calidad del ítem $\mathbf{Y}$, por su carácter interpretable y porque reflejan de forma transparente las preferencias y las cualidades en términos de aspectos. No se instancia, en cambio, el modelo completo: la propuesta prescinde del término de factores latentes $\mathbf{p}_u^\top \mathbf{q}_i$ de la Ecuación (3.35). El componente basado en contenido del híbrido emplea solamente una versión normalizada del término explícito,

$$\hat{r}_{u,p} = \frac{\sum_{a \in \mathcal{A}} X_{u,a} Y_{p,a}}{\sum_{a \in \mathcal{A}} X_{u,a}}, \quad (3.36)$$

de manera que la predicción se interpreta como el grado de correspondencia entre la importancia que el usuario asigna a cada aspecto y la calidad del pueblo en ese mismo aspecto, sin recurrir a ninguna factorización latente. La construcción concreta de $\mathbf{X}$ e $\mathbf{Y}$ a partir del corpus REST-MEX y su combinación con el componente colaborativo en el recomendador híbrido se desarrollan en el capítulo de metodología.

Capítulo 4

Metodología

Este capítulo describe el procedimiento completo que transforma el corpus de reseñas REST-MEX en un sistema de recomendación híbrido evaluable. El recorrido sigue el orden en que se ejecuta la canalización. Primero se divide el conjunto de trabajo en particiones de entrenamiento y prueba mediante un esquema temporal por usuario que reproduce la situación real de predecir el siguiente destino (Sección 4.1). Sobre la partición de entrenamiento se aplica la canalización de análisis de sentimientos basado en aspectos, que segmenta cada reseña y le asigna pares aspecto-sentimiento con dos modelos Transformer (Sección 4.2). La salida aumentada con esta información se agrega en las tres matrices estructurales $\mathbf{A}$, $\mathbf{X}$ e $\mathbf{Y}$, cuya construcción retoma el modelo de factores explícitos del marco teórico y la ajusta con un estudio de ablación (Sección 4.3). A partir de esas matrices se definen los tres modelos individuales y el protocolo con que se evalúan (Sección 4.4). Por último, los dos modelos basados en aspectos se combinan en un híbrido de un solo parámetro y se formula el criterio con que se selecciona su peso de fusión (Sección 4.5). Los resultados de la evaluación, el barrido del peso de fusión y el análisis del compromiso entre relevancia y cobertura que da título a este trabajo se presentan en el Capítulo 5.

4.1. Partición del conjunto de datos

La evaluación de un sistema de recomendación debe estimar su capacidad para anticipar interacciones futuras, no para reconstruir interacciones ya observadas. Una partición aleatoria de las reseñas viola este principio, pues permitiría que el modelo aprendiera de visitas posteriores a las que pretende predecir. Por ello se adopta una partición temporal por usuario, conocida como *last-month-out*, que reserva para prueba la actividad más reciente de cada viajero y entrena con la anterior.

El procedimiento opera a nivel de par usuario-pueblo. Para cada usuario y cada Pueblo Mágico que ha reseñado se determina la primera fecha de estancia, tomada como el momento en que el usuario conoció ese destino. El mes de calendario de la estancia más reciente entre todos sus pueblos define su último mes activo. Los

pueblos cuya primera visita cae en ese último mes se asignan al conjunto de prueba y constituyen el objetivo a predecir, mientras que el resto de sus pueblos forman su historial de entrenamiento. Los usuarios cuyos pueblos se concentran en su totalidad en un único mes quedan sin historial previo y se excluyen de ambas particiones, ya que no aportan señal de entrenamiento ni permiten una evaluación honesta. Sus reseñas se conservan por separado únicamente con fines de auditoría.

Aplicado al conjunto de trabajo de 9,582 usuarios, el esquema excluye a 448 usuarios sin historial previo y deja 9,134 usuarios con presencia simultánea en entrenamiento y prueba. La partición resultante reserva en promedio el 28.6 % de los pueblos de cada usuario para prueba y el 71.4 % para entrenamiento, una proporción cercana al habitual reparto 70-30 pese a no haberse fijado de antemano, sino haber emergido de la dinámica temporal de las visitas.

Las Figuras 4.1 y 4.2 caracterizan la partición desde la perspectiva del usuario. La distribución de la fracción de pueblos enviados a prueba se concentra en valores moderados, con una mediana de 0.333 y una media de 0.286: en el caso típico, un tercio de los destinos de un usuario constituye su objetivo de prueba y los dos tercios restantes alimentan su perfil. La masa de la distribución se ubica por debajo de la mitad, lo que confirma que la mayoría de los usuarios conserva suficiente historial para que los modelos colaborativo y de contenido dispongan de evidencia sobre sus preferencias. En términos absolutos, la partición es deliberadamente exigente: la mediana es de un solo pueblo en prueba por usuario y la media de 1.12, con un máximo de siete. La fuerte asimetría hacia la izquierda, visible en la escala logarítmica de la Figura 4.2, refleja que para la mayor parte de los usuarios el sistema debe acertar un único destino dentro de un catálogo de 48 pueblos, lo que fija un listón alto para las métricas de relevancia reportadas más adelante.




Figura 4.1: Distribución del número de usuarios según la fracción de sus pueblos visitados que la partición *last-month-out* asigna al conjunto de prueba. Las líneas verticales señalan la media (0.286) y la mediana (0.333).




Figura 4.2: Distribución del número de usuarios según la cantidad de pueblos asignados al conjunto de prueba (eje vertical en escala logarítmica). La media es de 1.12 pueblos y la mediana de un solo pueblo.

4.2. Canalización de análisis basado en aspectos

El componente textual del sistema convierte cada reseña en un conjunto de pares aspecto-sentimiento que indican qué atributos del establecimiento menciona el usuario y con qué polaridad los valora. La Figura 4.3 resume la canalización, que se aplica exclusivamente sobre la partición de entrenamiento para evitar cualquier filtración de información hacia el conjunto de prueba.

Segmentación en fragmentos

La unidad de análisis no es la reseña completa sino el fragmento, porque una misma reseña suele emitir juicios de polaridad opuesta sobre aspectos distintos que conviene separar antes de clasificar. La segmentación emplea el algoritmo no supervisado Punkt (Kiss y Strunk, 2006), descrito en la Sección 3.3.3, que detecta fronteras de oración a partir de regularidades distribucionales del propio corpus sin requerir anotación manual. Su elección frente a una segmentación ingenua por longitud fija de caracteres no es arbitraria, sino el resultado de un análisis comparativo que se discute más abajo. Cada reseña produce así una secuencia de fragmentos; aquellos más cortos que un umbral mínimo se descartan por carecer de contenido evaluable, y los excepcionalmente largos se subdividen para no exceder la ventana de los clasificadores.

Clasificación de aspecto y de sentimiento

Sobre cada fragmento operan dos modelos Transformer independientes. El primero infiere el aspecto tratado mediante clasificación *zero-shot* formulada como inferencia




Figura 4.3: Canalización ABSA. Cada reseña se segmenta en fragmentos con el segmentador Punkt; sobre cada fragmento se aplican un clasificador de aspecto por inferencia textual y un clasificador de sentimiento de cinco clases. La salida es una tabla con un par aspecto-sentimiento por fila.

textual (Sección 3.3.4). Cada aspecto candidato se transforma en una hipótesis con la plantilla “Esta reseña trata sobre ⟨aspecto⟩.” y el modelo, un codificador en español ajustado a una tarea de inferencia, estima la probabilidad de implicación entre el fragmento y cada hipótesis (Yin y cols., 2019). El esquema es multietiqueta: un fragmento puede activar más de un aspecto si supera el umbral de confianza, lo que captura oraciones que valoran simultáneamente, por ejemplo, el servicio y el precio. El conjunto de aspectos candidatos se condiciona al tipo de establecimiento, de modo que solo se evalúan atributos pertinentes para cada categoría. Los restaurantes admiten servicio, precio, ambiente y comida; los hoteles añaden ubicación y habitación; y los atractivos sustituyen estos últimos por naturaleza y cultura. La unión de todas las categorías produce los ocho aspectos sobre los que se construirán después las matrices.

El segundo modelo asigna la polaridad del fragmento sobre una escala ordinal de cinco niveles, de Muy Negativo a Muy Positivo (Sección 3.3.5). Se trata de un RoBERTa en español preentrenado sobre la Biblioteca Nacional de España y posteriormente adaptado al dominio turístico (Y. Liu y cols., 2019), lo que alinea la granularidad de la predicción con la escala de calificación de una a cinco estrellas del propio corpus. La salida de la canalización es una tabla en la que cada fila corresponde a un par aspecto-sentimiento, acompañado de la confianza de ambos clasificadores, junto con los identificadores de usuario, pueblo, lugar y tipo necesarios para la agregación posterior.

Selección del segmentador

La decisión de segmentar con Punkt en lugar de partir el texto en bloques de longitud fija se sustenta en un estudio comparativo sobre el conjunto completo de reseñas,

resumido en la Tabla 4.1. La segmentación por caracteres genera más fragmentos (322,885 frente a 230,006) porque corta el texto a ciegas, sin respetar las fronteras lingüísticas, lo que produce unidades que parten oraciones por la mitad. El efecto sobre los clasificadores es asimétrico. La confianza mediana del clasificador de aspecto apenas cambia entre ambas estrategias, en torno a 0.48, pero la del clasificador de sentimiento cae de 0.843 con Punkt a 0.727 con el corte fijo. La explicación es que la polaridad depende críticamente del contexto local de la oración, que el corte por caracteres fragmenta, mientras que la detección de aspecto se apoya en palabras clave que sobreviven a la fragmentación. Dado que Punkt conserva la coherencia sintáctica con un número menor de fragmentos y mejora la confianza de la subtaska más sensible al contexto, se adopta como segmentador definitivo.

Tabla 4.1: Comparación entre la segmentación por oraciones (Punkt) y por bloques de caracteres de longitud fija, sobre el conjunto completo de reseñas.

Métrica	Punkt	Caracteres
Fragmentos generados	230,006	322,885
Fragmentos por reseña (media)	3.71	4.07
Longitud del fragmento (mediana, car.)	75	100
Confianza de aspecto (mediana)	0.483	0.480
Confianza de sentimiento (mediana)	0.843	0.727

La Figura 4.4 muestra la distribución de la confianza de ambos clasificadores sobre la salida definitiva. El contraste entre los dos paneles revela una asimetría informativa relevante. La confianza de sentimiento se acumula cerca de la unidad, con mediana 0.843, lo que indica que el modelo adaptado al dominio resuelve la polaridad con poca ambigüedad. La confianza de aspecto, en cambio, se reparte de forma mucho más extendida y se centra en torno a 0.483, reflejo de que la detección de aspecto en modo *zero-shot* es la subtaska intrínsecamente más difícil: opera sin ejemplos etiquetados, debe discriminar entre categorías semánticamente próximas y admite fragmentos que no tratan con claridad ninguno de los aspectos candidatos. Esta brecha justifica el filtrado por umbral de confianza en la detección de aspecto y anticipa que la señal de aspecto, más ruidosa, conviene agregarla por volumen antes de incorporarla a las matrices.

Finalmente, la Figura 4.5 confirma que el condicionamiento de los aspectos por tipo de establecimiento se traduce en perfiles coherentes con el dominio. Los aspectos exclusivos de cada categoría aparecen únicamente donde corresponde: la habitación y la ubicación se concentran en los hoteles, la comida en los restaurantes, y la naturaleza y la cultura en los atractivos turísticos, mientras que los aspectos transversales como el servicio y el ambiente se distribuyen entre las tres categorías. Esta coherencia valida que la canalización captura estructura semántica de dominio y no simplemente ruido.




Figura 4.4: Distribución de la confianza del clasificador de aspecto (izquierda) y del clasificador de sentimiento (derecha) sobre los fragmentos de la partición de entrenamiento. La línea discontinua marca la mediana de cada distribución.




Figura 4.5: Porcentaje de fragmentos por aspecto dentro de cada tipo de establecimiento. Los aspectos específicos de cada categoría aparecen solo donde son pertinentes, lo que evidencia el condicionamiento por tipo.

4.3. Construcción de las matrices estructurales

La información extraída por la canalización ABSA se agrega en tres matrices que constituyen la entrada común de todos los modelos. La matriz de calificaciones **A** resume la señal numérica de las interacciones, mientras que las matrices de atención del usuario **X** y de calidad del pueblo **Y** codifican las preferencias y las cualidades en el espacio de aspectos, siguiendo el modelo de factores explícitos de [Y. Zhang y cols. \(2014\)](#) presentado en la Sección 3.4.

Matriz de calificaciones

La matriz $\mathbf{A} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{Z}|}$ recoge la valoración global de cada usuario sobre cada pueblo. Su entrada es el promedio de las calificaciones que el usuario otorgó a los establecimientos del pueblo,

$$A_{u,p} = \frac{1}{|\mathcal{R}_{u,p}|} \sum_{r \in \mathcal{R}_{u,p}} \text{calif}(r), \quad (4.1)$$

donde $\mathcal{R}_{u,p}$ es el conjunto de reseñas del usuario u en el pueblo p . Las entradas correspondientes a pares no observados quedan vacías, lo que refleja la elevada dispersión del corpus (90.32 % de celdas sin observar) y delimita el universo de candidatos sobre el que opera la recomendación.

Matrices de aspectos

La matriz de atención del usuario $\mathbf{X} \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{A}|}$ mide la importancia que cada usuario concede a cada aspecto a partir de la frecuencia con que lo menciona. Siguiendo la forma sigmoideal de la Ecuación (3.33), pero introduciendo un factor de escala T_x , se define

$$X_{u,a} = 1 + (N - 1) \left(\frac{2}{1 + \exp(-t_{u,a}/T_x)} - 1 \right), \quad (4.2)$$

donde $t_{u,a}$ es el número de fragmentos en que el usuario u menciona el aspecto a , $N = 5$ es el extremo superior de la escala y T_x es la mediana de los conteos no nulos. El factor T_x sitúa el punto de inflexión de la sigmoide en la frecuencia típica de mención, de modo que la importancia discrimina entre usuarios en el rango de conteos efectivamente observado en lugar de saturarse.

La matriz de calidad del pueblo $\mathbf{Y} \in \mathbb{R}^{|\mathcal{Z}| \times |\mathcal{A}|}$ combina la polaridad media de la comunidad sobre cada aspecto con el volumen de menciones que la respalda. Partiendo de la Ecuación (3.34) y aplicando el mismo escalamiento,

$$Y_{p,a} = 1 + \frac{N - 1}{1 + \exp(-t_{p,a} s_{p,a}/T_y)}, \quad (4.3)$$

donde $s_{p,a} \in [-1, 1]$ es el sentimiento medio sobre el aspecto a en el pueblo p (obtenido al centrar y normalizar la escala de cinco clases), $t_{p,a}$ es el número de menciones que lo sustentan y T_y es la mediana de la magnitud no nula del producto $t_{p,a} s_{p,a}$. El producto sentimiento por volumen otorga más peso a una valoración positiva sostenida por muchas opiniones que a un juicio aislado, en línea con la intuición del modelo original.

Estudio de ablación

La transcripción literal de las Ecuaciones (3.33) y (3.34) introduce el conteo de menciones t directamente en el argumento de la sigmoide. En el corpus REST-MEX, donde un pueblo popular acumula cientos de menciones por aspecto, este conteo crece sin cota y satura la sigmoide: casi todas las entradas de $\mathbf{Y}$ se aproximan a su máximo y la matriz pierde capacidad de discriminación. El factor de escala T que aparece en las Ecuaciones (4.2) y (4.3) corrige precisamente este efecto al normalizar la señal por su magnitud típica. Para verificar que este ajuste es necesario y suficiente se diseñó un estudio de ablación que cruza dos decisiones sobre la construcción de las matrices: incorporar o no el escalamiento T , y ponderar o no el volumen mediante una compresión logarítmica adicional. La Tabla 4.2 reporta las cuatro variantes resultantes, evaluadas con el modelo de contenido a $K = 20$.

Tabla 4.2: Ablación de la construcción de $\mathbf{X}$ e $\mathbf{Y}$. La columna de saturación indica la fracción de entradas de $\mathbf{Y}$ que superan 4.5 sobre un máximo de 5. Resultados del modelo de contenido a $K = 20$.

Variante	Construcción de $\mathbf{Y}$	$\mathbf{Y}$ saturada	NDCG@20	Cov@20
A	volumen logarítmico + T	0.013	0.388	0.958
B	forma literal de Zhang (sin T)	0.979	0.324	0.896
C	escalamiento T (sin logaritmo), X literal	0.336	0.418	0.958
D	escalamiento T (sin logaritmo)	0.336	0.418	0.958

Los resultados son concluyentes. La variante B, que reproduce la forma literal del modelo de factores explícitos sin escalamiento, satura el 97.9% de las entradas de $\mathbf{Y}$ por encima de 4.5 y colapsa su varianza por fila, lo que la convierte en la peor configuración con un NDCG@10 de apenas 0.324. Introducir el escalamiento T (variantes C y D) reduce la saturación a un tercio de las entradas y recupera la capacidad de discriminación, con una ganancia cercana a nueve puntos de NDCG y seis de cobertura respecto de B. La compresión logarítmica del volumen (variante A) también evita la saturación, pero lo hace en exceso: comprime tanto la señal que rebaja el NDCG a 0.388, por debajo de las variantes que solo escalan con T . La comparación entre C y D, idénticas salvo en la construcción de $\mathbf{X}$, muestra además que aplicar el mismo escalamiento a la matriz del usuario evita que los aspectos muy frecuentes saturen su importancia. Se adopta por tanto la variante D, que conserva únicamente el término de escalamiento T en ambas matrices y descarta la ponderación logarítmica, tal como recogen las Ecuaciones (4.2) y (4.3).

4.4. Modelos de recomendación

A partir de las tres matrices se ajustan tres modelos individuales que cubren las dos grandes familias de la recomendación. El primero es un filtrado colaborativo

clásico que opera sobre las calificaciones; los otros dos explotan las representaciones de aspectos, uno por la vía colaborativa y otro por la vía de contenido. Todos generan una lista de los K pueblos no visitados con mayor puntuación predicha, y se evalúan con las métricas de relevancia, diversidad y cobertura definidas en la Sección 3.1.5, tomando como verdad de referencia los pueblos que cada usuario reservó para prueba.

CFClassic. Es la factorización matricial con sesgos descrita por la Ecuación (3.10) (Koren y cols., 2009). Predice la calificación como $\hat{r}_{u,p} = \mu + b_u + b_p + \mathbf{p}_u^\top \mathbf{q}_p$, donde μ es la media global, b_u y b_p los sesgos de usuario y pueblo, y $\mathbf{p}_u, \mathbf{q}_p$ los vectores latentes aprendidos por descenso de gradiente estocástico con regularización sobre las entradas observadas de $\mathbf{A}$. Constituye la referencia colaborativa basada exclusivamente en la señal numérica y, por construir su predicción a partir de $\mathbf{A}$, no interviene en el híbrido.

CFAttention. Es un filtrado colaborativo usuario-usuario cuya novedad reside en medir la afinidad entre usuarios en el espacio de aspectos en lugar de en el de calificaciones. La similitud se define a partir de la distancia euclidiana entre las filas de $\mathbf{X}$, $\text{sim}(u, v) = 1/(1 + \|\mathbf{X}_u - \mathbf{X}_v\|_2)$, y la predicción corrige la media del usuario con la desviación ponderada de sus vecinos más afines,

$$\hat{r}_{u,p} = \mu_u + \frac{\sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v) (A_{v,p} - \mu_v)}{\sum_{v \in \mathcal{N}_k(u)} |\text{sim}(u, v)|}, \quad (4.4)$$

con $\mathcal{N}_k(u)$ el conjunto de los k vecinos más similares que han visitado el pueblo p . De este modo las preferencias por aspecto, y no la coincidencia en calificaciones, gobiernan la formación de la vecindad. Es la rama colaborativa del híbrido.

CBQuality. Es el modelo de contenido derivado del término explícito del EFM, según la versión normalizada de la Ecuación (3.36). Predice $\hat{r}_{u,p} = \sum_a (X_{u,a} / \sum_{a'} X_{u,a'}) Y_{p,a}$, esto es, el grado de correspondencia entre la importancia que el usuario asigna a cada aspecto y la calidad del pueblo en ese mismo aspecto, sin recurrir a ningún factor latente. Es la rama de contenido del híbrido.

Los tres modelos se ajustan sobre las mismas matrices y particiones, y su rendimiento comparado, junto con las pruebas de significancia que lo sustentan, se reporta en la Sección 5.3.

4.5. Modelo híbrido y compromiso relevancia–cobertura

Como se documenta en el Capítulo 5, la relevancia y la cobertura provienen de componentes distintos: el modelo de contenido aporta el ordenamiento certero y el colaborativo la exposición del catálogo. El híbrido las combina mediante la fusión

convexa de la Ecuación (3.15), restringida a las dos ramas basadas en aspectos,

$$\hat{y}_{u,p}(\alpha) = \alpha \hat{y}_{u,p}^{\text{CFAttention}} + (1 - \alpha) \hat{y}_{u,p}^{\text{CBQuality}}, \quad \alpha \in [0, 1]. \quad (4.5)$$

Ambas ramas se ajustan una sola vez y el parámetro α se limita a reponderar sus predicciones, por lo que recorrer todo el rango de fusión es computacionalmente trivial. El extremo $\alpha = 0$ recupera el modelo de contenido puro y el extremo $\alpha = 1$ el colaborativo, de modo que la evaluación de los modelos individuales contiene ya los dos vértices de la fusión.

La selección de un único α se resuelve escalarizando los dos objetivos con un peso de preferencia β , según la Ecuación (3.27), y leyendo el óptimo $\alpha^*(\beta)$ directamente del barrido como indica la Ecuación (3.28). El barrido completo del peso de fusión, el análisis de sensibilidad del óptimo y el frente de Pareto realizado que ambos inducen se presentan en la Sección 5.6.

Capítulo 5

Resultados

Este capítulo evalúa el sistema construido en el Capítulo 4 y analiza su comportamiento desde la representación hasta la operación. El recorrido comienza en los perfiles de aspecto que la canalización ABSA induce sobre los usuarios: primero se estudia qué estructura poblacional exhiben (Sección 5.1) y después se verifica que sean coherentes con las visitas reales, tanto pasadas como futuras (Sección 5.2). Sobre esa base se comparan los tres modelos individuales con pruebas de significancia (Sección 5.3), se examina cómo reparten sus recomendaciones sobre el catálogo (Sección 5.4) y cómo varía su rendimiento con la cantidad de historial disponible (Sección 5.5). La Sección 5.6 presenta el barrido del peso de fusión y el frente de Pareto que dan respuesta a la pregunta central del trabajo. El capítulo cierra con dos análisis de operación: un estudio de caso que ilustra la capacidad explicativa del modelo de contenido (Sección 5.7) y una simulación que valida la incorporación de usuarios nuevos mediante una encuesta inicial (Sección 5.8). Salvo indicación en contrario, todos los resultados se calculan sobre los 9,134 usuarios de la partición de prueba, con $K = 10$ como corte principal y con las matrices construidas según la variante D del estudio de ablación.

5.1. Perfiles de aspecto de los usuarios

La matriz $\mathbf{X}$ asigna a cada usuario un vector de importancia sobre los ocho aspectos. Antes de usar esos perfiles para recomendar conviene preguntarse qué estructura poblacional inducen: ¿existen tipos de viajero reconocibles, o la representación solo registra cuánto escribe cada quien? Para responderlo se aplicó agrupamiento k -medias sobre dos representaciones complementarias del mismo perfil: las filas de $\mathbf{X}$ estandarizadas por aspecto, que conservan la magnitud absoluta de las importancias, y su versión normalizada $w_{u,a} = X_{u,a} / \sum_{a'} X_{u,a'}$, que retiene únicamente la orientación relativa del perfil y coincide con los pesos que emplea el modelo de contenido. El número de grupos se seleccionó con el coeficiente de silueta (Figura 5.1).

Las dos representaciones revelan dimensiones distintas y complementarias. Sobre la matriz cruda la mejor partición es binaria y separa a los usuarios por la intensidad




Figura 5.1: Coeficiente de silueta en función del número de clusters para las dos representaciones del perfil. La matriz cruda alcanza su máximo en $k = 2$ y la normalizada en $k = 3$.

global de sus menciones (Figura 5.2): un grupo mayoritario con importancias bajas en todos los aspectos y otro, cerca de un tercio de la población, con importancias uniformemente altas. Los dos grupos comparten una composición similar de tipos de establecimiento reseñados, de modo que esta dimensión no distingue gustos sino volumen de escritura: la forma sigmoidal de la Ecuación (4.2) traduce el número de fragmentos en importancia, y el rasgo dominante de la población es cuánta evidencia textual aporta cada usuario.




Figura 5.2: Centroides del agrupamiento sobre la matriz $\mathbf{X}$ cruda, en la escala original de importancia. La partición separa usuarios de baja y alta intensidad de mención, con el mismo orden relativo entre aspectos en ambos grupos.

Al descontar la intensidad mediante la normalización aparece la estructura temática. La mejor partición tiene tres grupos de tamaños comparables cuyos centroides se muestran en la Figura 5.3: un grupo orientado al hospedaje, que concentra su peso en la habitación y la ubicación; un grupo orientado a los atractivos, con los mayores pesos relativos en cultura y naturaleza; y un grupo gastronómico, cuyo aspecto dominante es la comida. Esta lectura se valida externamente con la composición de las reseñas de cada grupo: la mayoría de las reseñas del primer grupo proviene de hoteles, la del segundo de atractivos turísticos y la del tercero de restaurantes. La proyección

sobre las dos primeras componentes principales (Figura 5.4) muestra los tres lóbulos claramente diferenciados. En conjunto, el perfil ABSA codifica dos dimensiones interpretables, la intensidad con que el usuario opina y la orientación temática de sus opiniones, y la segunda coincide con el tipo de experiencia turística que el usuario consume, lo que confirma que la canalización captura señal de preferencia y no solo ruido de frecuencia.




Figura 5.3: Centroides del agrupamiento sobre el perfil normalizado $w_{u,a}$. Cada grupo concentra su peso relativo en una familia de aspectos: hospedaje (C0), cultura y naturaleza (C1) y gastronomía (C2).




Figura 5.4: Proyección de los perfiles normalizados sobre las dos primeras componentes principales, coloreada por cluster temático. Los tres grupos ocupan regiones diferenciadas del espacio de aspectos.

5.2. Coherencia de los perfiles con las visitas

Que los perfiles exhiban estructura no garantiza que describan el comportamiento de viaje. Esta sección cuantifica el ajuste entre el perfil de un usuario y los pueblos con los que interactúa mediante la coherencia

$$\text{coh}(u, S) = \text{corr} \left(\mathbf{X}_u, \frac{1}{|S|} \sum_{p \in S} \mathbf{Y}_p \right), \quad (5.1)$$

la correlación de Pearson entre el vector de importancias del usuario y el perfil medio de calidad de un conjunto S de pueblos. Se evalúan cuatro conjuntos por usuario: su historial de entrenamiento, sus visitas futuras (los pueblos de prueba), y las listas top-10 de cada rama del híbrido. Una precaución metodológica resulta esencial: como todas las filas de $\mathbf{Y}$ comparten un patrón común de aspectos populares, la coherencia de un conjunto crece espuriamente con su tamaño, así que cada conjunto se contrasta contra un nulo de conjuntos aleatorios del mismo tamaño y se reporta el exceso de coherencia respecto de ese nulo. La Figura 5.5 resume las distribuciones y las pruebas de Wilcoxon pareadas correspondientes.



Figura 5.5: Distribución por usuario del exceso de coherencia de cada conjunto respecto de conjuntos aleatorios del mismo tamaño. La línea discontinua marca el nivel del azar; la barra negra, la mediana.

El historial es significativamente más coherente que el azar (mediana del exceso $+0.066$, $p < 10^{-4}$, $r = 0.28$), lo que confirma que el perfil resume las preferencias expresadas en las visitas pasadas, en parte por construcción, pues $\mathbf{X}$ se estima con los fragmentos escritos en esos mismos pueblos. El resultado informativo aparece en los otros tres conjuntos. Las visitas futuras no son más coherentes que el azar ($p = 0.59$): el destino siguiente de un usuario no se parece, en la forma de su perfil de calidad, más de lo esperable a su patrón de importancias. Las listas del modelo de contenido tampoco lo son ($p = 0.22$), a pesar de que CBQuality selecciona maximizando el emparejamiento $\mathbf{X}_u \cdot \mathbf{Y}_p$; la explicación es que su puntuación premia el nivel absoluto

de calidad ponderado por la atención del usuario, no el parecido de forma que mide la correlación, de modo que el modelo recomienda pueblos sobresalientes en general y no pueblos con silueta de calidad similar al perfil. Las listas de CFAttention, en cambio, sí presentan un exceso de coherencia pequeño pero muy consistente ($r = 0.30$): al construir la vecindad en el espacio de aspectos, las recomendaciones heredan la forma del perfil del usuario. Estos contrastes anticipan los dos comportamientos de exposición que se documentan en la Sección 5.4 y matizan la lectura del modelo de contenido: su ventaja predictiva, que se cuantifica a continuación, proviene de identificar calidad agregada relevante para el usuario más que de replicar la forma exacta de su perfil.

5.3. Evaluación de los modelos individuales

La Tabla 5.1 reúne el rendimiento de los tres modelos para $K \in \{5, 10, 20\}$, evaluados sobre el mismo conjunto de usuarios de prueba. El patrón es nítido y revela una complementariedad que motiva la fusión. CBQuality domina con holgura en todas las métricas de relevancia y en todos los cortes: su NDCG@10 casi triplica el de los dos modelos colaborativos, y otro tanto ocurre con la exhaustividad y el acierto. Este resultado confirma que, bajo la fuerte dispersión del corpus, el emparejamiento de perfiles de aspecto recupera preferencias que la escasa coincidencia de calificaciones no permite estimar de forma fiable, en coherencia con las ventajas del filtrado de contenido ante el problema del arranque en frío. El precio que paga CBQuality es la cobertura: a $K = 5$ expone menos de la mitad del catálogo, porque tiende a concentrar sus recomendaciones en los pueblos de mayor calidad agregada. Los dos modelos colaborativos exhiben el comportamiento opuesto, con cobertura prácticamente total desde los cortes bajos pero con una relevancia muy inferior. Entre ellos, CFClassic quedan próximos, lo que indica que medir la afinidad entre usuarios en el espacio de aspectos no se traduce por sí sola en mejor ordenamiento, aunque sí aporta la cobertura que a CBQuality le falta. Esta tensión entre relevancia y cobertura es la que el modelo híbrido busca administrar.

Para descartar que estas diferencias se deban al azar se aplicó la prueba de rangos con signo de Wilcoxon, pareada por usuario sobre el NDCG@10, con corrección de Holm por comparaciones múltiples y el tamaño de efecto $r = |z|/\sqrt{n}$ (Tabla 5.2). Las tres comparaciones resultan significativas, pero los tamaños de efecto cuentan dos historias distintas. La ventaja de CBQuality sobre ambos modelos colaborativos es un efecto grande, mientras que la diferencia entre CFClassic y CFAttention, aunque detectable gracias al tamaño muestral, es de magnitud casi nula. En la práctica ambos colaborativos ordenan igual de bien, y la elección de CFAttention como rama del híbrido se justifica por operar en el mismo espacio de aspectos que el resto del sistema, no por una ganancia de relevancia.

Tabla 5.1: Rendimiento de los modelos individuales para distintos cortes K . P, R y NDCG denotan precisión, exhaustividad y *ranking*; MRR el rango recíproco medio; ILD la diversidad intra-lista; y Cov la cobertura de catálogo.

Modelo	K	P@ K	R@ K	NDCG@ K	MRR	ILD	Cov@ K
CBQuality	5	0.102	0.446	0.312	0.275	0.001	0.479
	10	0.068	0.610	0.366	0.296	0.004	0.729
	20	0.045	0.811	0.418	0.310	0.008	0.958
CFClassic	5	0.033	0.150	0.091	0.076	0.008	1.000
	10	0.032	0.284	0.135	0.095	0.007	1.000
	20	0.029	0.527	0.197	0.112	0.007	1.000
CFAttention	5	0.030	0.133	0.081	0.068	0.008	0.979
	10	0.029	0.261	0.123	0.086	0.007	1.000
	20	0.029	0.525	0.190	0.104	0.007	1.000

Tabla 5.2: Pruebas de Wilcoxon pareadas por usuario sobre el NDCG@10 de los modelos individuales. Δ es la diferencia de medias; los p-valores incluyen la corrección de Holm; r es el tamaño de efecto.

Modelo A	Modelo B	Δ NDCG@10	p	r
CBQuality	CFClassic	+0.231	$< 10^{-4}$	0.509
CBQuality	CFAttention	+0.243	$< 10^{-4}$	0.535
CFClassic	CFAttention	+0.013	$< 10^{-4}$	0.048

5.4. Distribución de las recomendaciones sobre el catálogo

Las métricas agregadas no revelan cómo se reparten las recomendaciones entre los 48 pueblos. Esta sección analiza la exposición de cada pueblo, definida como el número de listas top-10 en que aparece, y muestra que detrás de la disyuntiva relevancia-cobertura hay dos regímenes de distribución radicalmente distintos.

La Figura 5.6 presenta las curvas de Lorenz de la exposición. CBQuality concentra sus recomendaciones de forma extrema, con un coeficiente de Gini de 0.75: la mitad del catálogo apenas recibe exposición y trece pueblos no aparecen en ninguna lista. Los dos modelos colaborativos reparten la exposición de manera mucho más equitativa, con Gini cercano a 0.4 y sin pueblos excluidos, y el híbrido en su punto de operación se sitúa entre ambos extremos. La Figura 5.7 identifica el mecanismo: la exposición de CBQuality crece de forma casi monótona con la popularidad del pueblo en entrenamiento (correlación de Spearman de 0.90), con un comportamiento de umbral en el que solo los destinos con gran volumen de reseñas alcanzan exposición masiva. Es la firma de un sesgo de popularidad heredado: los pueblos con más reseñas

acumulan más menciones positivas, la señal volumen-ponderada de la Ecuación (4.3) los lleva a la parte alta de $\mathbf{Y}$, y el modelo de contenido los recomienda a casi todos los usuarios. La exposición de CFAttention, en cambio, es esencialmente independiente de la popularidad (Spearman de 0.05): al predecir con desviaciones respecto de la media de cada vecino, las vecindades locales del espacio de aspectos reparten las recomendaciones por todo el catálogo.




Figura 5.6: Curvas de Lorenz de la exposición por pueblo en las listas top-10, con el coeficiente de Gini de cada modelo. El híbrido se evalúa en su punto de operación $\alpha^*(\beta = 0.5)$.




Figura 5.7: Exposición de cada pueblo en función de su popularidad en entrenamiento (escala logarítmica) para las dos ramas del híbrido, con la correlación de Spearman correspondiente. CBQuality exhibe un umbral de popularidad; CFAttention es prácticamente insensible a ella.

El mismo contraste se observa a nivel de usuario. Comparando el NDCG@10 de las dos ramas usuario por usuario, CBQuality gana en el 56 % de los casos, CFAttention en el 13 % y el 31 % restante son empates, casi todos entre listas que no aciertan. La

ventaja del modelo de contenido es además transversal: se mantiene en los tres clusters temáticos de la Sección 5.1 y en todos los niveles de historial, con su máximo entre los usuarios de historial mínimo. Sin embargo, las listas de ambas ramas comparten en promedio menos del 16% de sus elementos, de modo que el colaborativo no es una versión degradada del contenido sino una fuente de candidatos genuinamente distinta. Esa complementariedad estructural es la que explota la fusión: la rama de contenido aporta el acierto y la colaborativa el resto del catálogo, y por eso el híbrido puede ganar cobertura sin renunciar del todo a la relevancia, como se cuantifica en la Sección 5.6.

5.5. Rendimiento por segmento de actividad

El esquema de partición deja historiales de entrenamiento de tamaño muy variable, desde un solo pueblo hasta decenas. La Figura 5.8 desglosa el NDCG@10 y la cobertura por segmento de historial, y muestra que la conclusión global es robusta: el orden entre modelos se preserva en los cuatro segmentos, con CBQuality al frente en todos ellos.




Figura 5.8: NDCG@10 (izquierda) y cobertura de catálogo dentro del segmento (derecha) según el número de pueblos en el historial de entrenamiento. El híbrido se evalúa en $\alpha^*(\beta = 0.5)$.

Dos observaciones merecen destacarse. Primero, la relevancia de CBQuality no se degrada con historiales cortos; de hecho alcanza su máximo en el segmento de un solo pueblo. El perfil de aspectos se construye con los fragmentos de texto del usuario, no con la coincidencia de sus calificaciones, así que unas pocas reseñas bastan para estimar una representación útil. Este es precisamente el comportamiento deseable frente al arranque en frío parcial, y anticipa la viabilidad de la encuesta de la Sección 5.8. Segundo, la cobertura de CBQuality sí depende fuertemente del historial: en los segmentos cortos sus listas se concentran en una fracción pequeña del catálogo y solo entre los usuarios más activos, cuyos pueblos populares ya fueron visitados y quedan

excluidos, el modelo se ve forzado a explorar destinos menos expuestos. Los modelos colaborativos mantienen cobertura casi total en todos los segmentos. La lectura conjunta refuerza el diagnóstico de la sección anterior: la limitación del modelo de contenido no es de relevancia sino de exposición, y es una limitación estructural que no desaparece con más historial de los usuarios típicos.

5.6. El híbrido y el compromiso relevancia-cobertura

La Figura 5.9 traza el barrido del peso de fusión a $K = 10$. El NDCG@10 desciende de forma monótona desde 0.366 en $\alpha = 0$ hasta 0.118 en $\alpha = 1$, con una pendiente que se acentúa a partir de $\alpha \approx 0.6$. La cobertura recorre el camino inverso: tras una breve meseta inicial, en la que incluso cede ligeramente respecto del contenido puro, crece de manera sostenida hasta saturarse en la totalidad del catálogo cerca de $\alpha = 0.96$. La relevancia proviene de CBQuality y la cobertura de CFAttention, y no existe un valor de α que maximice ambas simultáneamente. Esta es la manifestación empírica del compromiso multiobjetivo formalizado en la Sección 3.2.




Figura 5.9: Relevancia (NDCG@10) y cobertura (Cov@10) en función del peso de fusión α . Al aumentar α la relevancia decrece y la cobertura crece hasta saturarse, lo que evidencia el conflicto entre ambos objetivos.

La Figura 5.10 presenta el análisis de sensibilidad que resulta de aplicar el criterio de selección de la Sección 4.5, esto es, de escalarizar ambos objetivos con el peso de preferencia β y leer el óptimo $\alpha^*(\beta)$ directamente del barrido. La trayectoria del óptimo es una escalera con tres regímenes. Cuando la preferencia se concentra en la cobertura, el óptimo se instala en $\alpha^* = 0.96$, el menor peso que ya alcanza cobertura total; elevar α por encima solo sacrificaría relevancia sin ganar nada, así que esas configuraciones quedan descartadas. En una amplia franja intermedia de preferencias el óptimo se estabiliza en $\alpha^* = 0.8$, y cuando la relevancia domina la decisión el

óptimo salta al modelo de contenido puro. Resulta notable la amplitud del régimen central: para la mitad de las preferencias posibles la respuesta es la misma mezcla, un híbrido cargado hacia la rama colaborativa que conserva cerca de dos tercios de la relevancia del contenido puro con exposición casi completa del catálogo.




Figura 5.10: Trayectoria del óptimo $\alpha^*(\beta)$ (escalera) y métricas alcanzadas en él. Al priorizar la relevancia (β creciente) el óptimo se desplaza de un régimen colaborativo a uno de contenido puro, mientras la cobertura cede terreno y el NDCG@10 aumenta.

Finalmente, la Figura 5.11 representa el frente de Pareto realizado del sistema en el plano cobertura-relevancia, el análogo empírico del frente teórico de la Figura 3.1. Cada punto corresponde a un valor de α ; los puntos no dominados forman la frontera eficiente sobre la que debe situarse cualquier elección razonable de fusión. La frontera exhibe un codo pronunciado en $\alpha = 0.8$: hasta ese punto la cobertura se compra barata, cediendo relevancia de forma gradual, mientras que más allá el último tramo de cobertura exige un desplome de la relevancia. Ese codo coincide con el régimen central de la escalera $\alpha^*(\beta)$ y constituye el punto de operación natural del sistema cuando no existe una preferencia fuerte hacia ninguno de los dos objetivos. La mejora del híbrido en ese punto no es artefacto muestral: frente a CFAttention, su ganancia de relevancia es significativa y de efecto grande ($r = 0.51$), y la pérdida frente a CBQuality, significativa pero de efecto medio ($r = 0.33$), es el costo cuantificado de exponer prácticamente todo el catálogo. La elección final del peso de fusión deja así de ser una cuestión técnica para convertirse en una decisión de diseño sobre cuánta relevancia se está dispuesto a ceder a cambio de exponer una mayor parte del catálogo.

5.7. Estudio de caso: recomendaciones explicables

Una ventaja del modelo de factores explícitos frente a los factores latentes es que sus predicciones se descomponen en contribuciones interpretables. Como $\hat{r}_{u,p} =$




Figura 5.11: Frente de Pareto realizado del híbrido en el plano Cov@10–NDCG@10. Cada punto es un valor de α ; los puntos resaltados son no dominados y conforman la frontera eficiente, con un codo pronunciado en $\alpha = 0.8$.

$\sum_a w_{u,a} Y_{p,a}$, la fracción $w_{u,a} Y_{p,a} / \hat{r}_{u,p}$ mide cuánto aporta cada aspecto a la recomendación y habilita explicaciones del tipo “se recomienda este pueblo porque valoras la gastronomía y destaca en ella”. Para ilustrarlo se seleccionó un usuario por cada cluster temático de la Sección 5.1, exigiendo historial mínimo de tres pueblos, acierto en su lista top-10 y un perfil marcadamente orientado al aspecto firma de su grupo. La Figura 5.12 muestra sus perfiles y la Tabla 5.3 las recomendaciones resultantes con sus contribuciones dominantes.




Figura 5.12: Perfiles de importancia $\mathbf{X}_u$ de los tres usuarios seleccionados, uno por cluster temático. El aspecto firma del cluster se resalta en tono oscuro; las barras en el mínimo de la escala corresponden a aspectos nunca mencionados.

Los tres casos ilustran el mecanismo explicativo y, al mismo tiempo, sus límites. El usuario A, orientado al hospedaje, recibe recomendaciones justificadas por la habitación y la ubicación; el usuario B, de perfil cultural, recibe destinos arqueológicos y coloniales explicados por la cultura; y para el usuario C la gastronomía domina cada puntaje, con un acierto directo en sus visitas futuras. La explicación es fiel al modelo,

Tabla 5.3: Top-3 de CBQuality para los tres usuarios del estudio de caso, con la fracción del puntaje aportada por los aspectos dominantes. La última columna indica si el pueblo apareció en las visitas futuras del usuario.

Usuario	#	Pueblo	Contribuciones principales	Acierto
A (hospedaje)	1	Isla Mujeres	habitación 33 %, ubicación 24 %	
	2	San Cristóbal de las Casas	habitación 33 %, ubicación 24 %	
	3	Bacalar	habitación 33 %, ubicación 24 %	
B (cultura)	1	Tulum	cultura 34 %, ambiente 13 %	
	2	Isla Mujeres	cultura 34 %, ambiente 13 %	
	3	Palenque	cultura 34 %, ambiente 13 %	
C (gastronomía)	1	Tulum	comida 36 %, ambiente 18 %	✓
	2	Isla Mujeres	comida 36 %, ambiente 18 %	
	3	Bacalar	comida 36 %, ambiente 18 %	

no una racionalización a posteriori, porque reproduce exactamente la aritmética de la predicción. Ahora bien, los conjuntos recomendados se parecen mucho entre usuarios: los mismos destinos de alta calidad agregada aparecen en las tres listas y lo que cambia es la justificación y el ordenamiento fino. Es la manifestación individual de la concentración de exposición de la Sección 5.4, y delimita el papel real de la personalización en el modelo de contenido: personaliza la explicación y el orden más que el conjunto de candidatos.

5.8. Usuarios nuevos: perfil por encuesta

El sistema descansa en perfiles extraídos de reseñas, de modo que un usuario recién llegado, sin texto del cual extraer aspectos, plantea el caso extremo del arranque en frío. La arquitectura ofrece una solución natural: como las entradas de $\mathbf{X}$ viven en la escala $[1, 5]$, una encuesta de incorporación con ocho preguntas del tipo “del 1 al 5, ¿cuánto te importa cada aspecto?” produce directamente un perfil sintético $\mathbf{X}_u$ en la representación que ambas ramas consumen. CBQuality puede puntuar de inmediato el catálogo completo con ese perfil, y CFAttention puede construir la vecindad del nuevo usuario en el espacio de aspectos y predecir con las calificaciones de sus vecinos, sin requerir historial propio.

La pregunta empírica es cuánta calidad de recomendación se pierde al sustituir el perfil continuo minado por ABSA por las respuestas discretas de una encuesta. Para estimarlo se simuló la encuesta sobre los usuarios de prueba cuantizando su perfil real a los niveles que el cuestionario capturaría, con dos granularidades: cinco niveles (redondeo al entero más cercano) y tres niveles. La Tabla 5.4 y la Figura 5.13 comparan el sistema completo bajo las tres fuentes de perfil.

La degradación es prácticamente nula. Con la encuesta de cinco niveles las listas

Tabla 5.4: Simulación del perfil por encuesta: métricas a $K = 10$ al sustituir el perfil continuo por su versión cuantizada. El híbrido se evalúa en $\alpha^*(\beta = 0.5)$.

Perfil	CBQuality		CFAttention		Híbrido	
	NDCG	Cov	NDCG	Cov	NDCG	Cov
Continuo (ABSA)	0.366	0.729	0.122	1.000	0.252	0.979
Encuesta 5 niveles	0.366	0.729	0.122	1.000	0.249	0.979
Encuesta 3 niveles	0.365	0.729	0.122	1.000	0.247	0.958




Figura 5.13: NDCG@10 (izquierda) y Cov@10 (derecha) del sistema según la fuente del perfil de usuario: continuo minado por ABSA, encuesta de cinco niveles y encuesta de tres niveles.

top-10 del modelo de contenido conservan el 99 % de sus elementos y la correlación de rangos por usuario entre ambos puntajes es casi perfecta; incluso la versión de tres niveles retiene el 98 % de las listas y todas las métricas dentro del medio punto porcentual. La información del perfil que el sistema realmente explota reside en niveles gruesos de importancia, no en la precisión decimal de la frecuencia de menciones, así que ocho respuestas bastan para situar a un usuario nuevo en igualdad de condiciones con uno cuyo historial completo fue minado por la canalización. La simulación tiene una limitación que conviene explicitar: asume que el usuario declararía en la encuesta lo mismo que sus reseñas revelan, cuando la literatura sobre preferencias declaradas documenta sesgos de auto-reporte. Validar esa correspondencia con usuarios reales queda como trabajo futuro; lo que este experimento establece es que la representación no es el cuello de botella, y que la vía de incorporación por encuesta es viable sin modificar ninguna pieza del sistema.

Capítulo 6

Conclusiones y trabajo futuro

Referencias

- Adomavicius, G., y Tuzhilin, A. (2005, junio). Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6), 734–749. doi: 10.1109/TKDE.2005.99
- Aggarwal, C. C. (2016). *Recommender Systems: The Textbook*. Springer. doi: 10.1007/978-3-319-29659-3
- Álvarez-Carmona, M. Á., Arce-Cardenas, S., Fajardo-Delgado, D., Guerrero-Rodríguez, R., López-Monroy, A. P., Martínez-Miranda, J., ... Rodríguez-González, A. Y. (2021). Overview of REST-MEX at IberLEF 2021: Recommendation System for Mexican Tourist Texts. En *Procesamiento del Lenguaje Natural*.
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Bustio-Martínez, L., y Herrera-Semenets, V. (2025, septiembre). Overview of Rest-Mex at IberLEF 2025: Researching Sentiment Evaluation in Text for Mexican Magical Towns. *Procesamiento del Lenguaje Natural*, 75, 499–511. doi: 10.26342/2025-75-37
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Muñiz-Sánchez, V., López-Monroy, A. P., ... Bustio-Martínez, L. (2022). Overview of REST-MEX at IberLEF 2022: Recommendation System, Sentiment Analysis and COVID Semaphore Prediction for Mexican Tourist Texts. *Procesamiento del Lenguaje Natural*, 69, 289–299.
- Álvarez-Carmona, M. Á., Díaz-Pacheco, Á., Aranda, R., Rodríguez-González, A. Y., Muñiz-Sánchez, V., López-Monroy, A. P., ... Bustio-Martínez, L. (2023). Overview of REST-MEX at IberLEF 2023: Research on Sentiment Analysis Task for Mexican Tourist Texts. *Procesamiento del Lenguaje Natural*, 71, 425–436.
- Balabanović, M., y Shoham, Y. (1997). Fab: Content-based, collaborative recommendation. *Communications of the ACM*, 40(3), 66–72. doi: 10.1145/245108.245124
- Barr, N. A. (2020). *The economics of the welfare state*. Oxford university press.
- Billsus, D., Pazzani, M. J., y Chen, J. (2000). A learning agent for wireless news access. En *Proceedings of the 5th international conference on intelligent user interfaces (iui '00)* (pp. 33–36). ACM. doi: 10.1145/325737.325768
- Burke, R. (2002, noviembre). Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, 12(4), 331–370. doi:

- 10.1023/A:1021240730564
- Cañamares, R., Castells, P., y Moffat, A. (2020). Offline evaluation options for recommender systems. *Information Retrieval Journal*, 23(4), 387–410. doi: 10.1007/s10791-020-09371-3
- Cano, E., y Morisio, M. (2017). Hybrid recommender systems: A systematic literature review. *Intelligent Data Analysis*, 21(6), 1487–1524. doi: 10.3233/IDA-163209
- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., y Pérez, J. (2020). Spanish pre-trained bert model and evaluation data. En *Pml4dc at iclr 2020*.
- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., . . . Stoyanov, V. (2019). Unsupervised cross-lingual representation learning at scale. *CoRR*, abs/1911.02116. Descargado de <http://arxiv.org/abs/1911.02116>
- Deb, K. (2011). Multi-objective optimisation using evolutionary algorithms: an introduction. En *Multi-objective evolutionary optimisation for product design and manufacturing* (pp. 3–34). Springer.
- de Campos, L. M., Fernández-Luna, J. M., Huete, J. F., y Rueda-Morales, M. A. (2010). Combining content-based and collaborative recommendations: A hybrid approach based on Bayesian networks. *International Journal of Approximate Reasoning*, 51(7), 785–799. doi: 10.1016/j.ijar.2010.04.001
- Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 4171–4186). Association for Computational Linguistics. Descargado de <https://aclanthology.org/N19-1423> doi: 10.18653/v1/N19-1423
- Do, H. H., Prasad, P. W. C., Maag, A., y Alsadoon, A. (2019). Deep Learning for Aspect-Based Sentiment Analysis: A Comparative Review. *Expert Systems with Applications*, 118, 272–299. doi: 10.1016/j.eswa.2018.10.003
- Fernández Poncela, A. M. (2016). Una revisión del programa pueblos mágicos. *CULTUR: Revista de Cultura e Turismo*, 10(1 (Febrero)), 3–34.
- González-Barba, J. Á., Chiruzzo, L., y Jiménez-Zafra, S. M. (2025). Overview of IberLEF 2025: Natural Language Processing Challenges for Spanish and other Iberian Languages. En *Proceedings of the Iberian Languages Evaluation Forum (IberLEF 2025), co-located with the 41st Conference of the Spanish Society for Natural Language Processing (SEPLN 2025)*.
- Hossain, A., Sikder, A., y Andreou, P. (2025, diciembre). Concf: A hybrid deep learning model for semantic-aware collaborative filtering in recommender systems. En *2025 7th international conference on electrical information and communication technology (eict)* (p. 1–6). Descargado de <https://ieeexplore.ieee.org/document/11355628> doi: 10.1109/EICT68394.2025.11355628
- Kiss, T., y Strunk, J. (2006). Unsupervised Multilingual Sentence Boundary Detection. *Computational Linguistics*, 32(4), 485–525. Descargado de <https://aclanthology.org/J06-4003/> doi: 10.1162/coli.2006.32.4.485
- Koren, Y. (2008). Factorization Meets the Neighborhood: a Multifaceted Collaborative Filtering Model. En *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 426–

- 434). New York, NY, USA: Association for Computing Machinery. doi: 10.1145/1401890.1401944
- Koren, Y., Bell, R., y Volinsky, C. (2009, agosto). Matrix Factorization Techniques for Recommender Systems. *Computer*, 42(8), 30–37. doi: 10.1109/MC.2009.263
- Liu, B. (2012). Sentiment Analysis and Opinion Mining. *Synthesis Lectures on Human Language Technologies*, 5(1), 1–167. doi: 10.2200/S00416ED1V01Y201204HLT016
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., ... Stoyanov, V. (2019). Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.
- Lops, P., de Gemmis, M., y Semeraro, G. (2011). Content-based Recommender Systems: State of the Art and Trends. En F. Ricci, L. Rokach, B. Shapira, y P. B. Kantor (Eds.), *Recommender Systems Handbook* (pp. 73–105). Springer. doi: 10.1007/978-0-387-85820-3_3
- MacCartney, B. (2009). *Natural language inference*. Stanford University.
- Marler, R. T., y Arora, J. S. (2004). Survey of multi-objective optimization methods for engineering. *Structural and multidisciplinary optimization*, 26(6), 369–395.
- Miettinen, K. (1999). *Nonlinear multiobjective optimization* (Vol. 12). Springer Science & Business Media.
- Mikolov, T., Chen, K., Corrado, G., y Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space*. arXiv:1301.3781 [cs]. arXiv. Descargado de <http://arxiv.org/abs/1301.3781> doi: 10.48550/arXiv.1301.3781
- Mooney, R. J., y Roy, L. (2000). Content-based book recommending using learning for text categorization. En *Proceedings of the fifth acm conference on digital libraries (dl '00)* (pp. 195–204). ACM. doi: 10.1145/336597.336662
- Musto, C., de Gemmis, M., Semeraro, G., y Lops, P. (2017, agosto). A Multi-criteria Recommender System Exploiting Aspect-based Sentiment Analysis of Users' Reviews. En *Proceedings of the Eleventh ACM Conference on Recommender Systems* (pp. 321–325). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/3109859.3109905> doi: 10.1145/3109859.3109905
- Oard, D. W., Kim, J., y cols. (1998). Implicit feedback for recommender systems. En *Proceedings of the aaai workshop on recommender systems* (Vol. 83, pp. 81–83).
- Payandenick, M., Othman, M. K., y Payandenick, M. (2025, noviembre). A multi-criteria recommendation system for personalised tourism experiences with user query analysis. *Information Technology & Tourism*, 28(1), 3. Descargado de <https://doi.org/10.1007/s40558-025-00348-w> doi: 10.1007/s40558-025-00348-w
- Pazzani, M. J., y Billsus, D. (2007). Content-Based Recommendation Systems. En *The Adaptive Web* (pp. 325–341). Springer. doi: 10.1007/978-3-540-72079-9_10
- Pennington, J., Socher, R., y Manning, C. D. (2014). Glove: Global vectors for word representation. En *Proceedings of the 2014 conference on empirical methods in natural language processing (emnlp)* (pp. 1532–1543).
- Pérez, J. M., Furman, D. A., Alonso Alemany, L., y Luque, F. M. (2022, junio). RoBERTuito: a pre-trained language model for social media text in Spanish.

- En *Proceedings of the thirteenth language resources and evaluation conference* (pp. 7235–7243). Marseille, France: European Language Resources Association. Descargado de <https://aclanthology.org/2022.lrec-1.785>
- Pontiki, M., Galanis, D., Papageorgiou, H., Androutsopoulos, I., Manandhar, S., Al-Smadi, M., ... Eryigit, G. (2016). SemEval-2016 Task 5: Aspect Based Sentiment Analysis. En *Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval-2016)* (pp. 19–30). Association for Computational Linguistics. doi: 10.18653/v1/S16-1002
- Raza, S., Rahman, M., Kamawal, S., Toroghi, A., Raval, A., Navah, F., y Kazemini, A. (2025, octubre). *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*. arXiv. Descargado de <http://arxiv.org/abs/2407.13699> (arXiv:2407.13699 [cs]) doi: 10.48550/arXiv.2407.13699
- Read, J., Dridan, R., Oepen, S., y Solberg, L. J. (2012). Sentence Boundary Detection: A Long Solved Problem? En *Proceedings of COLING 2012: Posters* (pp. 985–994). Descargado de <https://aclanthology.org/C12-2096/>
- Sarkar, J. L., Majumder, A., Panigrahi, C. R., Roy, S., y Pati, B. (2023, marzo). Tourism recommendation system: a survey and future research directions. *Multimedia Tools and Applications*, 82(6), 8983–9027. Descargado de <https://doi.org/10.1007/s11042-022-12167-w> doi: 10.1007/s11042-022-12167-w
- SECTUR. (2025). *Pib turístico contribuyó con 8.7 % del total de la economía y alcanzó más de 2.71 billones de pesos en 2024*. Descargado de <http://www.gob.mx/sectur/articulos/pib-turistico-contribuyo-con-8-7-del-total-de-la-economia-y-alcanzo-mas-de-2-71-billones-de-pesos-en-2024>
- She, K.-S., Haw, S.-C., y Chew, L.-J. (2020, agosto). Tourism recommender system utilising property graph ontology as knowledge base. En *Proceedings of the 12th international conference on computer modeling and simulation* (p. 14–18). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/3408066.3408102> doi: 10.1145/3408066.3408102
- Smyth, B., y Cotter, P. (2000). A personalised TV listings service for the digital TV age. *Knowledge-Based Systems*, 13(2–3), 53–59. doi: 10.1016/S0950-7051(00)00046-0
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is All you Need. En *Advances in Neural Information Processing Systems* (Vol. 30). Curran Associates, Inc.
- Williams, A., Nangia, N., y Bowman, S. (2018). A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference. En *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 1112–1122). Association for Computational Linguistics. doi: 10.18653/v1/N18-1101
- Yin, W., Hay, J., y Roth, D. (2019). Benchmarking Zero-shot Text Classification: Datasets, Evaluation and Entailment Approach. En *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*

- (pp. 3914–3923). Association for Computational Linguistics. Descargado de <https://aclanthology.org/D19-1404> doi: 10.18653/v1/D19-1404
- Zangerle, E., y Bauer, C. (2022). Evaluating recommender systems: survey and framework. *ACM Computing Surveys*, 55(8), 1–38. doi: 10.1145/3556536
- Zhang, W., Li, X., Deng, Y., Bing, L., y Lam, W. (2023, noviembre). A Survey on Aspect-Based Sentiment Analysis: Tasks, Methods, and Challenges. *IEEE Transactions on Knowledge and Data Engineering*, 35(11), 11019–11038. Descargado de <https://ieeexplore.ieee.org/abstract/document/9996141> doi: 10.1109/TKDE.2022.3230975
- Zhang, Y., Lai, G., Zhang, M., Zhang, Y., Liu, Y., y Ma, S. (2014, julio). Explicit factor models for explainable recommendation based on phrase-level sentiment analysis. En *Proceedings of the 37th international ACM SIGIR conference on Research & development in information retrieval* (pp. 83–92). New York, NY, USA: Association for Computing Machinery. Descargado de <https://dl.acm.org/doi/10.1145/2600428.2609579> doi: 10.1145/2600428.2609579

Apéndice A

Anexo

